

中文图书分类号：TP399
密 级：公开
UDC：621.3
学 校 代 码：10016



北京建筑大学

BEIJING UNIVERSITY OF CIVIL ENGINEERING AND ARCHITECTURE

硕士专业学位论文

Dissertation for Professional Master's Degree

论 文 题 目：基于 WSM-CNN 及其改进的音乐多情感分类方法

研究与应用

论 文 作 者：冯亚寒

专业类别（领域）：机械

指 导 教 师：张昱、谭励

论文提交日期：2025 年 6 月



北京建筑大学

BEIJING UNIVERSITY OF CIVIL
ENGINEERING AND ARCHITECTURE

学 位 论 文

基于 WSM-CNN 及其改进的音乐多情感分类方法研究与 应用

Research and Application of Multi Sentiment Classification Method for Music
Based on WSM-CNN and Its Improvement

冯亚寒

指导教师姓名 张昱 副教授 北京建筑大学

谭励 教授 北京工商大学

申请学位级别 硕 士 学位类别 机械硕士学位

所 属 学 科 机械

年 级 2022 级 学 号 2108550022054

论文答辩时间 2025 年 6 月

答辩委员会主席 秦雷 研究员 北京信息科技大学

摘要

当前音乐情感分类研究至关重要，其中歌词的重要性不容忽视。歌词不仅是音乐灵魂，也是情感表达的基石。所以在音乐产业的蓬勃发展下，歌词情感分类显得尤为重要，对管理歌词信息、推动市场发展、促进数据深度挖掘有着显著作用。然而，现有研究多关注音频，对歌词多情感分类研究不足。此外，传统机器学习在情感特征提取和模型泛化上存在局限，深度学习技术的发展为该领域带来新机遇。为此本文在引入卷积神经网络的同时对其进行改进，提出并开展了基于 WSM-CNN 及其改进的音乐多情感分类方法研究与应用。具体工作为：

首先本文构建了音乐多情感分类的技术框架，为了解决音乐歌词分类研究中的数据不足和相关语料库缺乏的问题，对数据进行了采集和中文分词处理。后续为了制作适用于音乐多情感分类的词汇表，设计并实现了权重抽取和词频统计相结合的方法。在情感特征表示方面，本文利用 Word2Vec 词嵌入模型训练得到的词向量特征作为基础输入。接着本文通过情感特征选择技术，从原始特征集中筛选出了对分类任务有显著贡献的有效特征，旨在提升分类的准确性和效率。

其次在卷积神经网络的基础上进行了创新性改进，提出并实现了融合 Word2Vec 词嵌入的多核卷积神经网络音乐歌词多情感分类算法(WSM-CNN)，该算法利用 Word2Vec 词嵌入将歌词文本转化为词向量，并在单层卷积神经网络的基础上添加三种不同高度的卷积核，解决了传统方法难以提取情感特征、上下文信息提取困难等问题。实验结果表明，WSM-CNN 可以提高音乐多情感分类的准确性，精准率达到了 89.54%，分类结果高于其它对比模型，验证了该分类算法的有效性。

再者本文进一步设计并实现了结合自注意力机制的改进词嵌入音乐多情感分类算法(WSM-ACNN)，该算法是 WSM-CNN 上进行的有效改进，主要体现在将 N-grams 和情感词典加入 Word2Vec 词嵌入技术中，并在池化层操作之后加入注意力机制，以此在充分提取歌词情感特征的同时减少了模型的计算负担。实验结果表明 WSM-ACNN 精确率达到了 92.75%，优于 WSM-CNN 分类算法。后续又针对数据集占比不均衡的问题进行了均衡化处理，实验结果表明在均衡数据集的分类精确率达到了 94.52%，表明数据均衡性对于模型的性能是有一定提高的。

此外本文进一步采取了一系列策略，以有效应对模型训练过程中可能出现的鲁棒性差、梯度消失或爆炸等挑战，从而保障模型的稳定性和预测准确性。具体而言，本文对数据集进行了精心划分，划分为训练集、验证集和测试集，以评估和确保模型的泛化性能。为了降低模型对个别训练样本的过度依赖，本文引入了 Dropout 层。为了优化训练过程，采用了 RAdam 优化算法和正则化处理，旨在提高模型的质量和训练效率，增强其准确性。同时通过交叉验证的方法，对模型的性能进行了全面评估。总体而言，本文通过综合运用多种技术和方法，确保了模型的鲁棒性和预测的精确度。

最后在实现音乐多情感分类的基础上，将 WSM-ACNN 算法应用于个性化音乐情感推荐系统，设计并开发实现了可视化的音乐界面。系统建立了音乐情感分类和推荐的应用，实现了既能对音乐情感自动分类，又满足当代人听音乐的情感选择习惯需求。

综上所述，本文经过理论分析和实验验证，证明了提出算法的有效性，推动了音乐多情感分类领域的研究进展，可以为后续研究任务提供帮助和支持。

关键词：多情感分类；卷积神经网络；音乐歌词；个性化推荐系统。

Abstract

The current research on the sentiment classification of music is crucial, in which the importance of lyrics cannot be ignored. Lyrics are not only the soul of music, but also the cornerstone of emotional expression. Therefore, under the booming development of the music industry, lyrics sentiment classification is particularly important, which has a significant role in managing lyrics information, promoting market development, and facilitating data deep mining. However, existing research focuses on audio, and there is insufficient research on multi sentiment classification of lyrics. In addition, traditional machine learning has limitations in emotion feature extraction and model generalization, and the development of deep learning technology brings new opportunities for this field. For this reason, this thesis introduces convolutional neural network and improves it, and proposes and carries out the research and application of music multi sentiment classification method based on WSM-CNN and its improvement. The specific work is:

Firstly, this thesis constructs a technical framework for music multi sentiment categorization, and in order to solve the problems of insufficient data and lack of relevant corpus in music lyrics categorization research, the data are collected and processed by Chinese word segmentation. Subsequently, in order to produce a vocabulary list suitable for music multi sentiment classification, a combination of weight extraction and word frequency statistics is designed and implemented. In terms of sentiment feature representation, this thesis utilizes the word vector features obtained from Word2Vec word embedding model training as the base input. Then this thesis filters out effective features from the original feature set that contribute significantly to the classification task by means of the sentiment feature selection technique, aiming to improve the accuracy and efficiency of classification.

Secondly, based on the convolutional neural network, innovative improvements are made, and a multi-core convolutional neural network music lyrics multi sentiment classification algorithm incorporating Word2Vec word embedding (WSM-CNN) is proposed and implemented, which utilizes Word2Vec word embedding to convert lyrics text into word vectors, and adds three kinds of convolution kernels of different heights on the basis of a single-layer convolutional neural network to solve the problems such as the difficulty of extracting emotional features and the difficulty of extracting contextual information by traditional methods. The experimental results show that WSM-CNN can improve the accuracy of music multi sentiment classification, and the precision rate reaches 89.54%, the classification results are higher than other comparative models, which verifies the effectiveness of the classification algorithm.

Furthermore, this thesis further designs and implements an improved word embedded music multi sentiment classification algorithm (WSM-ACNN) incorporating the self-attention mechanism, which is an effective improvement on the WSM-CNN, which is mainly embodied

in the incorporation of N-grams and sentiment lexicon into Word2Vec word embedding technique and the addition of the attention mechanism after the pooling layer operation as a means of extracting the lyrics adequately while reducing the computational burden of the model. The experimental results show that WSM-ACNN can be used as an embedding technique for the lyrics. The experimental results show that WSM-ACNN achieves an accuracy rate of 92.75%, which is better than the WSM-CNN classification algorithm. Subsequently, a balancing process is carried out to deal with the problem of unbalanced datasets, and the experimental results show that the classification accuracy in the balanced data set reaches 94.52%, which indicates that data balancing is a certain degree of improvement for the performance of the model.

In addition this thesis further adopts a series of strategies to effectively deal with challenges such as poor robustness, vanishing or exploding gradients that may occur during model training, so as to safeguard the stability and prediction accuracy of the model. Specifically, in this thesis, the data set is carefully divided into training, validation and test sets to evaluate and ensure the generalization performance of the model. To reduce the model's over-reliance on individual training samples, a Dropout layer is introduced in this thesis. To optimize the training process, RAdam optimization algorithm and regularization are used, aiming to improve the quality and training efficiency of the model and enhance its accuracy. Meanwhile, the performance of the model is comprehensively evaluated through the cross-validation method. Overall, this thesis ensures the robustness of the model and the accuracy of the prediction by integrating multiple techniques and methods.

Finally, on the basis of realizing multi sentiment classification of music, the WSM-ACNN algorithm is applied to the personalized music sentiment recommendation system, and a visual music interface is designed and developed to realize it. The system establishes the application of music sentiment classification and recommendation, which realizes both the automatic classification of music sentiment and meets the demand of contemporary people's sentiment selection habit of listening to music.

In summary, this thesis, after theoretical analysis and experimental verification, proves the effectiveness of the proposed algorithm, promotes the research progress in the field of music multi sentiment classification, and can provide help and support for subsequent research tasks.

Keywords: multi sentiment classification; convolutional neural network; music lyrics; personalized recommendation system.

目 录

第 1 章 绪论.....	1
1.1 研究背景和意义.....	1
1.2 国内外研究现状.....	2
1.2.1 音乐情感分类.....	2
1.2.2 文本情感分类.....	3
1.2.3 歌词情感分类.....	4
1.3 论文组织内容.....	5
1.4 论文组织结构.....	6
第 2 章 音乐多情感分类技术框架	8
2.1 数据采集.....	9
2.2 数据预处理.....	10
2.2.1 制定音乐歌词长度.....	10
2.2.2 中文分词.....	12
2.2.3 数据整合	13
2.3 歌词特征提取.....	13
2.3.1 词频统计	13
2.3.2 去除停用词.....	14
2.3.3 情感向量表示.....	15
2.4 情感特征选择.....	17
2.5 分类器.....	18
2.5.1 机器学习分类算法.....	18
2.5.2 深度学习分类算法.....	20
2.6 本章小结.....	22
第 3 章 融合 Word2Vec 词嵌入的多核卷积神经网络音乐多情感分类 算法(WSM-CNN)	23
3.1 关键技术.....	23
3.1.1 Word2Vec 词嵌入	23
3.1.2 卷积神经网络.....	24
3.2 WSM-CNN 音乐歌词多情感分类算法	25
3.3 正则化和模型训练.....	27
3.3.1 模型正则化.....	27
3.3.2 模型训练.....	28
3.4 实验结果与分析.....	29
3.4.1 实验环境和参数设置.....	29

3.4.2 评价指标.....	29
3.4.3 实验结果与分析.....	30
3.5 本章小结.....	34
第 4 章 结合自注意力机制的改进词嵌入音乐多情感分类算法(WSM-ACNN)	35
4.1 关键技术.....	35
4.1.1 改进 Word2Vec.....	35
4.1.2 自注意力机制.....	35
4.2 WSM-ACNN 音乐多情感分类算法	36
4.3 RAdam 优化算法	37
4.4 实验结果与分析.....	39
4.4.1 实验结果对比分析.....	39
4.4.2 均衡和不均衡数据集验证实验.....	40
4.5 本章小结.....	42
第 5 章 个性化音乐情感推荐系统的设计与实现	43
5.1 个性化音乐情感推荐系统需求分析	43
5.2 个性化音乐情感推荐系统设计	43
5.3 个性化音乐情感推荐系统实现	44
5.4 本章小结.....	47
第 6 章 总结与展望	48
6.1 总结.....	48
6.2 展望.....	49
参考文献.....	50

第1章 绪论

1.1 研究背景和意义

在社会不断进步和民众生活水平逐渐提升的背景下,情感表达的形式及其应用范围亦持续地呈现出扩展的趋势。音乐,作为一种深受人们喜爱的艺术形式,不仅能够传达愉悦、悲伤,还能表达更加复杂和微妙的情感。它的情感表达往往源自人们的生活体验和情感体验,因此,音乐成为表达情感的重要载体^[1]。

用户在庞大的音乐数据库中寻找与自身情感相契合的音乐作品是一项既费时又困难的工作^[2],所以如何高效地管理这些曲库资源,已成为一个迫切需要解决的课题。几十年来,这种想更深入理解音乐和情感之间关系的兴趣一直激励着来自不同知识领域的研究人员^[3]。目前,音乐分类普遍采用“情感”、“流派”、“主题”等多个维度。鉴于音乐是人类表达情感和交流思想的重要方式,据统计^[4],在听众常用的音乐分类中,“情感”类别的使用频率仅次于“流派”,这表明听众对音乐情感分类有着极高的需求。恰好情感分类正是计算机科学的重要分支之一,在健康、商业、政治、金融和教育等各个领域都有应用^[5]。因此,音乐情感分类逐渐成为学术界关注的焦点^[6]。在当前研究中,大部分关于音乐情感分类的研究都集中在音频分析这一领域,即通过分析音乐的旋律、节奏和音色等音频特征来识别和分类音乐所表达的情感^[7]。这种方法虽然在一定程度上能够捕捉到音乐的情感特质,但音乐作为一种综合的艺术形式,其情感表达不仅仅局限于音频层面。歌词作为音乐的重要组成部分,不仅承载着音乐的情感表达,还蕴含着深厚的文化内涵和文字艺术。歌词作为音乐文本的载体,它能够直接传达创作者的情感意图和思想内涵,对于理解音乐的整体情感色彩具有重要的补充作用^[8,9]。因此,忽视歌词情感的研究可能会遗漏音乐情感表达的某些重要方面,导致情感分类结果的片面或不准确。在这一背景下,自动且准确地提取这些信息及其隐含的情感并进行分类,对不同的主体来说有不一样的价值。例如:对于用户来说,可以帮助他们更好地理解自己的情感需求;对于商家来说,可以提供定制化的音乐推荐服务;对于研究者来说,可以深入探索音乐歌词与情感之间的关系^[10]。总的来说,针对歌词的音乐多情感分类技术的发展,有助于推动音乐产业的创新和进步。

传统的音乐情感分类方法往往依赖于人工进行分类,这要求分类人员必须具备较高的音乐专业知识和敏感度^[11],这种方法存在着明显的局限性:效率低下,耗时耗力,难以应对当下海量的音乐曲目和快速变化的音乐市场,所以现在迫切需要一种能够高效处理大量数据的自动化分类模型。在这种情况下,一个准确度高、效率出众的音乐分类模型显得尤为重要^[12]。这样的模型可以利用计算机的强大算力,对音乐曲目进行自动化分类,从而减轻人工负担,提高分类效率。自然语言处理(Natural Language Processing, NLP)在人工智能领域占据着核心地位,专注于从文本数据中提炼出关键信息。在处理大

量歌词数据并实现其有效管理的过程中,信息检索和文本挖掘技术都属于 NLP 领域并已经成为全球研究关注的焦点。同时,深度神经网络,尤其是卷积神经网络取得突破性的成果^[13-15],不需要由语言专家和数据挖掘专家特意设计就可以实现自动分类^[16],为音乐情感分类提供了新的思路和坚实的理论支撑,有望推动该领域的研究走向新的高度。

随着互联网技术的不断进步,个性化推荐系统的研究已经历数十年之久。目前,在众多应用场景下,个性化推荐技术已经被广泛采用,为用户提供定制化的服务体验^[17,18]。这类系统特别适用于两类具有鲜明特点的领域。首先,这类领域需要拥有丰富的信息数据资源,其次,用户在这些领域中的需求往往不是固定的,而是模糊和动态变化的,他们的兴趣和偏好可能会随着时间和情境的变化而变化。音乐领域是一个典型的例子,它完美地符合上述两种特点。因为现代音乐平台能够提供数以千万计的音乐资源,新歌推出的速度之快令人目不暇接,普通用户根本无法全部听完并挑选出自己喜欢的音乐或者根据自己当下的情感进行歌曲选择。其次,音乐在生活中扮演着多角色,它不仅是一种艺术形式,还是一种情感表达的方式,常常被用作背景音乐来调节氛围或情绪。所以用户在选择音乐时往往没有明确的目标,他们可能只需要几首应景的歌曲来满足自己的情感需求。此外,音乐推荐服务的使用门槛较低,这使得用户很容易接受这种服务。在众多音乐资源中,大部分都是免费提供的,这进一步降低了用户尝试新音乐的门槛,使得个性化推荐系统在音乐领域具有广泛的应用前景^[19,20]。因此,开发一个能够实现音乐多情感分类的个性化推荐系统,不仅具有显著的实用价值,还能够带来可观的经济效益,促进音乐作品的传播、满足个性化需求,提升音乐欣赏的体验。

1.2 国内外研究现状

1.2.1 音乐情感分类

音乐情感分类任务的研究开始于上世纪 90 年代,是 Bruner^[21]在 1990 年首次尝试根据情绪对歌曲进行分类。研究者们开始采用针对音频信号的处理技术作为基础,对音乐进行类别划分。利用计算机从音频文件中提取出与之相关的声学特征,如音质、响度、节拍等,以此对音乐的流派进行区分。Trochidis^[22]和 Hu 等人^[23],他们通过从歌曲音频和音轨中提取的一组特征对情绪进行多标签分类,用于分类的特征源自歌曲的音色和节奏。Tiple 等人^[24]通过链接预处理、特征提取和分类步骤提出了一种新的情感分类系统,用于处理帧并提取与音乐相关的时间、频谱和能量特征。在 2006 年,Lu^[25]等学者在音乐情感分类领域做出了开创性的贡献,他们对音乐分类的过程进行了创新性的改进。传统的音乐分类方法通常直接对音乐作品进行分类,而他们提出了一种分层的分析过程,这一过程更加细致和深入,有助于更准确地捕捉音乐的情感特征。Liu^[26]提出了一种音乐频谱的自动识别和分类算法,该算法考虑了可以从音乐中提取的情感线索,用以提高分类精度。后来陈长风^[27]采用 CNN-LSTM 混合网络架构,针对情感分类任务,从音频数据中提取了一系列特征向量。对比单一的 CNN 分类模型准确率提升了 5%。Farinas 等学者^[28-31]提出的一系列模型被应用于基于音频的音乐分类任务中,这些改进后的模型

展现出了良好的分类性能。目前,在音乐情感分类领域,基于机器学习技术和深度神经网络的分类算法已经得到了深入的研究,并且取得了一定的标志性成果^[32,33]。

1.2.2 文本情感分类

在音乐情感分类的研究中,早期的工作主要集中在音频数据的分析上。这些研究通过分析音乐的旋律、节奏、和声等特征来推断音乐的情感内容^[34]。然而这些特征都没有考虑歌词文本数据。音乐的音频特征虽然能够捕捉到音乐的情感氛围,但单一的基于音频数据的音乐情感分类结果并不总是准确。歌词作为音乐的文本载体,承载着丰富的语义信息和情感色彩^[35]。随着自然语言处理技术的快速发展^[36,37],尤其是文本情感分类技术的不断进步,研究者们开始意识到音乐歌词中的巨大潜力。文本情感分类作为一种重要的自然语言处理应用技术,它是通过结合自然语言处理技术与情感分类的相关方法,来对文本中的情感信息进行识别、抽取和分析的过程^[38]。这一技术的核心目的是更深入地理解和洞察文本或内容背后所蕴含的情感倾向和态度^[39]。在这方面,Nasukawa 及其同事^[40]在早期的研究工作中首次提出了情感分类的概念,并将其定义为一个针对含有情感色彩的文本进行分类的流程。这一概念为后续的情感分类研究奠定了基础,推动了相关技术的快速发展。基于情感词典是国内外的学者最初对文本情感分类的研究内容,Whissell^[41]在 20 世纪 90 年代便提出了情感词典的概念,旨在分析情景喜剧中的情感色彩。李晨等人^[42]基于现有的情感词典及情感词缀词典对文本进行了情感标记。他们采用句法分析和语义分析等先进技术来识别文本中的情感修饰词,但这种方法在实际应用中的效果并不尽如人意,同时对计算资源的消耗也相对较高。随着研究的深入,一些学者使用卷积神经网络(Convolutional Neural Networks, CNN)用于分类短文本^[43]。此外,递归神经网络(Recurrent Neural Network, RNN)^[44]和字符级 CNN^[45]都用于文本分类。Feng 等人^[46]鉴于传统 RNN 无法有效捕获后续文本的特征信息的问题提出了双向 RNN 结构,该结构在情感分类的应用中取得了显著的效果提升。但 RNN 在处理长序列数据时,存在梯度消失或者爆炸的问题,并且可能难以捕捉文本的局部特征,另一个主流模型 CNN 很好地弥补了此类问题。后来,在 CNN-RNN 的基础上,提出了一种基于注意力的双向 CNN-RNN 深度模型,通过考虑双向的时间信息流来提取过去和未来的上下文,用于文本情感分类^[47],这提高了文本情感分类的性能。虽然上述方法已成功用于文本情感分类,但它们的准确性仍然受到语料库的限制^[48,49]。2002 年 Pang 等人^[50]采用电影数据集作为实验对象,使用不同的分类包括进行情感分类,实验结果显示,采用支持向量机方法的结果准确率最高。Bandhakavi 等研究者^[51]在情感分类领域贡献了一项创新性的工作,提出了一个基于 Unigram 的混合模型。这一创新方法在四个不同的新闻数据集上进行了测试,并取得了令人满意的效果。高凯龙等人^[52]利用改进的 CNN 在中文文本数据集上进行文本情感分类,取得了不错的分类效果。凌敏等人^[53]在处理新浪微博文本时,面对单词多义性和话题混淆这两个挑战性问题,提出了一种创新性的混合神经网络模型。这一模型的目的是更准确地捕捉微博中的情感倾向,从而提高情感分类的效率和质量。

Selvakumar 等人^[54]在对用户评论情感分类的研究中,提出了一种基于双向编码器表示的转换器(Bidirectional Encoder Representation from Transformers, BERT)的先进方法。

1.2.3 歌词情感分类

歌词情感分类是文本情感分类的一个重要分支,歌词是文本的一种特殊形式,它融合了音乐与语言的艺术表现。作为歌曲的重要组成部分,歌词不仅承载着音乐作品的主题和情感,而且通过富有节奏和韵律的语言,传达了创作者的意图和听众的情感共鸣。在文本分类领域,歌词因其独特的表达方式和丰富的情感内容而具有较高的研究价值。它可以作为一种独特的文本类型,用于研究情感表达、语言风格、文化特征等多个方面,从而为文本情感分类、风格识别和文化研究等领域提供新的视角和素材。利用歌词进行音乐分类是自然语言处理的重要分支,前人研究中常利用歌词挖掘和其他相关技术,将歌词以观点、态度或者其它不同类别作为指标进行情感分类^[55-57]。在先前的研究工作中 Chen^[58]等学者在 Lu 等人^[25]的基础上改进了原有的分类方法,将第二阶段的压力水平获取方式从基于音色和节奏特征转变为基于歌词分类。Dan 等学者^[59]在音乐情感分类领域的一项研究中,证明了融合歌词与音频信息的模型在分类效果上要优于仅使用音频信息的模型。龚安等^[60]提出了跨媒体分词模型的情感分类方法,然而该方法无法处理歌词信息中包含与类别标签相同的情感词问题,并且情感识别率也比较低。王洁等^[61]对中文歌词的音乐情感分类方法作出研究,并且提到了利用 Word2Vec 技术来构建中文情感词典,再利用 K-近邻算法得到分类结果。Jia^[62]提出了一种基于深度学习和改进注意机制的音乐情感分类方法,该方法利用词频逆文档频率和 Word2Vec 方法提取音乐歌词特征,构建了基于 CNN-LSTM 的情感分类模型。Yang 等学者^[63]提出一种基于歌词和评论的音乐情感分类方法,将音乐的歌词和评论中的实体词与构建的情感词典相匹配,并综合考虑了情感词的词频、情感强度和词性对情感分类的影响,最终利用 CNN 模型分类器输出分类结果。

鉴于前人的研究分析成果,虽然在技术上取得了显著进步,但在实际应用中仍然面临一些关键性的挑战和问题:

(1)音乐歌词:在现有的音乐情感分类研究中,大多数研究者将重点放在音频数据的处理上,通过分析音频信号的波形、频率和节奏等特征来推断音乐的情感内容。这种方法虽然能够捕捉到音乐的部分情感信息,但往往忽略了歌词文本所蕴含的丰富情感和语义内容。歌词是音乐中直接传递情感和故事的重要媒介,它通过文字的组合和排列,传达出创作者的情感态度和思想深度。但是,针对歌词进行情感分类的研究相对较少,这是一个被忽视的研究领域。

(2)特征提取:在当前的音乐情感分类研究中,一个普遍存在的问题是情感特征提取的不充分性,这一问题直接制约了分类算法的准确率。如今研究者在追求整体准确率的同时,可能会忽视那些在数据集中占比不均衡或者对整体精确率贡献不大的情感类别。这些类别虽然在单个样本中可能不那么显著,但在音乐情感分类的整体框架中却扮演着

重要角色。

(3)实际应用：在实际生活中，推荐系统发挥着越来越重要的作用，大多数的推荐系统只针对内容，对于音乐来说，针对用户的情感去进行个性化分类的系统少之又少，影响用户体验感。

为了解决上述问题，本文研究深入探索音乐多情感分类，包括但不限于改进特征提取方法、优化模型架构设计，以及寻找能够在精确率和训练时间之间取得平衡的解决方案。只有这样，才能推动音乐情感分类技术的进一步发展，使其在实际应用中发挥更大的作用。

1.3 论文组织内容

在音乐多情感分类的研究领域中存在诸多挑战，主要体现在：首先，音乐歌词的情感分类研究相对较少；其次，传统的分类方法在提取音乐情感特征方面存在困难；再者，提取上下文依赖信息的过程复杂且难度较大；此外，局部歌词特征提取的方法还不够成熟，以及情感标签的精细度也有待提高。针对这些挑战，本文的研究内容主要围绕四个核心部分展开。

(1)数据处理。首先，鉴于相关语料库缺失的问题进行了数据采集，接下来，依据构建的数据索引，执行中文文本的分词处理。在此过程中，本文采用了权重提取和词频分析的方法，构建了一个专门针对音乐歌词多情感分类的词汇集合。此外，利用 Word2Vec 词嵌入技术对词汇进行向量表示，生成的词向量特征作为模型的初始输入，有效支持了歌词情感特征的映射与提取。最后通过情感特征筛选机制，从海量的原始特征中筛选出具有代表性的有效特征，以供后续模型训练使用。

(2)音乐多情感分类算法。本文首先对传统的机器学习算法 KNN 和 SVM 进行了音乐多情感分类的复现研究，在此基础上本文对循环神经网络以及具有不同层数的卷积神经网络进行了针对音乐多情感分类的详细实验研究。此外，本文还对上述模型在执行音乐多情感分类任务时的性能进行了对比分析。然后为了提升音乐多情感分类的准确性，本文在 CNN 模型的基础上进行了创新性改进，提出并实现了 WSM-CNN。随后为了进一步探索了算法的优化空间，又提出了 WSM-ACNN 算法，实验结果也证明了算法的有效性和实用性，为音乐歌词情感分类领域的研究提供了新的视角和技术路径。

(3)模型正则化和优化算法。为了有效防止机器学习和深度学习模型在训练过程中鲁棒性差、梯度消失或爆炸等常见难题，本文采取了一系列的措施来确保模型的稳定性和准确性。在数据集方面进行了合理的划分，包括训练集、验证集和测试集，以确保模型的泛化能力。同时在实验过程中采用了正则化和交叉函数，有效降低计算资源消耗的同时也显著提升了模型的分类性能。为了防止过拟合，本文在模型中引入了 Dropout 层，有效地减少了模型对特定训练样本的依赖。此外还采用了 RAdam 优化算法来优化模型的训练过程，提高了模型训练的效率。

(4)个性化音乐情感推荐系统。本文构建了一个个性化的音乐情感推荐系统，其中采

用了 WSM-ACNN 模型以提升推荐系统的性能,设计并实现了一个音乐情感分类与推荐的一体化应用。在音乐情感分类方面,系统依据分类结果,将其与已分类的音乐库进行对应匹配。通过筛选出与用户偏好情感类别一致的音乐库,系统将为用户推荐相应的歌曲。此外,系统还会优先考虑推荐用户已标记为喜欢的音乐作品。该系统能够自动对音乐进行情感分类,同时满足了现代听众在情感选择上的个性化需求,为用户提供了更为精准和贴心的音乐推荐体验。

综上所述,本文的组织内容框架如图 1-1 所示。



图 1-1 组织内容框架

Fig.1-1 Organizational content framework

1.4 论文组织结构

本文的组织结构主要分为以下五个章节：

第 1 章，绪论。在本章中，首先对音乐多情感分类研究的背景及其意义进行了深入剖析，接着分别综述了音乐情感分类、文本情感分类以及歌词情感分类领域的技术发展现状。最后，对本文的整体组织内容和结构安排进行了概述。

第 2 章，音乐多情感分类技术框架。本章重点介绍了针对歌词进行音乐多情感分类的技术架构及其核心流程。内容涵盖了数据采集、数据预处理、歌词特征提取、情感特征选择以及分类器的选择多个环节，并对每一环节进行了细致的说明。在分类器部分，本文对比了传统的机器学习算法与深度学习算法，并对深度学习算法在后续第三章中进行了更加深入的探讨。

第 3 章，融合 Word2Vec 词嵌入的多核卷积神经网络音乐多情感分类算法 (WSM-CNN)。首先对本章所需要用到的关键技术进行了详细的阐述，并在此基础上进

行改进，提出了新的音乐多情感分类算法，此外进行了模型的正则化和模型训练，最后介绍了实验环境和相关参数设置以及衡量模型的评价指标，设计了对比实验，将本章所提出的融合 Word2Vec 词嵌入的多核卷积神经网络音乐多情感分类算法与选取的其它算法进行实验结果的展示和可视化对比分析。

第4章，结合自注意力机制的改进词嵌入音乐多情感分类算法(WSM-ACNN)。本章基于第三章的基础上进行了改进，提出了结合自注意力机制的改进词嵌入音乐多情感分类算法，一开始介绍了需要用到的改进技术，并选用 RAdam 算法作为模型的优化算法。继而，本文设计了多组对照实验来验证 WSM-ACNN 改进模型的有效性，而且还采用了可视化手段对结果进行了深入分析，直观地展现了 WSM-ACNN 模型在分类任务中的卓越表现。最后针对情感类别数据集不均衡的问题进行了均衡化处理，进一步验证算法的有效性和实用性。

第5章，个性化音乐情感推荐系统。本章主要设计并开发了关于音乐情感分类算法的具体应用系统。首先，本章深入分析了个性化音乐情感推荐系统的需求分析。接着，从系统的设计以及相关技术支撑两个角度出发，详细说明了系统的设计方案。最后一部分全面展示了个性化音乐情感推荐系统开发完成后的实际运行效果及其功能实现。

第2章 音乐多情感分类技术框架

本文提出了一种针对音乐多情感分类的技术框架，其详细结构如图 2-1 所示。该技术框架的核心处理流程可以分为以下几个关键步骤：数据采集、数据预处理、歌词特征提取、情感特征选择以及分类器的设计与训练。




图 2-1 音乐多情感分类技术框架

Fig.2-1 Framework for multi sentiment classification technology in music lyrics

在数据采集方面，本文采取了多元化的策略以确保数据集的全面性和时效性。一方面，本文使用了网络上公开的音乐歌词数据集，这些数据集通常包含了大量的音乐作品，能够提供基础的数据支持。然而，考虑到公开数据集可能存在一定的时限性，以及为了确保分类样本的多样性和丰富性，本文还采用了网络爬虫技术进行数据采集，从而抓取了大量含有情感标签的音乐歌词数据，使得数据集更加全面和均衡。综合这两方面的数据来源，本文构建了一个完整的数据集，为后续的音乐多情感分类提供了坚实的基础。在数据预处理阶段，考虑到数据集包含的歌词文本长度长短不一的问题，所以本文通过大数据可视化分析来探索数据集的分布特征，通过这一步骤，能够直观地观察到文本序列的长度分布，从而确定一个合适的歌词文本序列读取长度。这一过程对于数据后续处理至关重要，因为它可以确保歌词数据的完整性和代表性。接下来，对读取的数据进行中文分词和数据整合一系列处理，同时实现了对大量文本数据的高效读写批处理，以提高处理速度和效率，为后续的模式训练和分类工作提供了有力的保障。

在歌词特征提取阶段，本文针对音乐歌词的特殊性，采取了精细化的处理策略，利用词频统计的方法分析音乐歌词，对于构造的数据索引实施了一种权重抽取和词频统计相结合的策略，以此构建了适用于音乐歌词分类的词汇表。此外，为了提高分类的准确性，对词汇表进行了去除停用词的操作。在这一部分，本文比较了几种情感向量表示方

法,选用合适的工具将标准化后的歌词数据转换为词向量,为后续的情感特征选择和分类器训练提供有效的数据表示。

在情感特征选择阶段,对比了多种情感特征选择方法,通过比较筛选出最有利于音乐多情感分类的特征。这一做法的目的是在减少数据维度的同时,尽可能保留对音乐歌词分类最具影响力的特征。本文通过固定嵌入向量的维数,以确保分类器的输入数据具有统一的格式,为后续进行训练和模型优化提供便利。

在分类器开发过程阶段,本文采纳了多种算法来对输入数据进行预处理、训练及深度学习。本文对模型参数进行了细致的调整以提升模型性能。继而,利用一个独立的测试集对所训练模型进行了验证,旨在评估其分类效能。通过分析模型对测试集的分类输出,并结合特定的衡量标准,本文对模型的分类性能进行了详尽的验证与评价。

通过以上方法过程,本文提出的技术框架在音乐多情感分类任务中表现出色,不仅提高了分类的准确性,也为音乐情感分类领域的研究提供了新的方法和思路。

2.1 数据采集

(1)公开数据集

本文研究的数据集总共分为两部分,其一是网络上公开的中文歌词数据集 Chinese Lyrics,这是一个专门为自然语言处理、音乐信息检索以及相关研究领域设计的中文歌词数据集。Chinese Lyrics 中文歌词数据集主要来源于互联网上的歌词网站,包括但不限于专门提供歌词的网站、音乐分享平台等。歌词数据通常以文本文件的形式存储,每首歌曲的歌词作为一个独立的文本条目。数据集包含了多种不同情感色彩的歌词,如欢快、悲伤、愤怒等。该数据集包含了数万首中文歌曲,旨在为研究人员提供丰富的文本资源,用于研究歌词中的语言规律、情感分类、风格识别、歌曲生成等方面,在本文中将其用于情感分类。

(2)爬虫技术

网络爬虫,也被称为蜘蛛或机器人,是一种自动化的程序,它能够按照某种规则,从一个或多个的网页开始,自动抓取互联网上的网页内容,并从中提取关键信息。网络爬虫是搜索引擎的核心组成部分之一,它帮助搜索引擎构建和更新索引库,使得用户能够通过关键词搜索快速找到相关的网页。网络爬虫的工作流程通常包括以下步骤:选择起始页面,网络爬虫从一组起始 URL(Uniform Resource Locator)开始工作;抓取页面内容,通过超文本传输协议请求获取页面内容;解析页面内容,提取页面中的链接,并可能提取页面中的文本内容;跟踪链接,根据一定的策略选择链接进行进一步的爬取;存储数据,将抓取到的数据存储到数据库或文件中;去重,避免重复访问相同的网页,网络爬虫通常会有去重机制;调度和优化:网络爬虫会根据一定的算法调度抓取任务,并不断优化以提高效率。

因为上述公开数据集存在时间较长,包含歌曲老旧,所以除公开数据集之外的第二部分则来源于 Scrapy 爬取豆瓣网站中的音乐歌词数据,以获取网络最新发表歌曲。

Scrapy 因其高效率、灵活性和强大的社区支持，在爬虫开发领域非常流行，是一个强大的 Python 开源网络爬虫技术，它的核心组件主要包含六个：引擎负责调度请求、处理爬取过程中的各种事件和信号；调度器接收引擎发送的请求，并将它们排队以便后续执行；下载器负责执行请求，并返回响应；爬取器用于定义爬取逻辑和解析响应；项目管道处理从爬取器提取出来的数据；最后的中间件是位于引擎、调度器、下载器和爬取器之间，提供钩子以插入自定义代码。各个组件之间相互配合，共同协作完成数据的爬取。模型详细结构如图 2-2 所示。




图 2-2 Scrapy 模型结构图
Fig.2-2 Scrapy model structure diagram

2.2 数据预处理

2.2.1 制定音乐歌词长度

由上一章节可知本地音乐歌词数据的收集和整合工作涉及两个主要来源：Chinese Lyrics 中文歌词数据库和网络爬虫数据库，经过选取整合后，共计 24631 首音乐。基于 Chinese Lyrics 中文歌词数据库原有的分类体系进行了进一步的优化和调整，将其细分为四个主要的情感类别，分别为欢快、治愈、伤感和宣泄。为了便于管理和检索，本文将每个情感类别都对应一个文件夹，每个情感类别文件夹里含有若干数量的文本文件，而每个文本文件里都含一首音乐的全部歌词数据。不同情感类别的音乐数据数量如图 2-3 所示。




图 2-3 四类音乐情感类别的数量

Fig.2-3 Number of sentiment categories in four types of music

本文采用了一种创新方法对整个数据索引进行精确构建，即对整合数据集进行大数据可视化分析。这一步骤的目的是通过直观的视觉呈现，帮助确定并设置最合适的读取歌词文本序列长度，这对于后续的数据处理和分析至关重要。音乐歌词数据的特点在于字数长短不一，差异较大。有些音乐歌词的字数可以达到几百字，呈现出较为丰富的情感和内容；而有些音乐歌词则可能不足一百字，相对简短。这种字数上的差异给数据读取带来了挑战。如果读取文本序列长度设置得太长，会浪费计算资源，影响模型的训练效果；相反设置得太短，可能会遗漏掉关键信息，无法完整捕捉到每条数据中的分类信息；反之，如果。因此设置一个合理的读取文本序列长度是很有必要的。




图 2-4 歌词长度的出现频数统计图

Fig.2-4 Statistical chart of frequency of appearance of lyrics length

由图 2-4 可以看出音乐歌词的长度出现频数，绝大部分的歌词长度都在 320 字以内。




图 2-5 歌词长度的累积分布函数图

Fig.2-5 Cumulative distribution function diagram of lyrics length

图 2-5 可以看出，在数据中 90%的分位点对应的歌词长度为 326，说明本文数据集中 90%的音乐歌词长度小于等于 326。因此，根据图 2-4、2-5 的分析结果，综合考虑音乐歌词数据的特点和分布，最终确定了一个既能满足数据完整性又能保证效率的歌词序列长度 320。这个长度能够有效覆盖绝大多数音乐歌词样本的数据内容。通过这种方式可以更好地为模型提供准确且充分的数据输入，从而提高模型的性能和分类效果。

2.2.2 中文分词

中文分词是歌词预处理过程中不可或缺的一个环节，它为中文文本分类研究提供了基础和前提。在执行该过程时，分词操作的核心目的是将连贯的语句拆解成若干单独的字或词汇单位。中文与英文不同，缺乏类似空格这样的天然分隔符，其文本结构仅能通过标点符号及段落分隔来标识句子与段落。因此，相较于英文，中文文本的划分显得更为复杂和烦琐。尽管英文文本中也存在短语划分的问题，但相较于汉语，英语在词汇方面的复杂性较低，因此分词难度相对较小^[64]。汉语的词汇复杂性和多样性使得中文分词成为一个更具挑战性的任务。

在本文中，中文分词对歌词后续的特征提取是否准确。模型训练是否有效，以及最终的分类效果是否理想都起到了举足轻重的地位。一个精确的分词结果可以为特征提取提供更加丰富的信息，有助于模型更好地学习文本的内在规律，从而提高分类的准确性和效率。在实际应用中，中文分词技术的发展和优化一直是自然语言处理领域的研究热点之一。研究人员通过不断探索和改进分词算法，希望能够更准确地捕捉到中文文本中的词汇边界，为中文文本分类和其他相关任务提供更可靠的基础。

随着技术的不断发展，中文分词领域已存在众多可直接应用的工具，例如 Jieba 分词和 SnowNLP 分词等。其中，Jieba 分词专为 Python 语言设计。它以其高效性能、高准确度以及出色的可扩展特性而备受青睐。Jieba 分词使用基于前缀词典的分词算法，速度快且效果良好。另一款分词工具：SnowNLP 分词。这类工具较为简单，支持分词、

词性标注、情感分类等功能。在经过对比分析后，本文选择了 Jieba 分词工具作为研究工具，Jieba 分词以其快速处理和实用性强的特点脱颖而出，不仅分词速度快，而且准确率较高，能够满足本文的研究需求，同时还能保持较低的计算资源消耗。

2.2.3 数据整合

在处理海量的音乐歌词文件时，文件数量庞大至上万份，导致读取时间显著延长。这种情况下，数据加载可能耗时数小时甚至更久，尤其在重复实验的背景下，时间成本成倍增加，严重影响实验进度。同时，大规模文件的存储需求也不容忽视，对磁盘空间造成巨大压力。

为高效解决这一问题，本文采纳了数据整合的策略，并利用 Python 的 pickle 模块，一个针对复杂数据类型的存储和读取工具。通过 pickle 模块将文本数据转换为二进制格式，这一转换不仅保留了数据的完整性，而且大幅提升了读取速度。二进制文件加载迅速，速度超过传统文本文件 50 倍以上，在处理大规模数据时尤为突出。具体实施中，对分词后的数据集进行了整合，将每 2000 个文本文件打包成一个二进制文件“.pickle”，从而减少了文件数量和存储空间的占用。同时，所有标签信息也整合至一个单独的二进制文件中。整合后的文件存储在硬盘中，便于后续实验中快速读取和反序列化，迅速恢复原始的音乐歌词文本数据。这种方法显著提升了数据处理效率，缩短了实验周期，同时也减轻了存储系统的负担，为音乐情感分类研究提供了高效的数据处理方案。

2.3 歌词特征提取

分词后的中文歌词，虽然包含了丰富的语义信息，但由于其非结构化的特性，无法直接被计算机程序所理解和处理。本文的核心目标是将那些无序的文本数据转换为有序的结构化格式，确保计算机能够有效地处理和计算文本信息。在文本分类任务中，文本的表征质量是影响预测精确度的关键因素。理想的文本表征技术不仅应确保文本的语义信息得到充分保留，还应便于分类器的训练过程。这意味着，文本表示不仅需要准确地捕捉文本中的关键信息，还应当以分类器易于处理的形式呈现这些信息。在本文提出的针对音乐歌词情感分类的技术框架中，歌词表示阶段的设计尤为关键。主要下文设计了词频统计、去除停用词和情感向量表示三个步骤。

2.3.1 词频统计

词频统计是自然语言处理中的一个重要环节，它涉及对文本中单词出现的频率进行计数和分析。在本文中，是为了制作词汇表，进一步为了音乐歌词数据的标准化做准备。在进行中文歌词分析时，首先需要对歌词中的每一个字进行详细的统计计数。这个过程中，不仅统计每个字出现的次数，还采用了一种带有权重的词频统计策略，以构建一个全面的词汇表语料库。具体来说，会对所有中文歌词文本中的字进行计数，然后根据它们的出现频率，筛选出排名前 7000 的字词，将这些字词作为词汇表语料库。这一步骤的目的是确保本文语料库能够覆盖到歌词中最常用和最有代表性的字词。上述提到的带

有权重词频统计策略是基于本文中的音乐情感类型被分为四类，然而这些情感类别中包含的音乐数据量各不相同，所以如果直接统计词频而不考虑数据量的差异，那么数据量较大的类别中的字词将会在词汇表中占据不公正的优势。为了公平地对待每个类别中的字词，保证它们在文本表示中的平衡性，在统计词频时引入了权重策略。例如：“爱”这个字，在所有欢快类音乐中出现的频率为 $F_{\text{欢快}}$ 次，对应的权重为 $W_{\text{欢快}}=1/4/8693$ ；在所有伤感类音乐中出现的频率为 $F_{\text{伤感}}$ 次，对应的权重 $W_{\text{伤感}}=1/4/7046$ ；以此类推，最终，“爱”出现的频率是 $f = F_{\text{欢快}} * W_{\text{欢快}} + F_{\text{伤感}} * W_{\text{伤感}} + \dots + F_{\text{宣泄}} * W_{\text{宣泄}}$ 。

根据以上方法，在构建词汇表的过程中，采用了带有权重的词频统计方法对中文歌词中的所有字词进行了排序。这种方法确保了每个字词在词汇表中的位置是根据其在不同音乐情感类别中出现的相对重要性和频率综合考量后的结果。经过排序，词汇表中的所有字词按照权重词频的高低排列，其中排名前 200 的字词被特别标记，带权重的词频统计在图 2-6 中展示。为了便于后续实验中的数据调用和处理，本文将统计好的词汇表数据保存到一个文件中。这个文件不仅包含了词汇表的数据，还对其进行了格式转换，将其转化成了二进制数据格式，即上一章节中提到的“pickle”文件。通过采取此类办法存储词汇表数据，不仅使得数据在实验中的调用变得更加便捷，还减少了因数据格式转换而可能产生的错误。这样，研究人员可以在实验过程中直接加载这个预处理的二进制数据文件，从而节省了时间并提高了实验的效率。

```
print(vocabulary_list[:200])
```

['PAD', ' ', '的', ' ', '我', ' ', '不', '一', '你', '是', '了', ' ', '!', '人', '有', '在', '感', '这', '宣', '伤', '泄', '个', '天', '好', '快', '心', '爱', '要', '来', ' ', '到', '歌', '欢', '就', '治', '情', '愈', '上', '么', '大', '会', '都', '看', '们', '为', '想', '啊', ' ', '1', '得', '过', '没', '时', '生', '也', '?', '去', '0', '那', '多', '说', '中', '还', '可', '能', '子', '着', '下', '自', '开', '真', '他', '后', '年', '家', '最', '里', '曲', '2', '哈', '以', ' ', '起', '小', '回', '无', '出', '让', '地', '只', '很', ' ', '和', '日', '发', '对', '现', '5', '再', '点', '太', '然', '手', '如', '道', ' ', '国', ' ', '什', '样', '给', '!', '被', '走', '知', '事', '又', '今', '意', 'e', 'o', '老', '温', '吧', '难', '明', ' ', '女', ' ', '美', ' ', '乐', '己', 'a', '笑', '高', '分', '前', '月', '成', '3', '面', '动', '己', '经', '当', '别', '作', '哭', '暖', ' ', '用', '世', '眼', '身', '果', '啦', '相', '头', '名', '谁', 'i', '把', '次', '间', '见', '像', '她', '所', '同', '觉', ' ', '学', '死', '风', '悲', '一', '于', '定', '做', '怎', '才', '安', '水', '力', '话', '实', '之', '远', '全', '8', '第', '白', '方', '4', '吃', '福', '从', '行', '9', '望', 'n', '长', '座', '每', '友', '花', '放', '而', '光', '海', '候', '路', ' ', '等', '儿', '活', '记', '夜', ' ', '流']

图 2-6 带权重的前 200 词频
Fig.2-6 Weighted top 200 word frequencies

2.3.2 去除停用词

汉语词汇可依据其词性被划分为实词与虚词两大类。在中文语句的构造中，实词承载着具体的含义。此外，存在一类使用频率较高但对于文本内容的区分度贡献较少的中性词，因此在某些情况下可以考虑将其排除。在文本分类任务中，虚词和中性词通常被视为停用词，它们的存在会降低关键词的集中度，从而可能对文本分类的准确性产生不利影响。因此，在构建词汇表的过程中，去除停用词成为一个必要的步骤。在 2008 年的时候，学者 Hao Lili 及其团队提出了一套用于中文文本分类的标准停用词列表，还创新性地引入了一种用于识别停用词的加权卡方统计方法^[65]。如果词汇表中存在大量重复繁杂的词语，在后续处理中会浪费大量计算时间和资源。

众所周知，在音乐歌词中有大量的重复片段，一些歌词使用频率很高但是意义不大，

根据上述定义，在歌词预处理阶段，针对一些副词、连词、数词在歌词中无实际意义的字（如“了”、“会”、“要”、“与”等），词汇表中去除这些使用频率过高，且语义影响不大的停用词，可降低对预处理的影响，同时提高自然语言处理的速度。因此，在停用词词汇表中设置去除音乐歌词中 30 个频繁停用词，如图 2-7 所示。

```
#去除停用词
stop_words = ['的', '了', '在', '是', '我', '有', '和', '就', '都', '一',
              '个', '上', '也', '到', '要', '去', '你', '会', '着', '这',
              '呀', '得', '成', '歌', '她', '样', '他', '舞', '地', '与']
```

图 2-7 去除停用词
Fig.2-7 Remove stop words

2.3.3 情感向量表示

(1) One-Hot 编码

One-Hot 编码是一种常用的数据编码方式，主要用于将分类数据（也可以称为名义数据或者离散数据，本文中称为分类数据）转换为机器学习模型可以处理的数值形式。在这种编码方式中，每个分类标签都被表示为一个向量，向量中的所有元素都是 0，除了对应于该分类标签的一个元素是 1。以本文的分类标签数据为例，需要词向量的音乐标签一共有 4 个情感类别：欢快、治愈、伤感和宣泄，情感向量里每一个位置都代表一个词。本文数据用 One-Hot 编码的词向量表示如下：

“欢快”表示为 [1, 0, 0, 0]

“治愈”表示为 [0, 1, 0, 0]

“伤感”表示为 [0, 0, 1, 0]

“宣泄”表示为 [0, 0, 0, 1]

这种方法具有很多特性：(1)唯一性，每个分类都有唯一的编码，这使得模型可以明确地区分不同的分类；(2)有序性，虽然编码本身没有顺序，但是编码的顺序通常与分类标签的顺序相对应，这可能会影响模型的训练；(3)稀疏性，在多分类问题中，数据通常是稀疏的，因为任何给定样本只有一个分类标签的编码位是 1，其余都是 0；(4)兼容性：One-Hot 编码可以与多种机器学习算法兼容，包括逻辑回归、支持向量机、神经网络等。虽然这种方法存储方式简单，但是在处理音乐文本内容时面临着一个挑战：音乐文本包含了成百上千种不同的字词。若继续采用 One-Hot 编码方式，将产生极高维度的词向量，其中大部分元素都是 0，暴露了 One-Hot 编码的固有局限。就导致这种高稀疏度的向量不仅降低了计算效率，也增加了存储负担。而且 One-Hot 编码无法体现词语之间的内在联系，造成了所谓的词汇鸿沟。将文本数据转化为 0 和 1 的向量表示的方式，无法准确计算词语之间的距离，也无法有效地把握词语在上下文中的关联性，不适用于对音乐歌词文本的处理。相反，应当采用一种能够精确度量文本相关性并且有助于模型训练的词向量生成策略，以此取代 One-Hot 编码。

(2) GloVe

GloVe 模型作为一种学习词向量的方法，是通过全局单词共现信息的矩阵分解来获得词向量。它的核心思想是基于全局词共现信息，优化全局词汇表中的词向量，GloVe 模型在初始阶段，依据丰富的大型语料库构建了一个共现矩阵 X ，在该矩阵中，各元素值指示了特定上下文窗口内各单词与上下文单词共同出现的频次，其计数单位从 1 开始。然而，GloVe 对此进行了不同的处理：它引入了一个基于单词间距离的衰减函数 $decay = 1/d$ ，这表明两个单词在上下文窗口中的距离越远，其对应的共现频次在总计数中所占的权重就越小，甚至可能降至零。具体而言，在 GloVe 模型生成词向量时，实际上是利用了词语与词语之间共现概率的比值来进行学习。这种比值能够反映出词语之间的相关性，即两个词语共同出现在同一上下文中的频率相对于它们各自出现的频率的比值。这种方法的一个关键优势是：它对于共现矩阵中的共现频次为 0 的词语并不进行计算，这一策略大大节省了计算资源。

然而，这种基于共现频次的模型也有其局限性。特别是当语料库规模有限时，一些词语的共现次数可能非常少，这导致模型无法充分捕捉到这些词语的语义信息。在这种情况下，共现矩阵中的一些重要信息可能会丢失，因为模型仅仅依赖于频次较高的共现关系来学习词向量。这就意味着，在语料库不足时，GloVe 模型可能会生成质量较低的词向量，无法准确反映词语的真实语义。

(3) Word2Vec

上述提到的 One-Hot 编码表示词向量的方法虽然简单直观，但它生成的词向量实际上是一种稀疏矩阵，这种稀疏矩阵在计算上存在一些问题，可能在计算过程中的信息并无任何用处，也可能增加计算负担；而且 GloVe 模型还可能无法表达正确的语义信息。相比之下，Word2Vec 模型提供了一种将稀疏矩阵转化为稠密向量的方法。Word2Vec 通过训练神经网络来学习每个单词的向量表示，这些向量通常是低维的稠密向量，这种向量表示不仅保留了单词的语义信息并能正确表达，而且在计算上更加高效。

Word2Vec 是一种高效且广泛应用的单词嵌入技术，它通过将各个词映射到一个固定长度的向量空间中，使用一个由两层神经网络组成的模型来表示词语。核心在于能够捕捉并表征单词之间的复杂语义关系。Word2Vec 中有两种预测模型：连续词袋模型 (Continuous Bag of Words, CBOW) 和跳字模型 (Skip-gram)，这两种模型都能够生成高质量的单词嵌入向量。

CBOW 模型的目标是预测给定的上下文单词，它通过聚合上下文单词的向量来预测中心词。其原理公式见式(2-1)所示。

$$\arg \max_{\theta} \prod_j [\prod_{i=1}^{T_j} p(w_{ij} | C_{ij}; \theta)] \quad (2-1)$$

式(2-1)中： T_j 表示歌词中的第 j 句， w_{ij} 表示歌词的第 j 句中的第 i 个词， θ 表示概率的参数。

Skip-gram 模型则相反，它的目标是预测给定单词的上下文，即它能够根据一个单

词来预测其周围可能出现的单词，其本质特征在于将一个词表示为一个向量。它的原理公式见式(2-2)所示。

$$\arg \max_{\theta} \prod_{W_{ij}}^D [\prod_{c \in C_{ij}} p(c|W_{ij}; \theta)] \quad (2-2)$$

式(2-2)中： T_j 表示歌词中的第 j 句， W_{ij} 表示歌词的第 j 句中的第 i 个词， θ 表示概率的参数。

2.4 情感特征选择

现有的特征选择和上述提到的特征提取两者定义并不相同，在前文中提到的特征提取，是出于对计算机分类任务的一种需求考虑。在分类任务中，模型通常需要以向量的形式接收输入数据，这是因为向量化数据更容易被模型处理和解析。音乐歌词文本作为一种非结构化的数据形式，其原始状态并不直接适用于大多数机器学习或深度学习模型的输入要求。因此需要采用特征提取的方法，将音乐歌词文本这种原始的数据形式，转化为能够表征其内在特征和信息的特征向量。这样处理后，特征向量就可以作为模型的输入，参与到后续的训练和学习过程中。模型能够基于这些特征向量来学习歌词文本的分类规律，区分不同情感类型的歌词。特征提取不仅提高了数据处理的效率，还有助于模型更好地理解 and 利用输入数据中的信息，从而提升分类任务的性能和准确性。

在特征选择阶段之后，所得到的情感数据量往往十分庞大。若直接将其输入分类器，则可能会引起分类器的不稳定性和计算资源的过度消耗。因此，进行情感特征选择对其降低维度是极其必要的。它的过程旨在对原始特征词向量进行优化，通过设定适宜的阈值来实现词向量的筛选和淘汰，以确保仅保留那些重要且具有效力的特征词向量。本节将详细阐述几种常见的特征选择方法：

(1) 相关性分析

相关性分析通常通过计算相关系数来量化两个变量之间的关系。最常用的相关系数是皮尔逊相关系数，它是通过计算两个变量 x 和 y 的协方差与各自标准差的商来得到的，用于衡量两个连续变量之间的线性相关程度。具体计算公式见式(2-3)所示。

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}} \quad (2-3)$$

(2) 信息增益

信息增益可以定义为在给定特征的情况下，两个不同目标变量的熵之间的差值。系统的信息含量对于某一特定特征来说，在有此特征和无此特征的情况下就会有所不同。这种差异，即前后信息含量的变动，反映了该特征对系统信息含量的贡献。在此，所提及的信息含量实际上是指熵的概念。熵越大，代表越不稳定，分类的准确性就越低。假如有变量 X ，其可能的取值有 n 种，每一种取到的概率为 P_i ，其具体原理的计算公式见式(2-4)所示。

$$H(X) = -\sum_{i=1}^n P(x_i) \log P(x_i) \quad (2-4)$$

(3)卡方检验

卡方检验作为一种独立性和相关性的特征选择方法，其核心是计算卡方 CHI 值。通过比较特征向量 x 和情感类别 S_i 之间的 CHI 值，能够量化它们之间的联系紧密度。当 CHI 值 $\chi^2(x)$ 较大时，表明特征向量与情感类别之间存在较强的关联性，反之，当 CHI 值较小时，表明特征向量与文本类别之间的关联性较弱，这个特征向量可能对于分类任务不是那么重要。 $\chi^2(x)$ 具体原理的计算公式见式(2-5)所示。

$$\chi^2(x) = \sum_i \frac{[P(x, S_i)P(\bar{x}, \bar{S}_i) - P(\bar{x}, S_i)P(x, \bar{S}_i)]^2}{P(x)P(S_i)P(\bar{x})P(\bar{S}_i)} \quad (2-5)$$

经过比较，首先卡方校验在关联性检测方面能够有效地检测特征与类别之间的关联性，对于本文分类任务来说非常重要；其次在非线性关系方面与皮尔逊相关系数相比，卡方检验不仅适用于线性关系，也能检测非线性关系；最后卡方检验的计算相对简单，易于实现和理解。本文最终选择卡方校验作为情感特征选择方法。

2.5 分类器

2.5.1 机器学习分类算法

在分类领域的机器学习算法中，支持向量机(Support Vector Machine, SVM)、朴素贝叶斯(Naive Bayes, NB)以及 K-近邻算法(K-Nearest Neighbor, KNN)是三种极具代表性的方法。下面分别概述这三种算法的基本原理：

(1)朴素贝叶斯

朴素贝叶斯分类(Naive Bayes Classification, NBC)的核心假设是特征之间的条件独立性。假设有一组样本数据集为 $D = \{d_1, d_2, \dots, d_n\}$ ，其中包含了一系列样本，每个样本都具备一组特征属性 $X = \{x_1, x_2, \dots, x_d\}$ ，这些样本被分类为不同的类别，其类变量为 $Y = \{y_1, y_2, \dots, y_m\}$ ，即 D 可以分为 Y_m 类别。其中特征属性相互独立且随机分布，对于某一特定类别 Y ，其先验概率记作 $P_{prior} = P(Y)$ ，后验概率为 $P_{post} = P(Y|X)$ ，根据朴素贝叶斯算法，后验概率可以由先验概率 $P_{prior} = P(Y)$ 、证据 $P(X)$ 、类条件概率 $P(X|Y)$ 计算出公式见式(2-6)所示。

$$P(Y|X) = \frac{P(Y)P(X|Y)}{P(X)} \quad (2-6)$$

在确定类别 y 的情况下，可以得到一个样本数据属于类别 y_i 。其公式见式(2-7)所示。

$$P(y_i | x_1, x_2, \dots, x_d) = \frac{P(y_i) \prod_{j=1}^d P(x_j | y_i)}{\prod_{j=1}^d P(x_j)} \quad (2-7)$$

(2)支持向量机

支持向量机(SVM)是一种强大的监督学习模型，主要用于分类和回归分析，其模型结构图如图 2-8 所示。




图 2-8 SVM 模型图

Fig.2-8 SVM model diagram

在分类问题中，SVM 可以用来解决二分类或多分类问题。对于二分类问题，SVM 通过寻找一个最优的超平面来将两类数据点尽可能清晰地分开。这个超平面的选择是基于最大化两类数据点之间的间隔的原则。当面对多分类问题时，SVM 可以采用一种称为“一对一”或“一对多”的策略来扩展其应用范围。在“一对一”策略中，SVM 会为每一对不同的类别分别训练一个独立的分类器。然后，在实际的多分类任务中，会通过比较所有分类器的输出结果来确定最终的分类标签。而在“一对多”策略中，SVM 则会为每一个类别分别训练一个独立的分类器。在这个策略中，每个分类器都会尝试将其对应的类别与其他所有类别区分开来。在实际的多分类任务中，最终的分类标签会被确定为那个能够得到最多分类器支持（即输出结果为该类别的次数最多）的类别。

(3)K-近邻算法

K-近邻分类算法其基本原理是：在特征空间内，若一个样本点周围最接近的 K 个样本（即在特征空间中距离最近的 K 个样本）大多数属于某一类别，则该样本点也被归入这一类别。举一个形象的例子，如图 2-9 所示。




图 2-9 K-近邻模型图

Fig.2-9 KNN model diagram

图中存在两类不同的样本数据，一类以蓝色正方形表示，另一类以红色三角形表示，而绿色圆形（图中间）则代表一个等待被分类的样本。对于这个未知类别的绿色样本，若要确定其类别归属，可以采用以下假设：当 K 值为 3 时，距离绿色圆形三个最近邻居中有两个是红色三角形，一个是蓝色正方形，此时少数服从多数，判定绿色圆点属于红色三角形类别；若 K 值为 5，绿色圆点的五个最近邻居中有两个红色三角形和三个蓝色正方形，同样依据少数服从多数的原则，判定绿色圆点属于蓝色正方形类别。

总结对比以上三类机器学习分类器的原理，可以看出朴素贝叶斯算法特点是假设所有特征的出现相互独立互不影响，每一特征同等重要，但事实上这个假设在现实世界中并不成立，所以本章选择剩余两类机器学习分类算法进行后续的复现，并与本文所提出的算法进行对比，展示实验结果。

2.5.2 深度学习分类算法

(1) 循环神经网络

循环神经网络作为一种以序列数据作为输入的神经网络，沿着序列的时间维度进行递归处理，其所有节点（即循环单元）以链式结构相互连接。该网络在自然语言处理领域被广泛采用，成为语义分析的重要工具之一，并在文本分类任务中得到了应用。循环神经网络中除了输入数据 X 之外，每一步的输出会作为下一步的输入，如此循环，并且每一次采用的激活函数和参数。如图 2-10 所示，在每次循环中， x_0 乘以系数 U 得到 s_0 ，再经过系数 W 输入到下一次，依次循环构成循环网络的正向传播。




图 2-10 循环神经网络模型图

Fig.2-10 RNN model diagram

在理论上，RNN 具有一个显著的优势，即它能够在任意时刻的单元中访问之前所有时刻的信息。这种特性使得 RNN 在处理序列数据时表现出色，因为它能够捕捉时间序列中的动态变化和长期依赖关系。然而，在实际应用中，尤其是在反向传播的过程中，循环神经网络面临着一个严重的问题：梯度爆炸或梯度消失。具体来说，当循环神经网络的层数增加时，梯度在反向传播的过程中会经历指数级的增长或衰减。这种梯度的不稳定性会导致两个极端现象：梯度爆炸或梯度消失。梯度爆炸会导致模型参数的剧烈变化，使得损失函数难以收敛；而梯度消失则意味着模型无法学习到长期依赖关系，因为相关信息在传播过程中被“淹没”。模型可能会因为梯度的问题而陷入局部最优的解，

无法全局优化，从而影响分类的准确性。

为了解决循环神经网络在处理长序列数据时的梯度问题，研究人员提出了一种循环神经网络的变体模型——长短时记忆神经网络(Long Short-Term Memory, LSTM)。LSTM 中的门控机制包括遗忘门、输入门和输出门，它们分别控制着信息的遗忘、输入和输出。遗忘门负责筛选出应从单元状态中移除的信息，输入门则负责确定哪些新的信息应当融入单元状态，输出门则负责决定哪些信息应从单元状态中释放，传递至下一时刻的状态。这三个门协同作用，构成了长短期记忆单元的核心功能机制。它们使得单元能够依据当前的输入信息以及先前的状态，高效地保持和更新其内部状态。这种门控机制使得 LSTM 能够更好地学习长序列文本中的时间依赖关系，同时保持梯度在反向传播过程中的稳定性。因此，LSTM 在处理长序列文本分类任务时，相较于传统的循环神经网络模型，具有更好的性能和泛化能力。

(2)卷积神经网络

卷积神经网络随着深度学习的技术的不断发展，凭借自己强大的特征提取能力，逐渐在文本分类任务中展现出卓越的性能。卷积神经网络通过卷积层对输入的词向量进行卷积操作，以提取局部特征。卷积核的大小可以根据具体任务进行调整，常用的卷积核大小有 3、4、5 等。通过多个不同大小的卷积核进行卷积操作，可以得到不同尺寸的特征图，其计算公式见式(2-8)所示。

$$W' = \frac{(W + 2p - k)}{s} + 1 \quad (2-8)$$

式(2-8)中： W 是输入矩阵大小， k 是卷积核大小， s 是步幅， p 是补零层数。

池化层负责对卷积结果进行降维处理，以保留最重要的特征。常用的池化方法包括最大池化和平均池化，其具体操作如图 2-11 所示。为了更全面地捕捉文本的特征，CNN 通常会使用多个不同大小的卷积核进行多通道卷积。这种多通道卷积可以有效提高模型的表达能力。在经过多个卷积层和池化层后，CNN 会将特征图展平。最后通过全连接层将其映射到预定义的类别上，并使用 Softmax 函数计算每个类别的概率分布，从而得到最终的分




图 2-11 不同池化方法
Fig.2-11 Different pooling methods

卷积神经网络在情感分类任务中，能够提取出与情感表达相关的词汇组合特征，使得结果达到较高的准确性，而且计算效率高，可以在短时间内处理大量的文本数据，模型相对简单，且结构较为直观。在本文中对卷积神经网络进行修改和优化，然后对音乐歌词进行多情感分类，取得了不错的成果，为后续自然语言处理领域的研究和实践提供了新的视角和方法。

2.6 本章小结

本章节构建了一套完整的技术框架用于音乐多情感分类，并对其主要构成要素及操作流程进行了详尽的阐述。该框架的核心环节包括数据采集、预处理、歌词特征提取、情感特征选择以及分类器的运用。在数据采集环节，本文详细说明了数据集的来源及收集过程。预处理阶段则重点描述了如何确定音乐歌词的长度标准、执行中文分词以及如何实现数据的有效整合，这些步骤为后续的情感分类提供了坚实的基础。后续本文又提出一种基于权重抽取的词频统计方法来构建词汇表，并进行了停用词的去除。此外，本文还探讨了多种情感向量表示方法，最终选择了 Word2Vec 作为词向量的表示。在情感特征选择环节，介绍了多种特征选择算法，旨在从歌词数据中识别并保留有价值的特征。而在分类器部分，本文重点分析了在音乐多情感分类中常用的传统机器学习算法，此外，本章还特别探讨了深度学习算法，如循环神经网络和卷积神经网络，其基本架构及其计算原理进行了深入解析，为后续章节中对模型的优化提供了理论支撑。

第3章 融合 Word2Vec 词嵌入的多核卷积神经网络音乐多情感分类算法 (WSM-CNN)

在音乐多情感分类领域,尚且存在情感提取不充分、串行序列的局限性以及分类器过拟合导致准确率不高等问题,为了解决上述问题,本章提出新的音乐多情感分类算法:首先对算法中的关键技术 Word2Vec 词嵌入和卷积神经网络进行了详细介绍;然后在串联两者的基础上对其进行改进,设计并实现了融合 Word2Vec 词嵌入的多核卷积神经网络音乐歌词多情感分类算法(WSM-CNN);其次对该算法的设计原理进行了详细阐述,并进行了模型正则化和训练;最后设计三组对比实验从而验证该算法的有效性。

3.1 关键技术

3.1.1 Word2Vec 词嵌入

在上章节中已经对 Word2Vec 表示词向量的算法原理进行了详细的阐述,在本文中,使用 Word2Vec 词嵌入方法,音乐歌词作为输入,输出则是反映该语料库中词语的一组向量(即音乐歌词情感特征向量)。

在提取音乐特征方面,将单词表示向量(称为词嵌入)作为自然语言处理的特征学习技术引起学者们的广泛关注^[66],词嵌入作为神经概率语言模型的衍生产品,单词嵌入隐含了单词在向量各个维度上的语义和句法信息,很好地表达了语义相似度^[67]。之所以选用 Word2Vec 词向量是因为它恰好满足了这种需求,能够较好地表达不同词之间的相似和类比关系,它们不仅考虑了词频信息,还考虑了词语之间的顺序及上下文关系。这种考虑使得 Word2Vec 能够捕捉到情感词本身的分布表示,进而将语义相近的词语映射到向量空间中的相近位置,实现了词语之间的语义关联。Garg 等研究者^[68]对词嵌入进行了研究,也证实了 Word2Vec 嵌入技术的优越性。因此,在许多应用场景中,Word2Vec 仍然是一个值得考虑的选择。

基于上述优势,本文提出利用 Word2Vec 技术来构建词典。Word2Vec 技术主要包括:连续词袋(CBOW)模型和跳字(Skip-gram)模型,这两个模型可以提供高质量的单词嵌入向量^[69]。其中,CBOW 预测给定上下文的单词,Skip-gram 预测给定单词的上下文^[70],具体公式详见上章节。Word2Vec 公式可以简单理解为,假设给定一个由 n 个词语按顺序组成的句子 $S = \{w_1, w_2, \dots, w_n\}$,为了估算一个句子出现的概率,仅需确定在特定上下文条件下,紧随其后的词是特定词汇的概率。一旦所有的条件概率得到确定,通过逐项相乘的方式,便能推导出整个句子出现的总概率 $P(S)$,其概率公式见式(3-1)所示。

$$P(S) = P(w_1, w_2, \dots, w_i) = P(w_1)P(w_2 | w_1)P(w_3 | w_1, w_2) \dots P(w_i | w_1, w_2, \dots, w_{i-1}) \quad (3-1)$$

通过这种方式可以创建一个包含丰富语义信息的词向量集合,这些词向量不仅能够

为音乐多情感分类任务提供强有力的支持,还能够更好地理解和处理自然语言数据,同时选用 Word2Vec 技术计算语义相似度,筛选相似度足够的词向量汇总成新的情感词典,能够将歌词转化为深度神经网络容易理解的数字形式,更适用于本文选用的分类器模型。模型图如图 3-1 所示。




图 3-1 Word2Vec 模型图
Fig.3-1 Word2Vec model diagram

3.1.2 卷积神经网络

(1)经典单层卷积神经网络

在 2.5.2 中,本文已经描述了卷积池化的具体工作流程,接下来需要将待分类的歌词文本数据转换为适合卷积神经网络处理的形式。为此,采用了词向量方法对歌词文本进行了预处理,将待分类的歌词文本数据通过词向量方法的转化输入到经典单层卷积神经网络的模型结构原理图如下 3-2 所示。




图 3-2 经典卷积神经网络模型结构图
Fig.3-2 Classical CNN model structure diagram

第一层为输入层,也被称为词嵌入(Embedding)层。在此层级上,卷积神经网络着手对输入的信息进行初步处理。第二层是卷积层,其主要功能是通过卷积运算对来自输入层的数据执行特征提取操作。卷积操作通过一系列的卷积核(或过滤器)来实现,这些卷积核在歌词数据上滑动,能够识别并提取出歌词中的局部特征。第三层是池化层,这一层的作用是从卷积层提取的特征中筛选出一个或多个最重要的特征。池化不仅能够降低特征的空间维度,减少计算量和过拟合的风险,而且它通过降采样的特点,能够进一

步提取文本数据中更为重要和显著的特征,这对于提高模型的泛化能力和鲁棒性至关重要。接下来的第四层是输出层,在这个层次中,所有从池化层提取的特征被全连接起来,形成一个完整的特征表示。然后,通过全连接层输出到 Softmax 函数, Softmax 函数的作用是对输出的特征向量进行归一化处理,将其转换为一个概率分布。这个概率分布代表了输入文本属于每个情绪类别的概率,从而实现了情感分类的任务。

总的来说,卷积神经网络模型的每一层都承担着不同的任务,从词嵌入层的向量化,到卷积层的特征提取,再到池化层的特征筛选,最后通过输出层的全连接和 Softmax 函数输出分类结果,共同构成了一个高效的情感分类系统。

(2)单层多核卷积神经网络

对于单层卷积神经网络来说由于网络结构的限制,可能会造成特征信息的丢失,在音乐歌词中,情感的表达往往依赖于细微的语义差异和上下文信息,而经典卷积神经网络在处理过程中可能会忽略这些细节,导致一些关键的情感信息无法被有效提取。而在此基础上如果加深深度神经网络的深度,进行卷积之后再卷积的操作容易导致原始输入中的重要信息在经过多层卷积和池化操作后被逐渐稀释或丢失。因此,本文在传统单层卷积神经网络架构的基础上进行了创新性的优化,构建了一种单层多核卷积神经网络结构。该网络通过在保持网络层数不变的前提下,引入3种不同尺寸的卷积核,以此增强音乐多情感分类的准确性。其原理结构图如图3-3所示。




图 3-3 单层多核卷积神经网络模型结构图

Fig.3-3 SM-CNN model structure diagram

3.2 WSM-CNN 音乐歌词多情感分类算法

在 3.1 章节关键技术的基础上,本文结合 Word2Vec 词嵌入技术,提出并实现了一种新的算法模型应用于音乐多情感分类任务中,并将其命名为融合 Word2Vec 词嵌入的多核卷积神经网络音乐多情感分类(WSM-CNN),该算法首先利用 Word2Vec 词嵌入提取歌词局部特征,构建特征情感向量,挖掘歌词中情感信息;随后,将这些歌词转换成适合分类器模型输入的词向量形式;其次在分类器中,选用卷积神经网络模型,并在此基础上采用三种不同高度卷积核的方式构建新模型,最后以此得到音乐多情感分类。

WSM-CNN 的算法模型如图 3-4 所示。




图 3-4 WSM-CNN 模型图

Fig.3-4 WSM-CNN model diagram

图中第 1 层为输入层，在模型的输入处理中，在本次实验研究中读取的音乐歌词长度为 320，所以 word embedding 设置为 100 维，在该层上采用了 Word2Vec 技术特征提取情感方法生出 f 维的矩阵，然后将生成的矩阵向量作为输入传至卷积层。歌词采用 Word2Vec 技术特征提取后，得到 f 维的词向量 R^f ，假设它是第 i 个字的向量表示，因此长度为 n 的句子可见式(3-2)所示。

$$x_{i:n} = x_1 \oplus x_2 \oplus \dots \oplus x_n \quad (3-2)$$

式(3-2)中： $\oplus$ 为连接符，将长度为 n 的句子中的每个向量全部连接起来。

第 2 层为卷积层，卷积层用于使用卷积核来提取特征映射。卷积核可以看作是矩阵。为了避免层数过多而导致特征过于抽象的问题，在单层 CNN 的基础上设计了不同尺寸的卷积核。卷积的详细操作如下。

设计 3 种不同高度的卷积核，3 种卷积核的高度设为 h ，分别为 3×100 、 4×100 、 5×100 ，每种尺寸的卷积核有 r 个，值设置 128，权值矩阵 w_1 是一个实数矩阵，对 h 个字的内容块进行一个特征提取的操作。由 x_{ii+h-1} 提取到的特征 o_i 可见式(3-3)所示。

$$o_i = f(w_1 \bullet x_{ii+h-1} + b_1) \quad (3-3)$$

式(3-3)中： x_{ii+h-1} 为输入的第 i 个到第 $i+h-1$ 个窗口内的词向量矩阵； $f(\bullet)$ 为一个非线性激活函数； b_1 为偏置项，属于实数。

整个卷积操作完成后会得到特征图，可见式(3-4)所示。

$$o = [o_1, o_2, \dots, o_{n-h+1}] \quad (3-4)$$

式(3-4)中： o 是大小为 $n-h+1$ 的实数向量。

第 3 层为池化层，池化层保留了卷积以后的数据特征。采用 1-Max 池化方法，从卷积后的每个窗口产生的特征向量中选择一个最优情感特征向量，最后将其拼接起来，降低了数据所在的高维数据空间的维数，避免了维数灾难，同时提取到更为重要的音乐情

感特征要素。

池化层的操作可见式(3-5)所示。

$$\hat{o} = \max \{o\} \quad (3-5)$$

式(3-5)中: $\hat{o}$ 为 o 的最大值。

本次研究中进行 3 种不同尺寸的卷积核操作, 因此将池化后的数据特征拼接到一起, 最终形成特征向量 $\theta, \theta \in R^{1+3r}$, 可见式(3-6)所示。

$$\theta = \hat{o}^3 + \hat{o}^4 + \hat{o}^5 \quad (3-6)$$

式(3-6)中: $\hat{o}^3, \hat{o}^4, \hat{o}^5$ 分别为卷积核高度为 3、4、5 最大池化后的输出情感向量。

下一层为降维层(又称为隐藏层), 经过非线性降维之后, 上述特征向量 θ 变成特征向量 $\theta \in R^{1 \times m}$, 其中 m 为降维层中神经元节点数。

最后一层为 Softmax 输出层, 又称为全连接层, 将最后的特征结果输出至该层, 通过 Softmax 层输出 4 种情感类别的概率分布, 得到的预测类别的标签值, 对应的表达式可见式(3-7)所示。

$$c_i = \text{Soft max}(w_2 \cdot n + b_2) \quad (3-7)$$

式(3-7)中: w_2 为一个实数矩阵; n 为类别数; b_2 为偏置项。

3.3 正则化和模型训练

3.3.1 模型正则化

(1) 划分合理数据集

为了确保模型能够在未知数据上具有良好的泛化能力, 本文将原始数据集划分为测试集、验证集和训练集。验证集是用于评估模型性能的数据集, 通常不参与模型的训练; 训练集是用于训练模型的原始数据集。模型在这一部分数据上学习并调整参数。在模型训练过程中, 验证集用来调整模型的超参数, 如正则化强度、网络结构等, 以及用于早期停止以防止过拟合; 测试集是用于最终评估模型性能的数据集, 确保模型的评估是在完全未见过的数据上进行的。当数据量较小, 例如在一万以下时, 可以将数据集分为较大的训练集和相对较小的验证集和测试集, 常用的比例是 6:2:2。然而, 当数据量变得非常大, 比如超过一万甚至达到百万级别时, 数据集的划分策略需要相应调整。在这种情况下, 训练集的比例通常会大幅增加, 而验证集和测试集的比例相应减少。例如, 可以设置比例为 98:1:1。这种划分方式的原因是, 在大量数据的情况下, 模型需要更多的数据来进行充分的学习, 而较小的验证集和测试集已经足够用来评估模型的性能。所以, 根据本身研究的数据量的大小来合理划分数据集是很重要的。本文研究的是两个数据集, 其总数据量达到了 24631 条记录。虽然这个数据量未达到百万级, 但已经远超过一万条记录。考虑到数据量的规模, 本文决定将研究的数据集按照 8(训练集): 1(测试集): 1(验证集)的比例进行划分。以此保证模型不仅可以在训练数据上表现良好, 更在实际应用中也能保持稳定的性能。

(2)添加 Dropout 层

在深度学习的实践中,神经网络模型往往会遇到过拟合现象,这是一种常见的问题,具体表现在:模型不仅学会了训练数据中的模式,还学到了其中的噪声和细节,这导致模型在新的、未见过的数据上表现不佳,从而降低了模型的准确率。为此,本文选用加入 Dropout 层的方法来减少这种现象的发生,Dropout 层的核心原理是在每次训练迭代中随机“关闭”网络中的一定比例的神经元。这种方法迫使网络的其他部分在没有这些被关闭的神经元的情况下独立地学习数据中的特征,进而使得模型能够学习到更加泛化的特征,增强模型在未知数据上的表现。具体到本文的实现方式,在每个全连接层后面引入了一个 Dropout 层,以概率 $P=0.5$ 随机关闭激活函数,这意味着在每次训练迭代中,大约有一半的神经元不会被激活,它们的输出被置为 0,相当于这些神经元在当前迭代中“被丢弃”。这种机制使得网络在每次迭代时都呈现出不同的结构,迫使网络学习更加鲁棒的特征表示。由于网络在训练过程中必须适应这种随机的丢弃,它被迫学习更加健壮的内部表示,确保即使在缺少部分神经元的情况下也能正确执行任务。这种方法有效地减少了模型对特定神经元的依赖,使得模型不容易受到个别神经元的异常激活的影响。其模型原理图如下图 3-5 所示。




图 3-5 Dropout 模型图
Fig.3-5 Dropout model diagram

3.3.2 模型训练

本文将模型训练视为关键环节,其核心在于利用损失函数对多种模型进行训练以达到预期效果。作为衡量模型预测值与实际标签差异度的工具,损失函数对于模型训练的成功至关重要。具体地,本文在模型训练阶段选用的是多分类交叉熵损失函数,通常称作对数损失函数。这种函数专门用于处理多分类问题,能够精确地衡量模型预测的概率分布与实际标签分布之间的不匹配程度。通过指导模型学习以降低这种不匹配,该函数有助于提升模型的分类性能。这种损失函数在多分类问题中普遍存在,因为它能够有效衡量模型对于每个类别的预测概率与实际标签之间的不一致性。多分类交叉熵损失函数的基本原理是:对于每个样本,计算模型预测的概率分布与实际标签的分布之间的负对

数似然。其原理公式可见式(3-8)所示。

$$L = -\frac{1}{n} \sum_{i=0}^{n-1} \sum_{j=0}^{M-1} y_{i,j} \log p_{i,j}$$

(3-8)

式(3-8)中， L 表示为损失函数， $y_{i,j}$ 表示为第*i*个样本属于第*j*个类别的概率， $p_{i,j}$ 表示模型预测第*i*个样本属于第*j*个类别的概率。使用多分类交叉熵损失函数能够提供关于模型预测准确性的直观反馈，因此，本文选择此类损失函数作为模型训练的关键组成部分。

3.4 实验结果与分析

3.4.1 实验环境和参数设置

为确保实验结果的准确性，本文搭建的实验环境和参数设置见表 3-1、3-2 所示。

表 3-1 实验环境
Table.3-1 Experimental environment

环境		配置
硬件	操作系统	Windows 11
	处理器	Intel(R) Core(TM) i5-10210U
	服务器	CPU@1.60 GHz、2.11 GHz
	机带 RAM/GB	GPU NVIDIA GTX2070 8G
	硬盘	8.00
软件	编程语言	2T
	编程软件	Python-3.6.5
	机器学习库	Jupyter notebook
	分词工具	Tensorflow-1.14、sklearn-0.19.1
		Jieba-0.42.1

表 3-2 参数设置
Table.3-2 Parameter settings

参数	值
歌词文本长度	300
embedding_size	128
batch_size	64
池化方法	Max
Dropout 层	0.5
训练次数	12000
卷积核高度	3,4,5
卷积核个数	256

3.4.2 评价指标

本文进行了多组不同模型算法的音乐多情感分类实验，并对不同算法的性能进行评价。为了验证算法的有效性，在衡量分类器的性能方面，提出了三类评价指标^[71]，包括精确率 p_{re} (Precision)、召回率 r_{ec} (Recall)和 F_1 (F-Measure)。

具体精确率、召回率和 F_1 值的计算原理如下：

(1) 精确率

精确率评价的是模型对于正类预测的严谨性，它被定义为模型正确预测的样本数（包括正类和负类）占总样本数的比例。如果精确率很高，这意味着模型分类预测结果中的样本大部分都是正确的结果，模型在分类预测上很少犯错误。相反，如果精确率很低，则说明模型在分类预测上有很多的误判。本文中精确率定义公式可见式(3-9)所示。

$$p_{re} = \frac{l_{yc}}{l_{yo}} \quad (3-9)$$

(2) 召回率

召回率用于衡量模型在识别所有正确样本方面的能力，它关注的是模型对于正确样本的捕获程度，即实际为正确的样本中有多少被模型正确的分类预测。如果召回率很高，则说明模型能够较好的分类预测出所有的正确样本，即模型对正确样本的遗漏较少；相反，如果召回率很低，则说明模型在分类过程中存在较多问题。在本文中召回率定义公式可见式(3-10)所示。

$$r_{ec} = \frac{l_{yc}}{m_{ul}} \quad (3-10)$$

(3) F_1 值

F_1 值是精确率和召回率的调和平均数，旨在提供一个单一的性能度量，同时考虑模型对正确样本的预测准确性（精准率）和模型的覆盖范围（召回率）。 F_1 值的特点是当精确率和召回率相等时， F_1 值达到最大值 1，而当两者中的任何一个为 0 时， F_1 值也为 0，这表明 F_1 值同时考虑了上述提到的模型分类预测正确的准确性和全面性。在本文中 F_1 值定义公式可见式(3-11)所示。

$$F_1 = \frac{2 * p_{re} * r_{ec}}{p_{re} + r_{ec}} \quad (3-11)$$

上述式中： l_{yc} 为实际正确的分类样本； l_{yo} 为预测正确的样本； m_{ul} 为全部正确的分类样本。

3.4.3 实验结果与分析

为了更好体现出提出的算法对于音乐多情感分类的性能，又对音乐多情感分类的研究设置了多个对比实验，以第二章介绍的 SVM、KNN 为代表的机器学习模型，和深度学习中的 RNN、经典 CNN 以及变形。具体的实验设计和结果分析如下：

(1) 机器学习和深度学习分类算法进行音乐多情感分类的对比实验。

为了全面评估深度学习分类算法在音乐多情感分类任务上的表现，在本文采用的数据集上将其与机器学习包括 KNN、SVM 和深度学习包括 RNN、CNN（单层 CNN）进行对比实验。不同实验的分类结果精确率见下表 3-3 所示。

表 3-3 分类结果

Table.3-3 Classification results

算法模型	p_{re}	r_{ec}	F_1
KNN	0.7098	0.7088	0.7093
SVM	0.7362	0.7349	0.7358
RNN	0.7928	0.7914	0.7919
CNN	0.8437	0.8421	0.8432

通过表 3-3 中的结果可以看出, (1)采用 Word2Vec 词嵌入的方法进行词向量的训练, 是一种将歌词文本转化为连续的情感向量的有效手段。在这个过程中, 歌词文本被转换成了分类器的输入, 即情感向量, 这在同一数据集上的机器学习和深度学习模型中均取得了 70%以上的精确率。这一结果说明, Word2Vec 词嵌入模型在捕捉和描述歌词情感特征向量方面是有效的, 它能够为分类器提供有用的信息, 从而帮助模型更好地理解 and 分类歌词的情感。(2)在比较不同模型的分分类准确率时, 不管是 RNN、还是单层 CNN, 其分类准确率均比机器学习中的 KNN、SVM 要高, 特别是单层 CNN 精确率达到了 84.37%, 相较于 KNN 精确率提高了 13.39%、SVM 提高了 10.75%、RNN 提高了 5.09%, 这不仅显示了深度学习模型在分类精度上的优势, 也说明了其在处理复杂文本数据时的强大能力。同时其它两类评估指标的值也均高于机器学习的分类模型, 这意味着深度学习模型不仅在准确率上具有优势, 而且在其他评估指标上也表现出色, 进一步验证了深度学习模型在音乐多情感分类任务上的优越性。综上所述, 实验结果清晰地表明, 在音乐多情感分类上, 深度学习模型, 尤其是单层 CNN, 其分类效果要显著好于传统的机器学习方法。

为了深入探究不同情感分类模型的性能, 本文在上述分类中选出深度学习中的分类模型进行可视化分析, 分别对单层 CNN、RNN 模型进行对比, 测试模型迭代 100 轮次输出一组测试精度值和损失值, 这些数据是评估模型性能的重要指标, 其中测试精度值反映了模型在测试集上的分类精确率, 而损失值则反映了模型预测结果与实际标签之间的差异。随着每轮迭代次数的变化, 这两类模型的输出结果如图 3-6 所示。




图 3-6 不同模型训练曲线图

Fig.3-6 Training curves of different models

由图 3-6 可知, CNN 和 RNN 模型的测试精度值在训练开始时会有较大的波动, 但随着训练的深入, 这些波动逐渐减少, 模型的精度值趋于稳定。这种现象表明, 模型在

训练过程中逐渐学习到了歌词中的情感特征,并能够更准确地对其进行分类。与此同时,模型的损失值也在迭代过程中不断下降。在训练的初期阶段,损失值也有较大的下降,是因为模型正在学习如何最小化预测结果与实际标签之间的差异。随着迭代次数的增加,损失值的下降速度逐渐放缓,最终在某个小区间内稳定波动。这表明模型已经找到了一个相对最优的参数配置,使得损失值不再显著下降,而是保持在一定的范围内波动。整体来说,CNN 模型整体的精度值曲线高于 RNN 模型,且损失曲线低于 RNN 模型,说明 CNN 在音乐多情感分类中的优越性。

(2)不同层数的 CNN 进行音乐多情感分类的对比实验

在之前的实验结果中已经明确地证明了深度学习算法 CNN 在音乐多情感分类任务中的优越性。为了进一步探究 CNN 模型在音乐多情感分类上的性能,本文对不同层数的 CNN 进行了比较,将其分为单层 CNN 和多层 CNN,其中单层 CNN 的实验结果已经在之前的对比实验中进行了可视化分析,展示了其在分类精度和损失值方面的表现。其分类结果见下表 3-4 所示。

表 3-4 分类结果
Table.3-4 Classification results

算法模型	P_{re}	r_{ec}	F_1
单层 CNN	0.8437	0.8421	0.8432
多层 CNN	0.8214	0.8201	0.8209

通过表 3-4 中对比两种层数的 CNN 实验可以看出,单层 CNN 的性能依旧优于多层 CNN,分类精确率达到 84.37%,比多层 CNN 的分类精确率高 2.23%。所以本文所提出的算法基于单层 CNN 进行了改进。结果表明:多层 CNN 相较于单层 CNN,其网络结构更为复杂,它包含了更多的卷积层和参数。这种结构上的复杂性带来了计算资源消耗的增加,因为在训练和推理过程中,多层 CNN 需要处理更多的参数和层间连接,所以只增加卷积神经网络的层数对提高音乐多情感分类精确率是没有效果的。接下来对单层 CNN 和多层 CNN 的精度值和损失值进行可视化分析,结果如下图 3-7 所示。




图 3-7 不同模型训练曲线图
Fig.3-7 Training curves of different models

从图 3-7 可以看出,就训练精度曲线可以直观地观察到两个模型的差异较小,但可以看出单层 CNN 的训练曲线是高于多层 CNN 的,同时图中表明多层 CNN 的波动较大,

单层 CNN 的精度曲线波动较小,说明它在训练过程中更加稳定。接着分析损失曲线,其变化趋势与精度曲线相似,两个模型的损失曲线相对接近,但单层 CNN 的损失曲线还是低于多层 CNN 的损失曲线,这种损失曲线的差异进一步证实了单层 CNN 在训练过程中的稳定性。

(3) WSM-CNN 和单层 CNN 进行音乐多情感分类的对比实验

将本章提出的新算法 WSM-CNN 与单层 CNN 的实验结果进行对比分析,结果见下表 3-5 所示。

表 3-5 分类结果

Table.3-5 Classification results

算法模型	p_{re}	r_{ec}	F_1
单层 CNN	0.8437	0.8421	0.8432
WSM-CNN	0.8954	0.8946	0.8951

通过表 3-5 的对比实验结果可以清晰地看出 WSM-CNN 模型相较于传统的单层 CNN 模型在分类效果上的提升。具体来说,WSM-CNN 模型的精确率相比单层 CNN 模型提高了 5.17%,召回率和 F_1 值的结果也要优于单层 CNN,进一步证明了 WSM-CNN 模型在性能上的优势。

这一结果说明 WSM-CNN 模型在单层 CNN 模型的基础上进行了有效改进,利用 Word2Vec 词嵌入的方法将歌词转换为向量的方法可以更好地捕捉歌词中的语义信息,同时在单层 CNN 的基础上添加三种不同高度的卷积核,可以使得模型能够更加全面地分析歌词情感特征,从而提高音乐多情感分类的精确率。

同样为了进一步分析这两类模型之间的差异性,对其进行可视化分析。两类模型的训练精度和损失如下图所示 3-8 所示。




图 3-8 不同模型训练曲线图

Fig.3-8 Training curves of different models

由图 3-8 可以看出,WSM-CNN 模型的整体精度值明显高于单层 CNN,由此说明 WSM-CNN 模型通过其独特的改进方法使得在音乐多情感分类任务上取得了显著的性能提升。此外在损失曲线上可以看出,WSM-CNN 模型的损失曲线前期波动较大,恰好反映了模型在训练过程中的调整和优化。更重要的是,WSM-CNN 模型的损失曲线收敛

速度明显快于单层 CNN，这表明模型能够更快地学习到数据的内在规律，并且更早地进入稳定的学习阶段，并且整体的损失曲线低于单层 CNN。由此可以看出，WSM-CNN 模型在音乐多情感分类上的有效性。

3.5 本章小结

本章提出并实现了一种融合 Word2Vec 词嵌入的多核卷积神经网络音乐多情感分类算法(WSM-CNN)，主要是对 Word2Vec 词嵌入和卷积神经网络这两种关键技术进行了详细的介绍，并在此基础上进行了改进。具体来说，本章首先利用 Word2Vec 词嵌入提取歌词局部特征，构建特征情感向量，挖掘歌词中情感信息，将歌词转化为更利于分类器模型输入的词向量；然后在分类器中，选用卷积神经网络模型，并在此基础上采用三种不同高度卷积核的方式构建新模型以此得到多情感分类；之后为了确保模型的泛化能力和稳定性，还进行了模型的正则化和训练；最后设计三组不同的对比实验，第一组对比了机器学习和深度学习分类算法在音乐多情感分类任务上的表现、第二组对比了不同层数的 CNN 算法的性能、第三组则直接对比了 WSM-CNN 和单层 CNN 算法的实验结果。结果表明本章所提出的 WSM-CNN 的确优于其它分类算法，验证了该算法解决音乐多情感分类领域中情感提取不充分以及分类器过拟合导致准确率不高等问题的有效性。

第4章 结合自注意力机制的改进词嵌入音乐多情感分类算法 (WSM-ACNN)

在第三章中已经介绍了 WSM-CNN,为了更好地提取歌词情感特征以及提高模型训练的效率,本章在第三章的基础上提出了新的改进算法:在 Word2Vec 词嵌入上加入 N-grams 和情感词典,并将自注意力机制加入改进的卷积神经网络中,设计并实现了结合自注意力机制的改进词嵌入音乐多情感分类算法(WSM-ACNN),详细地阐述了该算法的原理并对其添加优化算法,设计对比实验进行结果分析。最后针对音乐歌词数据集不均衡从而影响分类效果的问题,对数据进行了均衡化处理。

4.1 关键技术

4.1.1 改进 Word2Vec

在上章中选用的 Word2Vec 词嵌入技术在分配向量时尽管考虑了单词的上下文,但它对输入歌词中的所有词都进行同样的操作,这会导致具有高维度的合成向量,还是有一定的风险。因此,为了更好地改进音乐多情感分类,本章节提出了改进的 Word2Vec 模型:首先利用 N-grams 技术将输入歌词分成多个部分。N-grams 是一种基于滑动窗口的文本分割方法,它将文本中的连续 N 个词作为一个单元进行处理。其定义公式可见式(4-1)所示。

$$P_{n\text{-grams}}(w_1:N) = \prod_{i=n}^N \frac{C(w_{i-n+1:i})}{C(w_{i-n+1:i-1})} \quad (4-1)$$

式(4-1)中: $P_{n\text{-grams}}(w_1:N)$ 是句子在 n-grams 模型下的概率, $C(w_{i-n+1:i})$ 是在语料库中,连续 n 个词 $w_{i-n+1:i}$ 出现的次数, $C(w_{i-n+1:i-1})$ 是在语料库中,连续 $n-1$ 个词 $w_{i-n+1:i-1}$ 出现的次数。

通过使用 N-grams,模型能够关注到歌词中的局部模式,这对于捕捉情感信息尤为重要,因为情感往往通过特定的词汇组合来表达。接着,模型使用情感词典来识别这些 N-grams 中包含情感词的一个或多个部分。情感词典是一种包含情感词汇及其属性的资源,它能够帮助模型快速识别文本中的情感倾向。通过匹配 N-grams 中的词汇与情感词典中的条目,模型可以筛选出那些具有情感倾向的词汇组合。最后,这些包含情感信息的 N-grams 被输入到 Word2Vec 模型中进行训练。在训练过程中,模型会重点学习这些 N-grams 的表征,从而使得模型能够更好地捕捉到歌词中的情感信息。这种方法不仅提高了模型对情感歌词的表征能力,还能够增强模型对情感相关词汇的区分能力。

4.1.2 自注意力机制

在自然语言处理中,自注意力机制被作为一种重要的工具被广泛应用。在分类中,

自注意力机制会在特征已经聚合的情况下进行加权，计算出一个权重矩阵，该矩阵表示文本中每个单词或短语与其他所有单词或短语之间的关联程度，通过评估这些关联性，注意力机制能够根据上下文信息动态调整权重，使得模型能够更加精确地理解文本中的语义关系，同时使用权重矩阵来聚合上下文信息，这种权重的分配是基于每个元素对于当前处理任务的贡献度，从而使得模型能够更好地捕捉到对当前任务最为关键的信息^[72]。对于文本中的每个单词或短语，模型会根据权重矩阵选择与其关联度最高的上下文单词或短语，并将这些上下文信息聚合起来，有利于关键情感信息的捕捉，也会在一定程度上对模型的泛化能力和过拟合提供帮助。可以添加到深度学习模型中以增强模型对文本的理解和处理能力。自注意力机制的模型原理图如下图 4-1 所示。




图 4-1 自注意力机制模型图
Fig.4-1 Self-attention model diagram

具体计算公式可见式(4-2)、(4-3)、(4-4)、(4-5)所示。

$$Attention(Q, K, V) = \text{soft max}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (4-2)$$

$$Q = W^Q X \quad (4-3)$$

$$K = W^K X \quad (4-4)$$

$$V = W^V X \quad (4-5)$$

上述式中： X 为输入向量， W 为矩阵， Q 表示查询 Query， K 表示索引 Key， V 表示内容 Value，其值都是通过 X 和超参（先初始化，后通过训练优化）进行矩阵运算得来的。

4.2 WSM-ACNN 音乐多情感分类算法

本章提出了结合自注意力机制的改进词嵌入音乐多情感分类算法，该算法在音乐歌词数据集的基础上，利用改进的 Word2Vec 技术，包含 N-grams 和情感词典，并在单层多核 CNN 基础上将自注意力机制加入池化层之后，以提高音乐多情感分类精确率。WSM-ACNN 算法的模型如图 4-2 所示。




图 4-2 WSM-ACNN 模型图

Fig.4-2 WSM-ACNN model diagram

第1层是输入层，它的作用是接收输入数据，本次接收的数据是经过改进 Word2Vec 技术处理后的词向量，筛选出不重要的情感向量，降低了计算复杂度，减少模型需要学习的信息量，为后续分类器降低负担。

第4层是本次研究加入的自注意力机制，以往的研究中加入注意力一般在数据预处理这一层面上，而这次所研究的是在卷积神经网络中池化层之后，这一创新性的设计可以使情感特征在已经聚合的基础上进行加权，这有助于模型识别出全局特征中的关键信息；此外，通过在模型中引入自注意力机制还减少了不必要的计算负担，因为自注意力机制允许模型忽略掉一些不重要的信息，从而提高了模型训练的效率；最后，在池化层后应用自注意力机制还可以更好地整合全局信息，对于理解整个序列的全局特征有积极作用。这种设计使得分类器在处理音乐歌词情感分类任务时，能够更快地收敛，并在测试数据上展现出更高的准确性和更稳定的性能。

其余层的操作和第三章的 WSM-CNN 的原理相同，详细过程在 3.2 小节已经阐述，在此不再重复叙述。

4.3 RAdam 优化算法

在 3.3 小节中曾提到过利用多分类交叉熵损失函数进行模型训练，在后续研究过程中，发现可以通过优化算法来最小化损失函数，以达到训练不同模型的目的。模型通过这种方法能够学习到如何调整其参数，以便更好地预测训练集中的类别标签。在训练过程中，这种优化通常是通过梯度下降算法或其变体来实现的，如标准梯度随机梯度下降 (SGD) 或 Adam 优化器。这些优化算法在处理学习率的问题上，往往采取将学习率设置为一个固定的值，或者让学习率随着训练迭代次数的增加而逐渐减小，这种做法虽然在一定程度上简化了学习率的管理，但它却忽略了一个至关重要的问题：学习率对模型性能的深刻影响。

因此在传统梯度下降的算法基础上，为了更好地适应深度学习模型训练过程中学习率调整的复杂性，研究者们研究出了一系列针对学习率自适应调整的优化算法。为了深

入理解不同优化器对所提出算法性能的影响，本文在所提出的模型上进行了对比实验。这些实验使用了 SGD 算法、Adam 算法以及 RAdam 算法三种不同的优化器。通过对比实验，希望找出在不同情境下表现最佳的优化器，以及确定最合适的学习率设置。在实验中，初始学习率被设置为相同的值：0.001。这样的设置旨在观察学习率的变化对模型性能的影响。下图 4-3、4-4 为三种优化器在学习率是 0.001 时的精度和损失曲线，这些曲线直观地展示了不同优化器在训练过程中的表现。




图 4-3 不同优化器训练精度曲线图

Fig.4-3 Curve graph of training accuracy for different optimizer




图 4-4 不同优化器训练精度曲线图

Fig.4-4 Curve graph of training accuracy for different optimizer

从图 4-3、4-4 中可以清楚地发现：(1)SGD 算法的鲁棒性相较于其它两类算法来说并不好，在学习率为 0.001 时，Adam 和 RAdam 算法表现性能比较优异，对分类的结果也比较一致，并且对于模型的训练精度曲线来说也高度重合。(2)Adam 和 RAdam 两个算法的损失曲线降低的速度明显快于 SGD 算法，并且在训练的后续阶段与 SGD 算法相比相对稳定，这一现象表明自适应学习率的优化算法在收敛速度和学习稳定性方面具有显著优势。(3)RAdam 算法在总体精度和损失方面均优于 Adam 算法。此外，RAdam 算法对初始学习率的敏感性低于 Adam 算法。这是由于 RAdam 算法中嵌入了一个整流化项，该整流化项使得算法能够适应更宽泛的初始学习率范围，进而实现在更广阔的参数空间内进行优化。

实验结果表明，三类算法中 RAdam 算法表现效果最优异，因此本文中使用的优化算法为 RAdam 优化算法。RAdam 算法在保持 Adam 算法快速收敛优势的基础上，进一

步提高了整体精度和损失表现，同时降低了初始学习率对算法性能的影响，使得 RAdam 算法在深度学习等领域的应用中具有更高的实用性。

4.4 实验结果与分析

本章实验在第三章同一台机器下进行操作，不再介绍实验环境和参数设置，具体已在 3.4.1 节完整叙述。

4.4.1 实验结果对比分析

本章节主要设计并实现了结合自注意力机制的改进词嵌入音乐多情感分类算法 (WSM-ACNN)，由于第三章中已经实现了 SVM、KNN、RNN、多层 CNN、单层 CNN 和 WSM-CNN 在音乐多情感分类任务上的对比实验。因此在本小节中，将 WSM-ACNN 算法与以上算法的分类结果进行对比分析，其中评价标准与第三章评价标准一致。实验结果见下表 4-1 所示。

表 4-1 分类结果
Table.4-1 Classification results

算法模型	P_{re}	r_{ec}	F_1
KNN	0.7098	0.7088	0.7093
SVM	0.7362	0.7349	0.7358
RNN	0.7928	0.7914	0.7919
单层 CNN	0.8437	0.8421	0.8432
多层 CNN	0.8214	0.8201	0.8209
WSM-CNN	0.8954	0.8946	0.8951
WSM-ACNN	0.9275	0.9260	0.9268

由上表中可以得出：

(1)通过对比机器学习以及深度学习中 RNN、单层 CNN、多层 CNN 可以看出，WSM-ACNN 算法在音乐多情感分类任务上的表现更为优异，因此本章提出的 WSM-ACNN 不仅是一种可行的解决方案，而且是一种在音乐多情感分类领域内有效且具有改进性的算法。

(2)通过对比 WSM-CNN 和 WSM-ACNN 的实验结果可以得到，WSM-ACNN 的三类评价指标均高于 WSM-CNN，说明 WSM-ACNN 在 WSM-CNN 的基础上使用改进的 Word2Vec 词嵌入技术和加入自注意力机制方式是有效的。这是因为使用改进的 Word2Vec 技术可以更好地捕捉歌词情感信息，在池化层之后加入注意力机制可以获得歌词重点情感特征，从而提高情感分类的精确率。

为了更加清楚地对比 WSM-CNN 和 WSM-ACNN 的分类效果，将两者进行可视化分析，测试模型的输出结果如下图 4-5 所示。




图 4-5 不同模型训练曲线图

Fig.4-5 Training curves of different models

从图 4-5 中可以看出，WSM-ACNN 的训练精度曲线在 WSM-CNN 的训练精度曲线的上面，而且，在初始训练中，WSM-ACNN 的精度是优于 WSM-CNN 的。同时损失曲线中，代表 WSM-ACNN 的颜色曲线位于 WSM-CNN 的颜色曲线之下，且初始损失值比 WSM-CNN 要小。由此说明，在 WSM-CNN 的基础上进行改进的 WSM-ACNN，通过改进词嵌入方式和加入自注意力机制的方式可以更好地提取歌词情感特征、提高多情感分类结果。

4.4.2 均衡和不均衡数据集验证实验

在针对歌词的音乐多情感分类领域中面临的一个关键挑战是情感类别的内在不均衡性。具体来说，四类情感——欢快、伤感、治愈和宣泄，在现实生活中的分布本身就是不均匀的。这种不均衡性意味着某些情感类别的歌词出现的频率要远高于其他类别。由于这种自然的不平衡，当构建用于训练分类模型的歌词数据集时，这些数据集往往也呈现出不均衡的特点。本文采用的数据集中各类情感的占比如下图 4-6 所示。




图 4-6 各类情感占比图

Fig.4-6 Proportion chart of various emotions

从图 4-6 中可以看出，在四类情感类别中，其中欢快和伤感占据数据集总数的 60% 以上，相比之下另外两类情感数量占比太少，这样是不均衡的，会导致模型训练和学习过程中过多地关注占比较大的类别，而占比少的情感类别会被无法学习到有效的特征，导致分类性能不佳。在分类环节构建的混淆矩阵如表 4-2 所展示，表中各行表示情感的

实际分类，各列则指示预测出的分类。观察下表得出，那些在数据集中所占比例较小的情感类别往往被错误地划分到比例较大的情感类别中，例如，最多的有 307 条“伤感”类情感被错误预测为“欢快”。

表 4-2 混淆矩阵

Table.4-2 Confusion matrix

	欢快	宣泄	治愈	伤感
欢快	8132	246	178	137
宣泄	191	3276	102	149
治愈	253	126	4681	114
伤感	307	86	171	6482

为了解决不平衡数据集产生的问题，需要将数据集进行均衡化处理，使四个情感类别的数据集占比相同，实验模型选用音乐多情感分类效果中最好的 WSM-ACNN。均衡和不均衡的实验对比结果见下表 4-3 所示。

表 4-3 均衡和不均衡对比结果

Table.4-3 Comparison results of equilibrium and imbalance

数据集	p_{re}	r_{ec}	F_1
不均衡	0.9275	0.9260	0.9268
均衡	0.9452	0.9439	0.9447

从表 4-3 中可以看出，WSM-ACNN 在均衡数据集的分类效果优于在不均衡数据集上的分类效果，精确率提升了 1.77%，说明使用均衡数据集对音乐歌词进行多情感分类，能够解决情感数据集占比不均的问题，从而进一步提高音乐分类的精确率。

为了进一步分析在两个数据集上的差异性，将其进行训练精度和损失的可视化分析，结果如下图 4-7 所示。




图 4-7 均衡和不均衡数据集训练曲线图

Fig.4-7 Training curves for balanced and imbalanced datasets

由图 4-7 中可看出，(1)WSM-ACNN 在均衡数据集上的损失曲线是略低于不均衡数据集的，而且训练精度曲线则是略高于不均衡数据集的。(2)WSM-ACNN 的损失曲线在均衡数据集上随着迭代次数的不断增加而趋于平缓最终趋向收敛状态，同时波动的幅度明显变小。因此，经过均衡化处理数据集后的 WSM-ACNN 模型对音乐多情感分类结果

有着一定程度的提高，说明了数据集均衡性对模型性能的重要性，也展示了通过利用均衡数据集的方式来优化模型性能的有效性。

4.5 本章小结

本章主要提出并实现了结合自注意力机制的改进词嵌入音乐多情感分类算法 (WSM-ACNN)，该算法在第三章提出的 WSM-CNN 基础上改进而完成。首先阐述了改进的 Word2Vec 来准确提取歌词情感特征，主要是利用 N-grams 技术将输入歌词分成多个部分，而后使用情感词典来识别 N-grams 中包含情感词的一个或多个部分，通过匹配 N-grams 中的词汇与情感词典中的条目，筛选出最具有代表性的情感信息作为输入，进入到 Word2Vec 中进行训练转为词向量；其次在池化层之后加入自注意力机制，有助于模型识别全局特征中的关键信息减少计算负担。再者为了更好地预测训练中的情感类别标签，经过对比选用了 RAdam 算法作为 WSM-ACNN 的优化器进行后续的训练。后来在 SVM、KNN、RNN、单层 CNN、多层 CNN 的基础上加入第三章提出的 WSM-CNN 算法，实验结果验证了第四章提出的 WSM-ACNN 算法的有效性。最后针对情感类别数据集占比不均衡的问题进行了处理，得到的结果则是均衡化的分类算法在实验结果上得到了进一步的提高，解决了音乐多情感分类领域中歌词情感数据占比不一致的问题，验证了数据集均衡性对于情感分类的重要性。

第5章 个性化音乐情感推荐系统的设计与实现

个性化音乐情感推荐系统是为了应用 WSM-ACNN 分类算法而设计的可视化系统，该系统主要实现了音乐情感分类和推荐，满足人们打开音乐系统时可以根据当下心情而选择匹配的音乐聆听。本章从系统设计、需求分析以及实现三个方面进行相关阐述。

5.1 个性化音乐情感推荐系统需求分析

本文在深入探索音乐多情感分类的基础上，利用提出的 WSM-ACNN 算法将其成功应用于个性化音乐情感推荐系统。该系统通过结合音乐歌词情感分类技术和 Web 网站技术，设计并开发了一个直观、易用的可视化音乐界面。希望通过这个系统，将音乐情感分类和推荐服务融为一体，为用户构建一个全面的音乐情感体验平台。

首先，该系统具备对音乐库中的曲目进行精细情感分类的能力，能够识别如伤感、治愈、快乐等多种情感状态。这种分类能力的核心是基于歌词的音乐多情感分类技术，它为音乐分类和管理人员提供了强大的辅助工具，帮助他们更加高效地完成音乐资源的整理和分类。其次，系统致力于满足用户在特定情感状态下的个性化听歌需求，旨在为用户提供一个更加沉浸式和个性化的音乐体验。例如，当用户处于伤感情绪时，系统可以根据用户的情感状态推荐一些温暖、治愈的歌曲，帮助用户平复情绪，找到慰藉。这种情感驱动的推荐机制，不仅能够满足用户的心理需求，还能够提升用户的整体听歌体验。此外，系统还能够根据用户的历史听歌数据和情感反馈，不断优化推荐算法。通过这种方式，推荐结果将更加精准地贴合用户的个人喜好和情感变化，使得音乐推荐服务变得更加智能化和个性化。在快节奏的现代生活中，这样的系统可以帮助人们更加有效地管理自己的情绪，利用音乐的力量寻找内心的平衡和宁静。通过这个平台，用户不仅能够享受到高品质的音乐，还能在音乐中找到情感的共鸣和心灵的慰藉。

5.2 个性化音乐情感推荐系统设计

个性化音乐情感推荐系统的系统设计主要分为四个模块：表示层、逻辑层、访问层、系统层。

表示层：作为用户与系统交互的最前端界面，承担着接收用户输入和展示处理结果的重要任务。当用户通过界面进行操作时，会触发一系列的事件，这些事件通过表示层的捕获，转化为系统可以理解的事件反馈给访问层。而经过访问层的信息传递，这些事件和相关数据被传递到系统层，系统层通过处理这些事件，生成新的数据或者修改现有数据，最终，处理完毕的数据需要反向传播回表示层。

逻辑层：实现各种业务功能，它位于表示层和系统层之间，起承上启下的作用。当前端界面需要访问数据或者执行某些操作时，前端界面会将请求发送到逻辑层。逻辑层接收到前端界面的请求后，会根据请求的类型和内容，进行相应的逻辑处理，同时它不

仅负责处理来自前端的数据请求，还要负责表示层和系统层之间的数据交互。

访问层：是系统架构中的一个关键层次，它充当系统的持久层，负责对数据库中的数据进行管理。在这一层，系统实现对数据的增、删、改、查等操作，确保数据的完整性和一致性。在访问层处理的数据中，主要包括用户信息和音乐相关信息的两大类数据。

系统层：该层主要负责处理网络请求以及管理数据存储的核心职责。它遵循数据处理的标准流程，对数据进行收集、处理和保存，涵盖了从音乐歌词数据的输入、数据的初步处理、模型的训练，到 WSM-ACNN 算法的应用以及分类结果的记录等环节。此外，系统层还保障了数据的准确传递和系统的流畅运作。它负责将逻辑层的处理指令转化为访问层的数据操作，同时也会将访问层采集的数据反馈给逻辑层进行处理。当一首音乐通过 WSM-ACNN 模型进行预测，得出的情感类别存在不一致时，系统会将这首音乐单独暂存于一个特定的文件夹中，等待管理员的人工审核和分类。

具体系统结构如下图 5-1 所示。




图 5-1 个性化音乐情感推荐系统结构

Fig.5-1 Structure of personalized music sentiment classification recommendation system

5.3 个性化音乐情感推荐系统实现

个性化音乐情感推荐系统，一方面将提出的 WSM-ACNN 算法应用于音乐多情感分类，拓宽了算法应用途径，解决了音乐分类中情感匹配度不足的问题。另一方面建立了可视化的音乐情感分类和推荐界面，满足了人们的个性化听歌需求，促使音乐推荐服务变得更加智能化。

具体效果实现界面如图 5-2、5-3、5-4、5-5、5-6 所示。

图 5-2 为该系统主界面，用户在无需注册的情况下可以点击首页和探索界面进行查看，登录之后用户可以创建收藏自己的歌单。用户在登录之后，可选择自己喜欢的系统主题模式等内容。



图 5-2 系统主界面
Fig.5-2 System main interface




图 5-3 情感分类界面
Fig.5-3 Sentiment classification interface

上图 5-3 为用户通过这个界面选择不同类型的情感歌曲，界面布局清晰，操作简便，使得用户能够迅速找到符合自己心情的音乐。在界面上，有一系列的情感标签或图标，如图上述展示的“伤感”、“温暖”、“励志”等，用户只需点击相应的标签或图标，系统就会展示与之相关的歌曲列表。这些情感标签配以相应的图案，以增强视觉识别度，帮助用户更快地识别和选择。

下图 5-4 为具体的歌手推荐界面，界面中包含了多个歌手的头像和姓名，同时设计滚动功能，让用户能够轻松浏览更多的推荐内容。




图 5-4 歌手推荐界面

Fig.5-4 Singer recommendation interface

下图 5-5 中以歌手林俊杰为代表的详细界面，包括歌手简介，演唱曲目，其中演唱曲目中的推荐度由上而下排布，让用户直观选择大众曲目喜爱程度。



图 5-5 具体歌手界面

Fig.5-5 Specific singer interface



图 5-6 歌曲播放界面

Fig.5-6 Song playback interface

上图 5-6 为歌曲播放界面，该界面提供了丰富且直观的操作按钮，旨在让用户能够

轻松地控制音乐播放，享受个性化的听歌体验。在歌曲播放具体操作区域，包括了一组核心控制按钮，如播放、暂停、上一首、下一首，以及下载等按钮。歌曲播放界面不仅提供了基本的播放控制功能，还让用户能够根据自己的听歌习惯和偏好进行个性化设置，从而极大地提升了用户的音乐播放体验。

5.4 本章小结

本章开发并实现了个性化音乐情感推荐系统，阐述了该系统的需求分析、系统设计和具体实现过程。首先，在系统需求分析部分，详细阐述了音乐情感分类、用户个性化听歌偏好分析以及音乐推荐三个核心需求。其次，在系统设计部分，以 Web 网页作为实现界面平台，系统整体架构包括表示层、逻辑层、访问层、系统层，其中核心的音乐情感分类模块采用 WSM-ACNN 算法进行训练。最后详细阐述了个性化音乐情感推荐系统的具体实现效果，通过实际应用测试表明，该系统能够有效识别用户的情感状态，提供精准的音乐推荐服务，具有良好的用户体验和实用价值，为音乐平台的智能化发展提供了新的解决方案。

第6章 总结与展望

6.1 总结

音乐多情感分类任务是一项具有广泛应用前景和社会价值的科学研究课题,随着网络技术迅速发展,深度学习算法在处理大规模数据方面取得了显著的成果,尤其是 CNN,但在面临未来多方面的需求时,如何在 CNN 算法的基础上进行不断的改进,提高其适用性和准确性是很重要的,因此,本文利用改进的 CNN 提出新算法用于音乐多情感分类任务中,并从以下几个方面进行研究:

(1)在数据方面,当前公开的数据集存在老旧的问题,限制了研究者在音乐多情感分类任务上的进展,为此本文对相关数据进行了爬取,以获取最新的音乐歌词数据。本文选择了一个包括四类情感的数据集,后续又对其进行分词,对分词后的歌词进行了数据整合并构建了适合音乐多情感分类的词汇表。在情感向量表示方面,选择了 Word2vec 预训练的词向量作为输入,解决了歌词特征提取困难和局部情感特征提取不够全面等问题。

(2)本文设计并实现了融合 Word2Vec 词嵌入的多核卷积神经网络音乐多情感分类算法,本文提出的算法关键在于对单层卷积神经网络进行改进,通过在卷积层中集成三种不同尺寸的卷积核,实现了对歌词情感特征更为全面和精细的提取,同时减少了连续卷积可能引起的信息遗失。为进一步验证该算法的性能,研究设计了一系列对照性实验。对比了 WSM-CNN 与传统机器学习算法 SVM、KNN,以及深度学习算法 RNN、单层 CNN 和多层 CNN 的表现。实验结果显示,WSM-CNN 在音乐多情感分类任务上实现了 89.54%的高准确率,显著领先于其他参比算法。

(3)为了避免深度学习算法在训练过程中常见的问题,如鲁棒性差、梯度消失或爆炸等,本文引入了 Dropout 层,该机制的主要功能是在神经网络计算过程中随机地抑制特定层中的一些神经元,导致这些受抑制的神经元在当前的训练周期内不参与计算及参数的更新。采用这种策略,模型能够有效地缓解过拟合的问题。此外,本文还对比了三种流行的优化算法:Adam 优化算法、SGD 优化算法和 RAdam 优化算法,通过实验结果的详细分析,发现 RAdam 优化算法具有一些显著的优势。RAdam 算法通过引入整流项,使其对不同学习率具有更好的鲁棒性,这意味着它能够在更广泛的超参数设置下保持稳定和有效的训练过程。

(4)在 WSM-CNN 算法的基础上,本文进一步探索了算法的优化空间,设计并实现了 WSM-ACNN。该算法为了更精确地提取歌词中的情感特征并提升模型训练的效率,在原有的 Word2Vec 词嵌入基础上进行了扩展,引入了 N-grams 和情感词典,此外,本文将自注意力机制融入到改进的卷积神经网络中,使得神经网络更加聚焦于情感关键信息。接着设计不同算法的对比实验,分别与 WSM-CNN 算法以及复现的算法进行了实

验对比,结果显示,WSM-ACNN 在音乐多情感分类任务中的精确率高达 92.75%,显著优于其它对比算法。后续进一步考虑到数据集样本不均衡可能对分类性能产生的影响,在 WSM-ACNN 上设计额外的对比实验,通过对数据集进行均衡处理后实验结果表明分类效果更为出色,精确率达到 94.52%,也进一步验证了算法的有效性和实用性。

(5)基于音乐多情感分类的成果,本文进一步探索了 WSM-ACNN 在个性化音乐情感推荐领域的应用,设计并实现了一个可视化音乐界面。该界面集成了音乐情感分类与推荐功能,旨在满足用户在听音乐时对情感选择的需求。该系统不仅能够自动对音乐进行情感分类,还能够提供个性化的音乐推荐。经过实际应用测试,结果显示该系统在识别用户情感状态和提供精确推荐服务方面表现出色,具备了良好的用户体验和实际应用价值。本文通过结合音乐多情感分类与个性化推荐,为用户带来了更加智能化的音乐体验,同时也为音乐产业的数字化转型和智能化发展提供了强有力的技术支持。

本文以音乐多情感分类任务为研究对象,成功实现了两种高效的分类算法和一个音乐情感推荐系统,有效解决了相关领域中面临的难题,为其理论发展和实际应用提供了新的思路和方法支撑。

6.2 展望

本文提出并实现了 WSM-CNN 和 WSM-ACNN 两种音乐多情感分类算法、设计并开发了一个推荐系统。但对其经过深入分析,发现仍有提升的空间。为了进一步优化算法和系统,本文提出了以下几个研究方向和改进点:

(1)模型泛化能力的提升:目前本文的实验仅基于音乐歌词数据集进行。为了提高模型的泛化能力,未来可以将本文提出的模型应用于其它情感分类任务,以验证模型的适用性。

(2)集成学习策略的探索:基于集成学习的思想,可以将本文提出的算法与其他优秀算法相结合,构建出一个更加鲁棒和高效的集成学习系统。

(3)个性化音乐情感推荐系统的完善:在个性化音乐推荐领域中,情感分类扮演着至关重要的角色。本文计划继续深入该领域的探索,完善个性化音乐情感推荐系统的功能,以满足用户日益增长的个性化需求,为音乐产业创造更多的经济价值和社会效益。

参考文献

- [1] 张昱,冯亚寒,丁千惠. 融合 Word2Vec 词嵌入的多核卷积神经网络音乐歌词多情感分类方法[J]. 科学技术与工程. 2024:24(20):8598-8605.
- [2] Bin S, Sun G. Matrix Factorization Recommendation Algorithm Based on Multiple Social Relationships[J]. Mathematical Problems in Engineering, 2021: 1-8.
- [3] Turchet L, Pauwels J. Music Emotion Recognition: Intention of Composers-Performers Versus Perception of Musicians, Non-Musicians, and Listening Machines[J]. IEEE/ACM Trans. Audio Speech Lang. Process, 2022: 305-316.
- [4] Korvel G, Kostek B. Discovering rule-based learning systems for the purpose of music analysis[J]. The Journal of the Acoustical Society of America, 2019: 2947-2947.
- [5] Chauhan P, Sharma N, Sikka G. TANTISA: a hybrid approach for text/non-text classification and sentiment analysis of multimodal social media images[J]. Sādhanā, 2025: 50, 33.
- [6] Pandeya Y R, Lee J. GlocalEmoNet: An optimized neural network for music emotion classification and segmentation using timbre and chroma features[J]. Multimed Tools Appl 83, 2024: 74141-74158.
- [7] Li T. Optimizing the configuration of deep learning models for music genre classification[J]. Heliyon, 2024: e24892.
- [8] 邵曦,陶凯云. 基于音乐内容和歌词的音乐情感分类研究[J]. 计算机技术与发展, 2015:25(08):184-187+193.
- [9] Takashima N, Li F, Grzegorzec M, et al. Embedding-Based Music Emotion Recognition Using Composite Loss[J]. IEEE Access, 2023: 36579-36604.
- [10] Cui X, Wu Y, Wu J, et al. A review: Music-emotion recognition and analysis based on EEG signals[J]. Frontiers in Neuroinformatics, 2022: 16: 997282.
- [11] Vlahavas I. Multilabel classification of music into emotions[J]. EURASIP Journal on Audio, Speech, and Music Processing, 2013: 1.
- [12] Chang P C, Chen Y S, Lee C H. IIOF: Intra and Inter-feature orthogonal fusion of local and global features for music emotion recognition[J]. Pattern Recognition, 2024: 110200.
- [13] Tong G. Music Emotion Classification Method Using Improved Deep Belief Network[J]. Mobile Information Systems, 2022: 1-7.
- [14] Su Y, Chen J, Chai R, et al. FFA-BiGRU: Attention-Based Spatial-Temporal Feature Extraction Model for Music Emotion Classification[J]. Applied Sciences, 2024: 6866.
- [15] Sujeesha A S, Mala J B, Rajan R. Automatic music mood classification using multi-modal attention framework[J]. Engineering Applications of Artificial Intelligence, 2024: 107355.
- [16] 杨帆,余华平. 中文歌词文本的情感分类综述[J]. 电脑知识与技术, 2021:17(03):207-208+215.
- [17] Zihayat M, Ayanso A, Zhao X, et al. A utility-based news recommendation system[J]. Decision Support Systems, 2019: 14-27.
- [18] Asenova M, Chrysoulas C. Personalized Micro-Service Recommendation System for Online News[J]. Procedia Computer Science, 2019, 160:610-615.
- [19] 门恭圣. 基于情感分类的个性化音乐推荐算法的研究与应用[D]. 天津工业大学, 2023.
- [20] 张晨光. 基于多模态特征融合的音乐情感识别及其应用研究[D]. 东华大学, 2022.

- [21]Gordon C, Bruner II. Music, Mood, and Marketing[J]. Journal of Marketing, 1990: 94-104.
- [22]Trochidis K, Tsoumakas G, Kalliris G, et al. Multi-label classification of music by emotion[J]. AUDIO SPEECH MUSIC PROC. 2011: 4.
- [23]Hu X, Choi K, Downie J S. A framework for evaluating multimodal music mood classification[J]. Journal of the Association for Information Science and Technology, 2007: 68(2):273-285.
- [24]Tiple B, Patwardhan M. Multi-label emotion recognition from Indian classical music using gradient descent SNN model[J]. Multimedia Tools and Applications, 2022: 8853-8870.
- [25]Lu L, Liu D, Zhang H J. Automatic Mood Detection and Tracking of Music Audio Signals[J]. IEEE Trans.audio Speech Lang, 2006, 14(1):5-18.
- [26]Liu J. An Automatic Classification Method for Multiple Music Genres by Integrating Emotions and Intelligent Algorithms[J]. Applied Artificial Intelligence, 2023: 2211458.
- [27]Chen C. Music Audio Sentiment Classification based on CNN-LSTM[J]. Communications Technology, 2019: 52(05): 1114-1118.10.
- [28]Roger V, Farinas J, Pinquier J. Deep Neural Networks for Automatic Speech Processing: A Survey from Large Corpora to Limited Data[J]. arXiv, 2020: [2025-03-24].
- [29]Akinpelu S, Viriri S. Deep Learning Framework for Speech Emotion Classification: A Survey of the State-of-the-Art[J]. IEEE Access, 2024: 12: 152152-152182.
- [30]Liu Z, Xu W, Zhang W, et al. An emotion-based personalized music recommendation framework for emotion improvement[J]. Information Processing & Management, 2023: 60(3): 103256.
- [31]Salur M U, Aydin I. A novel hybrid deep learning model for sentiment classification[J]. IEEE Access, 2020: 58080-58093.
- [32]李军. 基于混合策略的音乐推荐系统研究与实现[D]. 山东大学, 2020.
- [33]Pandeeya Y R, Bhattarai B, Lee J. Deep-Learning-Based Multimodal Emotion Classification for Music Videos[J]. Sensors, 2021: 21(14): 4927.
- [34]Li J, Soradi-zeid S, Yousefpour A, et al. Improved differential evolution algorithm based convolutional neural network for emotional analysis of music data[J]. Applied Soft Computing, 2024: 153: 111262.
- [35]Li Y, Zhang Z, Ding H, et al. Music genre classification based on fusing audio and lyric information[J]. Multimedia Tools and Applications, 2023: 82(13): 20157-20176.
- [36]Zhang D, Zhu Z, Kang S, Zhang G, Liu P. Syntactic and semantic analysis network for aspect-level sentiment classification[J]. Appl Intell, 2021: 51:6136-6147
- [37]Zhu Y, Zheng W, Tang H. Interactive dual attention network for text sentiment classification[J]. Computational intelligence and neuroscience, 2020: (3):1-11
- [38]Kumar MRP, Jayagopal P. Context-sensitive lexicon for imbalanced text sentiment classification using bidirectional LSTM[J]. Journal of Intelligent Manufacturing, 2023: 34(5): 2123-2132.
- [39]张志勋,王娟. 基于短文本情感分类的微博舆情分析[J]. 中国新通信, 2019:21(14):240-241.
- [40]Nasukawa T, Yi J. Sentiment analysis: Capturing favorability using natural language processing[C].//Proceedings of the 2nd international conference on Knowledge capture, 2003: 70-77.
- [41]Whissell C. Objective analysis of text: II. Using an emotional compass to describe the emotional tone of situation comedies[J]. Psychol Rep, 1998: 643-646.
- [42]李晨,朱世伟,魏墨济,等. 基于词典与规则的新闻文本情感倾向性分析[J]. 山东科学, 2017:30(01):115-121.

- [43]Wang R, Li Z, Cao J, et al. Convolutional recurrent neural networks for text classification. In: 2019 International joint conference on neural networks (IJCNN)[J]. IEEE, 2019: 1-6.
- [44]Liu T, Yu S, Zhang H, Yin H. Recurrent neural networks and convolutional neural networks for text classification[J]. Computer engineering & software, 2018: 39(01):64-69.
- [45]Zhang X, Zhao J, LeCun Y. Character-level convolutional networks for text classification[J]. Advances in neural information processing systems, 2015: 28:649-657.
- [46]Liu C, Feng L, Liu G, et al. Bottom-up Broadcast Neural Network For Music Genre Classification[A]. arXiv, 2019: 2025-03-24.
- [47]Meb A, Sn A, Ma B, et al. Abcdm: An attentionbased bidirectional cnn-rnn deep model for sentiment analysis[J]. Futur Gener Comput Syst, 2021: 115:279-294
- [48]Ahmed N A, Shehab M A, Al-ayyoub M, et al. Scalable multi-label arabic text classification. In: 2015 6th International conference on information and communication systems (ICICS)[J]. IEEE, 2015: 212-217
- [49]Minaee S, Kalchbrenner N, Cambria E, et al. Deep learning-based text classification: A comprehensive review[J]. ACM Computing Surveys (CSUR), 2021: 54(3):1-40
- [50]Pang B, Lee L, Vaaithyanathan S. Thumbs up?: sentiment classification using machine learning techniques[C]. Association for Computational Linguistics, 2002: 79-86 [2025-03-24].
- [51]Bandhakavi A, Wiratunga N, Padmanabhan D, et al. Lexicon based feature extraction for emotion text classification[J]. Pattern recognition letters, 2017: 93: 133-142.
- [52]高凯龙. 基于深度学习的中文文本情绪分类方法研究[D]. 北京建筑大学, 2022.
- [53]Ling M, Chen Q, Sun Q, et al. Hybrid neural network for Sina Weibo sentiment analysis[J]. IEEE Transactions on Computational Social Systems, 2020: 7(4): 983-990.
- [54]Selvakumar B, Lakshmanan B. Sentimental analysis on user's reviews using BERT[J]. Materials Today: Proceedings, 2022: 62: 4931-4935.
- [55]郑承宇,王新,王婷,等. 基于 Stacking-Bert 集成学习的中文短文本分类算法[J]. 科学技术与工程, 2022:22(10):4033-4038.
- [56]黄卫春,邹瑶,熊李艳,等. 基于卷积神经网络的多通道特征表示文本分类模型[J]. 科学技术与工程, 2021:21(16):6764-6771.
- [57]Mutinda J, Mwangi W, Okeyo G. Sentiment analysis of text reviews using Lexicon-enhanced Bert embedding(LeBERT) model with convolutional neural network[J]. Applied Sciences, 2023, 13(3): 1445-1445.
- [58]Chen R, Xu Z, Zhang Z, Luo F. Content Based Music Emotion Analysis and Recognition[C].//International Workshop on Computer Music and Audio Technology, 2006: 68-75.
- [59]Dan Y, Lee W S. Music Emotion Identification from Lyrics[C].//IEEE International Symposium on Multimedia, 2009: 624-629.
- [60]龚安,丁明波,窦菲. 基于DBN的多特征融合音乐情感分类方法[J]. 计算机系统应用, 2017:26(09):158-164.
- [61]王洁,朱贝贝. 面向中文歌词的音乐情感分类方法[J]. 计算机系统应用, 2019:28(08):24-29.
- [62]Jia X. Music Emotion Classification Method Based on Deep Learning and Improved Attention Mechanism[J]. Computational Intelligence and Neuroscience 2022: 1-8.
- [63]Yang Q, Liu S, Gong T. Improve the application of reinforcement learning and multi-modal information in music sentiment analysis[J]. Expert Systems, 2023: 21(2): 1154-1160.

-
- [64]刘开峰. 基于深度学习的新闻文本分类方法研究与应用[D]. 北京建筑大学, 2021.
- [65]Hao L, Hao L. Automatic identification of stop words in Chinese text classification[A]. International Conference on Computer Science and Software Engineering, 2008: 718-722.
- [66]Rahimi Z, Homayounpour M. TensSent: a tensor based sentimental word embedding method[J]. Applied Intelligence, 2021, 51(8): 6056-6071.
- [67]Yu K, Zhang Y, Wang X. Topic model over short texts incorporating word embedding[C].//Environment and Chemical Science. New York: AEECS, 2018.
- [68]Garg S, Subrahmanyam V. Sentiment analysis: choosing the right word embedding for deep learning model[M]. Berlin: Springer International Publishing, 2022.
- [69]Rezaeinia S, Rahmain R, Ghodsi A, et al. Sentiment analysis based on improved pre-trained word embeddings.[J]. Expert Systems with Applications, 2019: 117: 139-147.
- [70]Gu J, Li G, Jung J, et al. Contextual Word2Vec model for understanding chinese out of vocabularies on online social media[J]. International Journal on Semantic Web and Information Systems, 2022: 18(1): 1-14.
- [71]丁森华, 邵佳慧, 李春艳, 等. 歌词情感分类方法对比研究[J]. 广播电视信息, 2020, 2020(4): 92-96.
- [72]Trockman A, Kolter J Z. Mimetic Initialization of Self-Attention Layers[A]. arXiv, 2023: 2025-03-26.

DISSERTATION FOR
PROFESSIONAL MASTER'S

