

基于大数据技术的个性化 音乐推荐系统设计与实现

本科毕业设计·开题报告

数字化音乐时代的“信息茧房”与技术瓶颈

海量音乐资源带来了选择的自由，也带来了前所未有的筛选难题。



用户侧：信息过载

Source Han Sans SC Regular
面对千万级曲库，用户难以发现符合个人品味的新音乐，容易陷入“听歌疲劳”。



技术侧：传统算法失效

Source Han Sans SC Regular
早期的协同过滤和单机算法，在处理千万级交互日志时性能低下，无法满足工业级需求。



模型侧：核心难题待解

Source Han Sans SC Regular
普遍存在的“冷启动”和数据稀疏性问题，严重影响推荐的精准度。

项目价值：探索工业级推荐方案的理论与实践

理论意义



探索 **深度学习模型 (DeepFM)** 与 **分布式大数据架构 (Spark)** 的耦合机制。



为推荐系统中的多源异构特征融合与高阶非线性关系建模提供实践参考。



研究用户实时行为对静态画像的动态修正逻辑，深化用户理解。


实际应用价值



构建“**离线训练+在线预测**”的解耦架构，实现业务逻辑与算法引擎分离。



为中小型音乐平台提供一套低成本、高效率、具备工业参考价值的推荐解决方案。



产出一套完整的集成“**大数据挖掘**”与“**全栈Web开发**”的系统，具备直接部署潜力。

研究现状（一）：从协同过滤到深度语义建模的演进

国际研究起步早，已形成从基础算法到大规模分布式架构，再到深度语义挖掘的完整技术路线。

早期 (Early Stage)

以协同过滤 (Collaborative Filtering) 为主，奠定推荐系统基础。

中期 (Mid Stage)

转向大规模分布式架构。

案例：Niu Yizhen等学者探索了在 **Spark** 架构下并行化实现协同过滤，解决了海量数据计算效率问题。

近期 (Recent Stage)

深入到深度语义与用户偏好建模。

案例：Park & Lee (RecSys '22) 通过对比学习探索用户“**负向偏好**” (Negative Preference) 在内容推荐中的作用，指出“解释讨厌的音乐比解释喜欢的更易”，为理解用户品味提供了新视角。

趋势：应用注意力机制、自动编码等模型，更深层次地理解音乐内容与用户偏好。


研究现状（二）：国内前沿聚焦大数据与深度学习融合

近三年国内研究在系统实现、语义挖掘和知识图谱应用上取得显著进展。



系统工程实现 (System Engineering)

- **赵吉** 等人基于 **Spark** 提升了千万级日志处理效率，验证了分布式计算的可行性。
- **杨率** 利用深度神经网络等构建了高响应实时系统，聚焦于工程落地。



语义与情感挖掘 (Semantics & Emotion Mining)

研究重心正从内容特征转向情感理解。如**冯亚寒**利用改进型**WSM-CNN**模型对音乐歌词进行精准情感分类，为情感化推荐提供可能。



知识图谱应用 (Knowledge Graph Application)

李津 等通过引入知识图谱，关联音乐、歌手、风格等实体，有效优化推荐精度，缓解数据稀疏与冷启动问题。


核心研究目标：构建端到端的个性化推荐闭环

实现海量计算获取深度偏好，在线业务实现精准分发




系统总体架构：业务与算法的高效解耦

采用分层解耦设计，确保系统稳定性、可扩展性与维护性。



技术路线：贯穿“离线训练”与“在线服务”的数据闭环



研发环境与核心工具选型

后端服务 & 数据层 (Backend Service & Data Layer)



核心语言: Java 23



Web框架: Jakarta Servlet 6.1, JSP 3.1



数据库: MySQL 8.4.0



连接池: C3P0 0.9.5.5


大数据 & 算法引擎 (Big Data & AlgorithmEngine)



核心语言: Python 3.12



大数据框架: PySpark



深度学习库: PyTorch



推荐模型库: DeepCTR-Torch



核心算法: ALS (召回), **DeepFM** (排序)

拟解决的关键技术难题

难题一：跨语言系统的异步协作

 **问题：** Java在线业务系统与Python离线算法引擎如何高效、稳定地进行数据同步与任务调度？

 **解决方案：** 通过数据库作为中间件进行解耦，定义清晰的数据接口规范，利用定时任务（如Cron）驱动离线计算流程。

难题二：有限内存下的特征维数灾难

 **问题：** 在16GB内存环境下，如何处理高维稀疏特征，避免内存溢出并保证模型训练效率？

 **解决方案：** 利用 **PySpark** 进行分布式特征处理；采用 **DeepFM** 模型，通过Embedding层将高维稀疏特征映射到低维稠密向量。

难题三：动态冷启动下的表征不足

 **问题：** 新用户或新歌曲加入时，如何快速生成有效推荐？


 **解决方案：** 采用混合策略，对冷启动用户/物品优先使用基于内容的推荐或热门推荐作为补充。

项目核心创新点



创新点一：架构解耦

实现 **Java生产环境**与**Python离线引擎** 的高效协同。该架构将复杂的算法计算与高可用的在线服务分离，提升了整个系统的健壮性和可维护性。



创新点二：深度特征交互

应用 **DeepFM** 模型自动学习用户行为与音乐属性间的**高阶非线性关系**，超越了传统型仅能捕捉的低阶或线性特征，提升了推荐的精准度。



创新点三：多维画像动态修正

研究用户 **实时搜索行为** 对其长期静态画像的动态修正机制，使推荐更能反映用户当下的即时兴趣。

预期研究成果与量化指标

成果形式 (Deliverables)



一套完整的系统：一套可部署、可演示的，集成“大数据挖掘”与“全栈Web开发”的个性化音乐推荐系统原型。




一个深度模型：一个在KKBox等公开数据集上训练达标的 **DeepFM** 深度学习模型。



一份研究报告：一篇详细阐述系统设计、算法原理、实验过程与结果分析的毕业论文。

量化评估指标 (Quantitative Evaluation Metrics)

将通过 **AUC** (Area Under Curve) 和 **LogLoss** (Logarithmic Loss) 等业界标准指标，对推荐模型的排序性能进行严格的离线评估与验证。



详细工作进度规划

Week 1-4

第一阶段：数据治理与特征工程


任务：KKBox数据集清洗与预处理；设计并建立MySQL与Spark特征库。



Week 5-9

第二阶段：算法引擎开发与链路打通

任务：构建ALS召回与DeepFM排序模型；实现数据从MySQL到Spark再返回MySQL的自动化链路。



Week 10-13

第三阶段：Web业务模块集成


任务：开发前端播放器、搜索功能；集成后端推荐逻辑，实现个性化内容展示。



Week 14-16

第四阶段：系统测试与模型调优

任务：针对16GB内存环境进行压力测试；根据评估指标对模型超参数进行调优；撰写论文。



总结：不止于推荐，更是对用户音乐品味的深度理解

本项目旨在构建一个技术上先进、架构上合理的大数据推荐系统。

但其最终目标，是通过数据与算法，探索如何更精准地捕捉、理解并服务于每一位用户独特且动态变化的音乐品味。

这不仅是预测下一次点击，更是创造下一次**“心动”**的发现。