

AIGC检测结果报告单

基本信息

报告编号: AG2026040546915956E3436FA0

检测文献: 基于大数据技术的个性化音乐推荐系统的设计与实现 (V5)
文档作者: 卢伟军

字符数: 46535
检测时间: 2026-04-05 12:44:13

检测结论



疑似AIGC全文占比
71.31%



重度疑似占比
71.31%



轻度疑似占比
12.32%

疑似AIGC片段分布



结果分布

序号	片段	疑似AIGC概率	疑似程度
1	疑似AIGC片段1	64.46%	■
2	疑似AIGC片段2	80.02%	■
3	疑似AIGC片段3	99.25%	■
4	疑似AIGC片段4	76.22%	■
5	疑似AIGC片段5	79.44%	■
6	疑似AIGC片段6	99.31%	■
7	疑似AIGC片段7	99.46%	■
8	疑似AIGC片段8	99.99%	■
9	疑似AIGC片段9	99.64%	■
10	疑似AIGC片段10	97.1%	■
11	疑似AIGC片段11	98%	■
12	疑似AIGC片段12	99.41%	■
13	疑似AIGC片段13	82.57%	■
14	疑似AIGC片段14	98.48%	■
15	疑似AIGC片段15	79.95%	■
16	疑似AIGC片段16	98.95%	■
17	疑似AIGC片段17	96.15%	■
18	疑似AIGC片段18	98.14%	■
19	疑似AIGC片段19	98.12%	■
20	疑似AIGC片段20	97.36%	■
21	疑似AIGC片段21	98.51%	■
22	疑似AIGC片段22	98.38%	■
23	疑似AIGC片段23	73.82%	■
24	疑似AIGC片段24	97.04%	■

序号	片段	疑似AIGC概率	疑似程度
25	疑似AIGC片段25	98.69%	
26	疑似AIGC片段26	98.39%	
27	疑似AIGC片段27	97.24%	
28	疑似AIGC片段28	96.97%	
29	疑似AIGC片段29	77.61%	
30	疑似AIGC片段30	94.87%	
31	疑似AIGC片段31	97.4%	
32	疑似AIGC片段32	99.28%	
33	疑似AIGC片段33	95.31%	
34	疑似AIGC片段34	98.16%	
35	疑似AIGC片段35	97.5%	
36	疑似AIGC片段36	95.49%	
37	疑似AIGC片段37	97.97%	
38	疑似AIGC片段38	99.99%	
39	疑似AIGC片段39	79.24%	
40	疑似AIGC片段40	99.99%	
41	疑似AIGC片段41	99.01%	
42	疑似AIGC片段42	97.62%	
43	疑似AIGC片段43	81.94%	
44	疑似AIGC片段44	77.69%	
45	疑似AIGC片段45	75.78%	
46	疑似AIGC片段46	96.56%	
47	疑似AIGC片段47	96.71%	
48	疑似AIGC片段48	96.82%	
49	疑似AIGC片段49	76.9%	
50	疑似AIGC片段50	76.62%	
51	疑似AIGC片段51	98.69%	
52	疑似AIGC片段52	88.67%	
53	疑似AIGC片段53	97.76%	
54	疑似AIGC片段54	96.9%	
55	疑似AIGC片段55	97.54%	
56	疑似AIGC片段56	98.38%	
57	疑似AIGC片段57	97.35%	
58	疑似AIGC片段58	98.7%	
59	疑似AIGC片段59	98.48%	
60	疑似AIGC片段60	98.06%	
61	疑似AIGC片段61	98.77%	
62	疑似AIGC片段62	98.11%	
63	疑似AIGC片段63	98.75%	
64	疑似AIGC片段64	98.3%	
65	疑似AIGC片段65	97.35%	
66	疑似AIGC片段66	97.23%	
67	疑似AIGC片段67	96.35%	
68	疑似AIGC片段68	97.13%	
69	疑似AIGC片段69	96.94%	
70	疑似AIGC片段70	96.71%	
71	疑似AIGC片段71	98.43%	
72	疑似AIGC片段72	78.03%	

序号	片段	疑似AIGC概率	疑似程度
73	疑似AIGC片段73	97.09%	
74	疑似AIGC片段74	97.15%	
75	疑似AIGC片段75	98.26%	
76	疑似AIGC片段76	78.69%	
77	疑似AIGC片段77	98.21%	
78	疑似AIGC片段78	99.11%	
79	疑似AIGC片段79	76.96%	
80	疑似AIGC片段80	90.93%	
81	疑似AIGC片段81	95.28%	
82	疑似AIGC片段82	96.77%	
83	疑似AIGC片段83	95.75%	
84	疑似AIGC片段84	85.28%	
85	疑似AIGC片段85	65.59%	
86	疑似AIGC片段86	99.98%	
87	疑似AIGC片段87	97.88%	
88	疑似AIGC片段88	96.07%	
89	疑似AIGC片段89	97.51%	
90	疑似AIGC片段90	98.35%	
91	疑似AIGC片段91	96.47%	
92	疑似AIGC片段92	95.18%	
93	疑似AIGC片段93	96.67%	
94	疑似AIGC片段94	97.57%	
95	疑似AIGC片段95	97.97%	
96	疑似AIGC片段96	98.73%	
97	疑似AIGC片段97	98.59%	
98	疑似AIGC片段98	94.43%	
99	疑似AIGC片段99	99.34%	
100	疑似AIGC片段100	98.48%	
101	疑似AIGC片段101	93.24%	
102	疑似AIGC片段102	99%	
103	疑似AIGC片段103	98.98%	
104	疑似AIGC片段104	93.32%	
105	疑似AIGC片段105	95.41%	
106	疑似AIGC片段106	97.75%	
107	疑似AIGC片段107	97.54%	
108	疑似AIGC片段108	78.05%	
109	疑似AIGC片段109	98.94%	
110	疑似AIGC片段110	98.6%	
111	疑似AIGC片段111	97.81%	
112	疑似AIGC片段112	68.15%	
113	疑似AIGC片段113	77.87%	
114	疑似AIGC片段114	98.18%	
115	疑似AIGC片段115	99.99%	
116	疑似AIGC片段116	76.79%	
117	疑似AIGC片段117	99.97%	
118	疑似AIGC片段118	78.12%	
119	疑似AIGC片段119	94.72%	

序号	片段	疑似AIGC概率	疑似程度
120	疑似AIGC片段120	95.1%	
121	疑似AIGC片段121	58.11%	
122	疑似AIGC片段122	99.35%	
123	疑似AIGC片段123	98%	
124	疑似AIGC片段124	94.43%	
125	疑似AIGC片段125	99.91%	
126	疑似AIGC片段126	99.96%	
127	疑似AIGC片段127	99.96%	
128	疑似AIGC片段128	97.75%	
129	疑似AIGC片段129	92.77%	
130	疑似AIGC片段130	98.43%	
131	疑似AIGC片段131	97.73%	
132	疑似AIGC片段132	98.6%	
133	疑似AIGC片段133	97.8%	
134	疑似AIGC片段134	98.1%	
135	疑似AIGC片段135	98.31%	
136	疑似AIGC片段136	83.91%	
137	疑似AIGC片段137	33.3%	

原文内容

■ 重度疑似■ 轻度疑似（不计入AIGC结果统计）■ 不予标识部分

广州华立学院

本科生毕业论文（设计）

题目：基于大数据技术的个性化音乐推荐系统设计与实现

学院 计算机工程学院

专业 数据科学与大数据技术

班级 Z1大数据

学号 5124440106796

姓名 卢伟军

指导教师 王波

2026年4月

原创性声明

本人郑重声明：在广州华立学院攻读学士学位期间，所提交的毕业论文（设计）《基于大数据技术的个性化音乐推荐系统设计与实现》，是本人在导师指导下独立进行研究工作所取得的成果。对本文的研究工作做出重要贡献的个人和集体，均已在文中以明确方式注明，其它未注明部分不包含他人已发表或撰写过的研究成果，不存在购买、由他人代写、剽窃和伪造数据等作假行为。

本人愿为此声明承担法律责任。

作者签名：日期：2026年4月20日

摘要

随着数字音乐流媒体平台的用户规模与曲库容量持续扩张，用户面临的信息过载问题日趋突出。如何从海量候选曲目中精准匹配用户潜在偏好，已成为个性化音乐服务面临的核心技术挑战。音乐消费行为的隐性性、用户兴趣的动态漂移以及长尾曲目的交互稀疏，进一步加大了推荐任务的建模难度。

针对上述问题，本文基于KKBOX公开音乐数据集，设计并实现了一套由前端交互平台MusicWeb与推荐引擎MusicMode构成的个性化音乐推荐系统，探索大数据处理技术与多模型协同精排在音乐推荐场景中的工程集成方案。

系统在特征工程阶段构建了融合用户行为统计、歌曲属性与协同过滤嵌入的多维特征管道，采用折外目标编码方案有效规避高基数类别特征在训练阶段的标签泄漏风险。推荐算法采用“多路召回—粗排—精排集成—重排”四层管道设计：多通道召回层并行生成约600首候选曲目；梯度提升树模型完成粗排筛选，将候选集压缩至300首；DeepFM与BST行为序列Transformer对Top-300候选进行深度特征建模，并经SLSQP约束优化实现双模型预测加权融合；重排阶段引入最大边际相关性算法，在推荐质量与列表多样性之间进行权衡，最终为每位用户输出50首推荐结果。

工程层面整合了外部音乐数据接口，并通过隐式反馈闭环机制支持推荐结果的持续迭代优化。

离线与在线双轨评估结果表明，所设计的四层推荐管道在排序精度与候选覆盖方面均达到较高水平，系统在有历史偏好与冷启动两类用户场景下均实现了基本可用的推荐效果。

关键词：大数据技术；个性化推荐；深度学习；集成学习；协同过滤；特征工程

Abstract

With the continuous expansion of user scale and music library capacity on digital music streaming platforms, the problem of information overload has become increasingly prominent.

Accurately matching users' potential preferences from massive candidate tracks has emerged as a core technical challenge for

personalized music services.

The implicit nature of music consumption behavior, the dynamic drift of user interests, and the interaction sparsity of long-tail tracks further complicate the recommendation modeling task.

Addressing these challenges, this thesis designs and implements a personalized music recommendation system based on the KKBOX public music dataset, comprising a front-end interaction platform (MusicWeb) and a recommendation engine (MusicMode), aiming to explore the engineering integration of big data

processing technologies and multi-model collaborative fine-ranking in music recommendation scenarios.

In the feature engineering stage, the system constructs a multi-dimensional feature pipeline integrating user behavior statistics, song attributes, and collaborative filtering embeddings.

An out-of-fold target encoding scheme is adopted to effectively prevent label leakage from high-cardinality categorical features during training.

The recommendation algorithm employs a four-layer pipeline of multi-channel recall, coarse ranking, fine-ranking ensemble, and reranking: the recall layer generates approximately 600 candidate tracks in parallel; a gradient boosting tree model compresses candidates to 300 tracks; DeepFM and Behavior

Sequence Transformer (BST) conduct deep feature modeling on the top-300 candidates, with their predictions fused through SLSQP-optimized weighted combination; the reranking stage applies the Maximal Marginal Relevance algorithm to balance recommendation quality and list diversity, ultimately outputting

50 recommendations per user. External music data interfaces are integrated at the engineering level, supported by an implicit feedback loop for continuous recommendation optimization.

Offline and online dual-track evaluation results demonstrate that the designed four-layer pipeline achieves satisfactory ranking accuracy and candidate coverage. The system delivers functionally effective recommendations for both users with rich historical preferences and cold-start users with limited interaction history.

Keywords: Big Data Technology, Personalized Recommendation, Deep Learning, Ensemble Learning, Collaborative Filtering, Feature Engineering

目 录

摘 要 II

Abstract III

1 绪 论 1

1.1 研究背景与意义 1

1.2 国内外研究现状 1

1.2.1 国内研究现状 1

1.2.2 国外研究现状 2

1.3 论文研究内容 4

1.4 论文组织结构 4

2 系统开发技术与算法选型 6

2.1 大数据技术 6

2.1.1 PySpark分布式计算框架 6

2.1.2 Redis缓存技术 6

2.2 协同过滤与向量检索技术 7

2.2.1 协同过滤与ALS矩阵分解 7

2.2.2 向量近邻检索技术 (FAISS) 8

2.3 梯度提升树与LightGBM原理 9

2.4 精排深度模型 10

2.4.1 DeepFM模型原理 10

2.4.2 BST行为序列Transformer原理 12

2.5 Stacking集成学习框架 14

2.6 Java Web核心技术栈 16

2.6.1 MVC架构与Servlet/JSP技术 16

2.7 本章小结 16

3 系统需求分析 18

3.1 系统总体目标 18

3.2 前端功能性需求分析 18

3.2.1 用户端功能需求 18

3.2.2 管理端功能需求 20

3.2.3 推荐引擎功能需求 21

3.3 后端功能性需求分析 22

3.3.1 性能需求 22

3.3.2 安全性需求 23

3.4 本章小结 24

4 系统设计 25

4.1 引言 25

4.2 系统总体架构设计 25

4.2.1 MusicWeb前端模块架构 26

4.2.2 MusicMode推荐引擎模块架构 27

4.2.3 双模块交互与部署设计 28

4.3 推荐算法流水线设计 28

4.3.1 召回层设计 29

4.3.2 粗排层与精排层设计 31

4.3.3 集成层设计 32

4.3.4 重排层设计 32

4.4 数据库设计 34

4.4.1 表的概念结构设计 34

4.4.2表各字段功能设计	34
4.5 前端交互设计	35
4.5.1 页面总体结构设计	35
4.5.2 核心功能页面设计	36
4.5.3 推荐交互与行为反馈设计	37
4.6 本章小结	38
5 系统实现	40
5.1 引言	40
5.2 开发环境与工具配置	40
5.3 数据处理与特征工程实现	42
5.3.1 数据来源与ETL处理	42
5.3.2 数据清洗	44
5.3.3 特征工程	45
5.3.4 数据集时序切分	49
5.4 MusicMode推荐算法实现	49
5.4.1 ALS协同过滤召回实现	49
5.4.2 FAISS向量检索召回实现	50
5.4.3 热度兜底召回实现	50
5.4.4 LightGBM粗排实现	50
5.4.5 DeepFM深度精排实现	51
5.4.6 BST行为序列Transformer精排实现	53
5.4.7 Stacking集成与重排输出的实现	54
5.5 MusicWeb前端实现	55
5.5.1 MVC分层架构搭建	55
5.5.2 用户认证与账户管理实现	55
5.5.3 个性化推荐展示	58
5.5.4 音乐搜索与播放收藏实现	59
5.5.5 歌单管理功能实现	60
5.5.6 管理员后台功能实现	61
5.5.7 隐式反馈采集实现	64
5.6 本章小结	64
6 系统测试与评估	66
6.1 引言	66
6.2 推荐效果评估	66
6.2.1 评估指标说明	66
6.2.2 不同模型AUC结果分析	68
6.2.3 离线推荐效果评估	69
6.2.4 在线推荐效果评估	70
结 论	73
参考文献	74
致 谢	76
附 录	78

2

1 绪 论

1.1 研究背景与意义

随着数字音乐流媒体平台的规模持续扩张,以Spotify、网易云音乐为代表的主流平台曲库容量普遍突破亿首量级,用户通过人工榜单或关键词搜索发现音乐的效率极为低下,信息过载问题日趋突出。个性化推荐系统通过对用户历史行为的系统性建模,将海量候选曲目压缩为符合潜在偏好的少量结果,已成为各平台维持用户活跃度的核心技术基础设施[1]。

音乐推荐在技术层面面临若干固有挑战:用户反馈以播放时长、跳曲等隐式行为为主,正负样本标注噪声较高;音乐消费具有显著的情境依赖性,静态偏好模型难以捕捉用户兴趣的动态漂移;长尾曲目的交互记录极度稀疏,协同过滤方法在冷启动场景下性能退化显著[2]。上述挑战要求推荐系统在算法设计与工程实现两个维度均进行系统性定制化处理。

本文将基于KKBOX公开数据集,设计并实现由MusicWeb与MusicMode构成的双模块个性化音乐推荐系统,探索大数据处理与多模型异构精排在在线音乐场景中的工程集成方案,研究成果可为中小型在线音乐平台的推荐系统建设提供工程参考。

1.2 国内外研究现状

1.2.1 国内研究现状

在工程化实践方向,赵吉[1]基于分布式计算框架构建了以矩阵分解协同过滤为核心的大规模音乐推荐系统,验证了分布式计算路径的工程可行性,但未引入深度学习精排层,对特征交叉信息的利用较为有限;杨率[2]将深度神经网络应用于个性化实时音乐推荐,探索了用户行为序列的动态偏好建模,然而其系统缺乏完整的前端交互平台,推荐结果的用户反馈闭环有待完善。上述两项工作初步论证了大数据技术在音乐推荐场景中的适用性,但均未形成召回、精排与重排的多层流水线,本文在此基础上引入多模型集成精排管道,以期在推荐精度与系统完整性上有所推进。

在语义增强与情感特征方向,李津[3]引入知识图谱丰富物品侧语义表示,对缓解稀疏场景下的冷启动问题有一定效果,但图卷积的计算复杂度较高,难以适配百万量级曲库的实时推理需求;冯亚寒[4]提出了融合小波散射变换与多尺度卷积网络的音乐多情感分类方法,在情感特征提取上具有一定新颖性,但该方法聚焦于内容侧标签预测,未与用户行为数据联合建模,难以直接用于个性化推荐;吴亚迪和陈平华[5]设计了融合用户长短期偏好与情感注意力的推荐模型,在个性化偏好建模方面有所改进,但两者均依赖显式情感标注,在以隐式行为反馈为主的大规模数据集上的适用性有待进一步验证。

在综述与前沿方法方向,王慧心和董向荣[6]梳理了融合知识图谱的推荐系统研究进展,指出语义增强对于缓解数据稀疏性具有较好效果,但计算开销制约了其在实时推荐中的落地;梁锋等[7]对基于联邦学习的推荐系统隐私保护机制进行了综述,为在不共享原始数据条件下的协同建模提供了参考思路;郑楠等[8]对基于深度学习的群组推荐方法进行了分类比较,总结了不同群体偏好聚合策略的适用边界;闫猛猛等[9]提出了基于自监督学习的序列推荐算法,在减少人工标注数据依赖方面具有一定借鉴价值;龚雪鸾等[10]对点击率预测方法进行了系统综述,梳理了从浅层模型到深度模型的演进路径,为本文精排层的模型选型提供了参考依据。上述综述类研究揭示了现有方法在计算效率、隐式反馈利用及多阶特征交叉等方面的共性不足,本文在精排层采用DeepFM与BST的组合,正是对这一不足的针对性回应。

综合来看,现有国内研究在单一模型创新方面已有较多积累,但针对多模型集成精排管道的完整工程实现、前端交互平台与大数据推荐引擎的异构集成,以及特征工程阶段标签泄露的系统性防控,仍缺乏系统性的公开论述,本文将就上述方面展开针对性研究与实践。

1.2.2 国外研究现状

在音乐推荐专项研究方向, Liu等[11]提出情感驱动个性化音乐推荐框架, 通过对歌词与音频的情感分析构建用户情绪—偏好映射; Wan等[12]设计了多视图增强图注意力网络用于基于会话的音乐推荐, 在多个公开数据集上取得了较好表现; Li等[13]提出注意力自编码器用于内容感知型推荐, 在交互稀疏场景下的性能优于纯协同过滤基线; Mao等[14]提出轻量化音乐分类推荐网络, 探索了分类任务与推荐任务联合建模的可行性; Paul等[15]对协同过滤、内容过滤与混合推荐三类范式进行了冷启动与稀疏场景下的适用边界比较; Tran等[19]将Transformer架构与认知科学中的记忆激活理论相结合,

专门针对音乐收听场景中频繁出现的重复播放行为进行建模, 为序列化音乐推荐中的用户行为分析提供了新的研究视角。上述研究在情感特征、内容建模与序列行为分析方面各有贡献, 但多数工作聚焦于单一模型的改进, 对多模型协同精排管道的完整工程集成探索相对不足。

在深度精排与行为序列建模方向, Chen等[20]将Transformer架构引入推荐系统精排层, 提出行为序列BST, 通过多头自注意力机制对用户历史行为序列中的时序依赖关系进行建模, 相较于注意力池化类方法在点击率预测任务上展现出一定的性能优势。该工作表明Transformer在用户行为序列建模中具有较大潜力, 为本文将行为序列Transformer引入音乐精排场景提供了重要的方法论参考。

在大规模工程方向, Niu等[16]基于分布式计算框架实现了大规模协同过滤音乐推荐, 验证了分区策略对矩阵分解训练效率的提升作用; Johnson等[17]提出的高性能向量近邻检索库已广泛应用于工业界推荐系统的召回层; Wang等[18]通过神经因果图协同过滤对交互数据中的混淆因素进行显式建模, 对缓解观察偏差对推荐结果的影响具有一定参考价值。上述工程方向的研究多聚焦于单一技术组件的优化, 对多组件端到端集成方案的系统性论述相对有限。

综合来看, 现有国内外研究在单模型创新与特定场景优化方面已有较多积累, 但针对多模型异构精排管道的完整工程实现、前端平台与大数据推荐引擎的异构集成以及特征工程中标签泄漏的系统性防控, 仍缺乏全面的公开论述, 本文将围绕上述方面展开研究与实践。

1.3 论文研究内容

本文将重点解决以下四个核心问题:

(1) 大规模音乐数据的高效治理与无泄漏特征工程

将基于KKBOX数据集构建全量ETL导入与特征工程管道, 采用OOF (Out-of-Fold, 折外预测) 目标编码方案系统性消除训练集与验证集之间的标签泄漏风险, 为粗排层与精排层各模型分别构建独立的多维特征集供模型训练使用。

(2) 四层推荐管道构建与双模型Stacking集成

将LightGBM、DeepFM与BST三个模型纳入统一的四层推荐管道 (召回→粗排→精排→重排), 其中LightGBM担任粗排将候选集从约600压缩至300, DeepFM与BST在精排集成层对Top-300进行深度建模, 通过SLSQP约束优化求解DeepFM与BST两个精排模型的最优融合权重, 经多样性重排策略后输出Top-50最终推荐列表。

(3) MusicWeb音乐平台全功能工程实现

基于Java Web技术栈构建MVC分层架构的在线音乐平台, 覆盖用户注册登录、个人信息管理、个性化推荐展示、音乐搜索、在线播放与收藏、歌单管理及管理员后台五大模块; 通过节流机制异步采集用户播放行为, 经C3P0连接池高并发持久化写入, 构建推荐反馈闭环。

(4) 离线与在线双轨推荐效果评估体系

离线评估基于KKBOX数据集用户级时序切分, 以HR@10、Precision@10、NDCG@10、MRR衡量Top-10推荐质量; 在线评估基于系统实际部署后2位真实用户共377条推荐记录, 对比有历史偏好用户与冷启动用户的推荐效果差异, 验证系统在不同场景下的实用性。

1.4 论文组织结构

本文共分为六章, 另附有附录, 结构安排如下。第1章梳理个性化音乐推荐领域的研究背景与国内外研究现状, 并明确本文的研究内容与技术路线。第2章介绍系统所涉及的大数据处理框架、推荐系统基础理论、深度学习推荐模型及向量检索与Web开发的核心技术原理。第3章从功能性与非功能性两个维度对系统的设计目标进行需求分析。第4章阐述双模块总体架构、四层推荐算法流水线的设计方案及数据库逻辑结构。第5章描述数据预处理、特征工程、各推荐算法模块及前端功能的具体实现过程。第6章采用离线与在线双轨评估体系, 对系统整体推荐效果进行实验分析与评估。

2 系统开发技术与算法选型

2.1 大数据技术

2.1.1 PySpark分布式计算框架

Apache Spark是面向大规模数据处理的内存计算框架, 通过将中间状态存于内存, 在需反复迭代的机器学习场景中较传统磁盘批处理实现了数量级的性能提升。作为其Python接口, PySpark允许开发者通过简洁API调用分布式读写、查询与机器学习等完整功能。Spark的核心抽象RDD具备三大特性: 惰性求值 (支持全局链路优化)、血统容错 (记录转换路径以便在故障时自动重建分区) 和分区并行 (根据硬件灵活配置并行度)。在此基础上, 其结构化数据层进一步优化了列式存储与查询, 在处理大规模特征矩阵时吞吐优势显著。

在本系统中, PySpark以本地多核模式承担两项核心任务: 其一, 对KKBOX公开数据集的全量原始交互记录执行完整的数据清洗与特征工程构建; 其二, 通过其内置的协同过滤算法 (ALS) 在分布式环境下完成用户与歌曲潜在因子向量的离线训练, 所得嵌入向量直接输送至召回层的协同过滤通道与向量检索通道使用。PySpark将分布式计算能力以标准化编程接口的形式对外提供, 使大规模特征工程与召回模型训练得以高效完成, 是MusicMode推荐引擎的核心计算基础设施。

2.1.2 Redis缓存技术

Redis是一款基于内存的键值型数据库, 能够以亚毫秒级的读写延迟响应高并发请求, 并通过内置的键过期机制自动淘汰超时数据, 是在线服务中实现缓存加速的主流选型之一。此外Redis以内存作为主存储介质, 采用单线程事件驱动模型处理并发请求, 该设计彻底规避了多线程竞争加锁的额外开销, 使其在高并发场景下能够稳定维持极高的吞吐能力。

在本系统的前端服务模块中, 在线推荐服务对响应时延高度敏感——推荐列表展示、收藏状态查询、偏好屏蔽过滤等操作均属高频只读场景, 并发访问量巨大且对延迟容忍度极低。若上述请求直接落至关系型数据库, 读取压力将在高并发时段迅速累积, 成为在线服务的性能瓶颈。Redis亚毫秒级的内存读写延迟、对多种数据结构的原生支持以及键过期自动淘汰特性, 恰好满足上述高频只读场景对低延迟与数据形态多样性的双重需求, 是将高频查询从关系型数据库卸载至内存缓存层、保障在线服务低延迟体验的最优选型。

2.2 协同过滤与向量检索技术

2.2.1 协同过滤与ALS矩阵分解

协同过滤 (CF) 是基于行为相似性假设的经典推荐算法, 分为基于用户 (User-based) 和基于物品 (Item-based) 两类。前者利用用户相似度发现邻居, 后者通过物品相似度推荐关联项; 在物品规模较小时, Item-based CF 具有更好的工程稳定性和成本优势。然而, 该算法受限于数据稀疏性与可扩展性: 超过 99% 的矩阵稀疏率会导致推荐精度显著下降, 且相似度矩阵的计算存储开销随规模呈平方级增长, 难以支撑百万级以上的大数据工业场景需求。

矩阵分解方法将高维稀疏交互矩阵R近似分解为用户潜在因子矩阵U与物品潜在因子矩阵V的乘积 (即 $R \approx UV^T$), 将每个用户和物品映射为低维稠密向量, 有效规避了稀疏性与平方级计算开销的双重瓶颈。用户u对物品i的预测偏好得分由两者潜在因子向量的内积给出, 见式 (2-1) 所示:

式中 ——用户u的k维潜在因子向量的转置 (行向量);

——物品i的k维潜在因子向量; 内积值越大表明用户对该物品的潜在兴趣越强。

——用户u对物品i的预测偏好得分;

针对音乐推荐中用户行为数据 (播放次数、播放时长等) 仅能反映正向兴趣信号、缺乏明确负样本的隐式反馈特点, ALS引入置信度加权机制: 对有交互记录的样本依据交互计数赋予更高置信权重, 同时保留无交互样本的建模贡献, 避免将无交互一律视为负样本所带来的信号偏差。其加权优化目标函数如式 (2-2) 所示:

式中 ——二值化偏好指示变量, 有交互记录时取1, 否则取0;

——置信度权重, 随原始交互计数增大而增大;

λ ——L2正则化系数, 用于抑制模型过拟合。

ALS算法通过交替固定两组因子矩阵分别求解另一组的方式, 将非凸优化问题转化为若干凸子问题, 每次迭代均存在解析解, 天然支持大规模分布式并

行计算。

本系统召回层面对229万首候选歌曲与7.37M条训练样本，需从大规模隐式反馈数据中高效提取用户与歌曲的潜在语义关联。ALS矩阵分解凭借对隐式反馈的原生支持、置信度加权对播放计数信号的充分利用，以及天然支持分布式并行的交替迭代求解机制，能够在分布式计算环境下高效完成全量因子矩阵的离线训练，所得用户与歌曲嵌入向量直接用于协同过滤召回与后续向量检索，是本系统召回层的核心选型。

2.2.2 向量近邻检索技术（FAISS）

向量近邻检索（Approximate Nearest Neighbor, ANN）是大规模推荐系统召回层的核心工程手段。FAISS（Facebook AI Similarity Search）是由Meta开源的高性能向量检索库，广泛应用于工业级推荐系统召回层建设。其核心的IVFPQ两级索引结构兼顾检索效率与内存占用：粗量化阶段（IVF）预先将全部物品嵌入向量聚类为若干簇，查询时仅在与用户兴趣向量最近的若干簇内搜索，将候选范围从全库大幅压缩；精量化阶段（PQ）对向量进行子空间分段编码，以极低的内存代价存储全库向量的近似表示，在内存占用与检索精度之间取得工程平衡。

本系统需在229万首候选歌曲、160维嵌入向量的规模上执行用户兴趣召回，若对全库逐一执行相似度计算，单次查询需完成数百万次向量运算，时延远不满足在线推荐的实时性要求。FAISS的IVFPQ索引能够在可接受的精度损失前提下将查询时延压缩至毫秒级，其高效的压缩索引结构也使全量歌曲向量库能够以极低内存代价持久化存储，是本系统向量召回通道的最优选型。

2.3 梯度提升树与LightGBM原理

梯度提升树（Gradient Boosting Decision Tree, GBDT）是一种以决策树为弱学习器的迭代集成方法，其核心理念是逐步逼近：每一轮训练的目标并非直接预测真实标签，而是专门拟合当前集成模型在所有样本上的预测残差（负梯度方向），逐步将整体误差压缩至最小。设经过第T轮迭代后集成模型的预测值为 $FT(x)$ ，其加法更新规则如式（2-3）所示：

式中 $FT_{-1}(x)$ ——前T-1轮集成模型的预测值；

$hT(x)$ ——第T轮新增的决策树弱学习器；

η ——学习率，控制每棵树对最终预测结果的贡献步长，取值越小模型泛化能力越强。

LightGBM是微软开源的高效GBDT实现框架，针对大规模高维特征场景引入了三项关键工程优化：直方图算法将连续特征离散化为K个区间，节点分裂时仅需遍历K个候选切分点而非全部样本值，将单次分裂时间复杂度从 $O(n)$ 降至 $O(K)$ ；基于梯度的单边采样（GOSS）优先保留大梯度样本以减少计算量；互斥特征捆绑（EFB）将互斥稀疏特征合并，进一步降低特征维度，LightGBM的算法原理如图2-1所示。

图21 LightGBM算法原理示意图

LightGBM以分裂增益作为节点划分的评判标准，各候选切分点的增益计算如式（2-4）所示：

式中 GL 、 GR ——分别为左、右子节点所有样本的一阶梯度之和；

HL 、 HR ——分别为左、右子节点所有样本的二阶梯度之和；

λ ——叶节点权重的L2正则化系数，惩罚过大的叶节点输出值；

γ ——引入新叶节点的最小收益阈值，增益低于该值时分裂被剪枝，起结构正则化作用。

LightGBM采用基于叶子的生长策略（Leaf-wise），每轮优先分裂当前增益较大的叶节点而非逐层全量扩展，在相同叶节点数量约束下可获得更低的训练损失。

本系统粗排阶段需对召回层筛选出的约600首候选歌曲进行快速打分并压缩至300首，特征集涵盖59维用户-歌曲混合特征，包含稀疏类别特征与稠密数值特征两类。LightGBM对高维稀疏特征具有较好的适应性，直方图算法显著降低了大规模样本下的节点分裂开销，叶节点增益剪枝机制也为模型提供了有效的结构正则化能力。综合考虑粗排阶段对计算效率与预测精度的双重需求，选用LightGBM承担本系统的粗排打分任务。

2.4 精排深度模型

2.4.1 DeepFM模型原理

DeepFM通过共享Embedding层将传统因子分解机（Factorization Machine, FM）与深度神经网络（DNN）整合于同一端到端框架中联合训练，无需人工特征工程即可同时捕获低阶与高阶特征交互，其模型结构示意图如图2-2所示。DeepFM由FM组件与Deep组件并联构成，两部分共享同一Embedding层输出，分别承担不同阶次的特征交叉建模任务。

图2-2 DeepFM模型结构示意图

DeepFM由FM组件与Deep组件并联构成，两部分共享同一Embedding层输出，分别承担不同阶次的特征交叉建模任务。

（1）FM组件：

FM组件负责捕捉一阶线性关系与二阶特征交叉。对于含n个特征域的输入，FM组件的输出如式（2-5）所示：

式中 w_0 ——全局偏置项；

w_i ——第i个特征的一阶线性权重；

v_i ——第i个特征对应的K维Embedding隐向量；

x_i 、 x_j ——第i、j个特征的输入值。

上式通过等价变换将二阶特征交叉的计算复杂度从 $O(n^2)$ 降至 $O(nK)$ ，同时以隐向量内积 (v_i, v_j) 衡量特征i与特征j的交叉强度，即使对于训练集中未曾共现的特征对，也能通过隐向量泛化估计其交叉权重。

（2）Deep组件

Deep组件为多层全连接神经网络，以各特征域Embedding向量的拼接结果作为输入，通过逐层非线性变换挖掘高阶特征交叉关系，第l层的前向传播规则如式（2-6）所示：

式中 $a^{(l)}$ ——第l层神经元输出向量；

$W^{(l)}$ ——第l层权重矩阵；

$b^{(l)}$ ——第l层偏置向量；

σ ——激活函数（本系统采用ReLU）。

（3）联合预测输出

DeepFM将FM组件与Deep组件的输出相加后，经Sigmoid函数映射至 $[0,1]$ 区间，作为用户对候选歌曲的点击概率预测值，见式（2-7）。

式中 $\hat{y}$ ——用户对候选歌曲的点击概率预测值；

y_{FM} ——FM组件的输出值；

y_{Deep} ——Deep组件的输出值；

$\sigma(\cdot)$ ——Sigmoid激活函数，将两组件输出之和压缩至 $(0,1)$ 区间，使结果可解释为点击概率。

由于FM与Deep两组件共享同一Embedding层，反向传播时联合更新参数，有效避免了分阶段训练带来的次优解问题。

精排阶段候选歌曲的特征体系涵盖用户画像、歌曲属性及用户-歌曲交叉特征多个维度，既包含低阶线性关系，也存在深层非线性交互。DeepFM通过共享Embedding层将低阶交叉与高阶交叉纳入统一框架，端到端联合训练使两类特征交叉的学习能够相互增益，在特征交叉建模方面具有较好的适应性，因此选用DeepFM作为本系统精排阶段的候选歌曲打分模型之一。

2.4.2 BST行为序列Transformer原理

传统深度推荐模型在提取用户兴趣表征时，通常对历史行为序列中所有交互物品的Embedding向量直接求平均，忽视了行为序列的时序依赖与上下文语义。行为序列Transformer（Behavior Sequence Transformer, BST）将Transformer的自注意力机制引入行为序列建模，通过位置感知的多头自注意力层在全序列范围内对历史行为物品的相互依赖关系进行联合建模，使模型能够同时感知序列的局部兴趣模式与全局上下文语义。BST的整体结构如图2-3所示，对于含N条历史行为记录的用户，将各物品的Embedding向量与位置编码相加，得到每个位置的序列输入表示，再经Transformer层为每一位置生成融合全局上下文的输出表示。

图23 BST模型结构示意图

以单头自注意力为例，其计算如式（2-8）所示：

式中 Q ——由序列输入经线性投影得到的查询矩阵；

K ——键矩阵；

V ——值矩阵；

dk ——键向量维度，用作缩放因子以防止内积值过大导致梯度消失。

多头自注意力在 h 个不同子空间并行执行上述运算后拼接输出，再经前馈网络与残差连接进行处理，如式（2-9）所示：

式中 $head_j$ ——第 j 个注意力头的输出，由 $head_j = \text{Attention}(QW_jQ, KW_jK, VW_jV)$ 计算得到；

WO ——输出投影矩阵；

h ——注意力头数。

在本系统中，用户的音乐偏好往往随收听序列的演变而动态变化，近期播放行为对当前兴趣的反映强于久远记录，行为间的顺序关系也携带着兴趣迁移的语义信息。BST通过位置编码感知行为的时序位置，通过多头自注意力捕捉序列内部的依赖关系，能够从用户历史播放序列中提取比均值池化更为精细的动态兴趣表征，较好地满足精排阶段对序列感知能力的需求，因此选用BST作为本系统精排阶段的序列建模组件。

2.5 Stacking集成学习框架

集成学习的核心思想是通过有机组合多个异质基学习器，利用模型间的差异性提升整体预测性能，使其泛化能力超越任意单一模型。从统计学视角看，单一模型在处理复杂的大规模数据时，往往难以在偏差与方差之间取得最优平衡，而异质模型的组合能够实现误差补偿，从而降低系统性风险。本系统在精排阶段采用 Stacking 两阶段训练框架，如图2-4所示。

本系统在精排阶段以DeepFM与BST作为两个基学习器，两者在归纳偏置上存在显著互补性。DeepFM通过FM与DNN并联，同时建模低阶显式特征交互与高阶隐式特征交互，而BST通过Transformer结构对用户历史行为序列进行时序建模，捕捉行为间的依赖关系。两者的误差来源不同，构成集成多样性的基础。

图24 Stacking两阶段训练框架示意图

本系统采用SLSQP（Sequential Least Squares Programming）约束优化方法，在验证集上搜索使集成AUC最大的融合权重，最终预测见式（2-12）：

式中 $\hat{p}(\text{DFM})$ 、 $\hat{p}(\text{BST})$ ——DeepFM与BST在验证集上的预测概率；

w_1 、 w_2 ——SLSQP求解所得的融合权重，满足 $w_1 + w_2 = 1$ ，且 w_1 、 $w_2 \geq 0.20$ ，权重下界约束用于防止集成退化为单一模型。

同时将SLSQP方案与等权平均（0.5/0.5）基线进行对比，取验证集AUC更高者作为最终权重配置，以保障集成结果的稳健性。

在特征工程层面，本系统采用折外（Out-of-Fold，OOF）目标编码防范标签泄漏。若直接使用全量数据计算点击率均值，会导致样本自身的标签信息渗入特征，引发模型离线评估指标虚高。OOF编码通过K折交叉验证的思想，确保样本 i 的特征编码仅依据其余 $K-1$ 折的数据统计得出，见式（2-13）：

式中 c_i ——样本 i 的类别特征 c 的编码值（即该类别的点击率估计）；

$1[c_i = c_j]$ ——指示函数：样本 j 与样本 i 属于同一类别时为1，否则为0；

S_k ——样本 k 所在的第 k 折验证集；

y_i ——样本 i 的真实标签；

$\bar{y}$ ——全局标签均值；

α ——平滑系数。

选用该方案基于以下考量：一是归纳偏置互补，DeepFM与BST分别侧重特征交互与时序建模，异构集成可获显著增益。二是引入SLSQP约束优化自适应分配权重，下界约束防止集成退化，策略对比保障了结论稳健性。三是应用OOF目标编码实现训练与验证的信息隔离，有效防范标签泄漏，确保离线评估结论的科学性。综上，该集成框架通过视角互补与权重优化，兼顾了预估精度与鲁棒性。

2.6 Java Web核心技术栈

2.6.1 MVC架构与Servlet/JSP技术

MVC（模型-视图-控制器）架构模式通过职责分离将应用程序划分为三个协作层次：模型层封装业务规则与数据访问逻辑，视图层负责数据的界面呈现，控制器层承担请求路由与流程调度。本系统基于Jakarta EE规范，以Servlet作为控制器层核心组件，负责接收HTTP请求、解析参数并调度业务逻辑；JSP作为视图层模板引擎，负责将服务端数据渲染为页面响应。

本系统Servlet层按业务职能划分为用户认证、推荐获取、音乐检索与行为上报等功能域；DAO层对核心数据表的读写进行统一封装，实现业务逻辑与存储细节的解耦。数据库连接通过C3P0连接池统一管理，请求复用已有连接、用后归还，降低连接创建开销；Redis缓存层通过Jedis连接池管理，并内置优雅降级机制，Redis不可用时自动回退至数据库查询。

选用上述技术方案的主要考量如下：其一，Jakarta EE Servlet规范成熟稳定，与Tomcat容器配合部署简便；其二，MVC层间职责分离使控制器、数据访问与视图各自独立演进，功能迭代时能较好地控制改动范围；其三，C3P0连接池将连接创建开销集中于启动阶段，在多用户并发场景下可有效降低单次数据访问的响应延迟。

2.7 本章小结

本章围绕个性化音乐推荐系统的核心技术原理展开论述，从基础设施到算法模型依次构建完整的技术体系。在大数据基础设施层面，介绍了PySpark分布式计算框架在大规模特征工程与模型训练中的应用，以及Redis内存缓存存在高并发在线服务中的缓存加速机制。

在召回层，梳理了ALS隐式反馈矩阵分解算法的置信度加权机制，以及FAISS的IVFPQ两级索引结构在百万级候选歌曲毫秒级召回中的工程价值。在分层排序模型层面，LightGBM以直方图优化承担粗排压缩候选集；DeepFM通过共享嵌入层联合建模低阶与高阶特征交互；BST借助自注意力机制对用户行为序列进行时序建模；三者基础上，Stacking集成框架以DeepFM与BST为基学习器，通过SLSQP约束优化搜索融合权重，结合OOF目标编码防范标签泄漏。

在前端工程层面，简述了基于MVC模式的Java Web分层架构与C3P0连接池的高并发保障机制。上述技术模块依次对应“分布式建模—向量召回—精排融合—在线响应”的完整推荐链路，为后续系统设计与工程实现奠定理论基础。

3 系统需求分析

3.1 系统总体目标

本系统的设计目标是构建一套面向在线音乐场景的双模块个性化推荐平台，由MusicWeb用户交互模块与MusicMode推荐引擎模块协同构成。系统需在完整支持音乐播放、收藏、搜索等基础业务功能的同时，实现基于大数据技术的用户兴趣建模与个性化内容推送，并通过隐式反馈采集形成推荐优化的持续数据闭环。

从功能层面看，系统须为普通用户提供注册登录、音乐检索与播放、收藏与歌单管理、个性化推荐展示及账号自助管理等完整使用路径。对管理员则提供用户账号管理、歌曲资源管理、申诉审核与数据统计等后台运营能力。从而为推荐引擎提供多路候选召回、多模型精排融合与定时推荐更新等算法执行能力，三者之间通过共享的MySQL数据库实现数据流转与状态同步。

从性能与可用性层面看，系统在正常并发负载下须保证用户界面的交互响应延迟维持在可接受范围内。推荐引擎须在合理时间窗口内完成全量用户的每日推荐重算，向量检索须满足在线服务的响应时延要求。同时，系统须具备基本的异常容错与服务降级能力，推荐服务在部分模型异常时须能回退至基础召回策略，保证推荐列表的最低可用性。

综上，本系统的总体目标可归纳为：以大数据技术为基础设施，以多模型集成精排管道为算法核心，以Java Web平台为用户交互载体，构建一套具备功能完整性、性能可达性与工程可维护性的个性化音乐推荐系统。

3.2 前端功能性需求分析

3.2.1 用户端功能需求

用户端面向普通注册用户，提供音乐消费的完整交互闭环。其整体功能如图31所示，其中用户端的核心用例覆盖以下六个功能域。

(1) 账号管理

系统须支持新用户完成账号注册，注册信息包括用户名、密码、邮箱、手机号等基本资料；注册成功后，用户通过身份验证登录系统，系统维护用户的登录会话状态。用户在登录期间可访问个人中心，对昵称、邮箱、手机号等资料进行修改，并支持密码变更与账号注销操作。针对账号因违规被冻结的情形，系统须提供申诉入口，用户可填写申诉原因与联系邮箱提交申诉请求，管理员审核通过后须恢复账号状态并通知用户。

(2) 音乐检索与浏览

系统须提供全文检索功能，支持用户按歌曲名称、艺术家、专辑、流派等多维度关键词进行组合搜索，并自动保存最近的搜索历史以便快速重复检索。在内容浏览层面，系统须提供热歌榜、新歌榜与收藏榜三类排行榜，按不同热度维度聚合展示全库曲目。

(3) 音乐播放

系统须支持用户对目标曲目发起在线流媒体播放，播放器须具备进度拖拽、音量调节等基础交互控制能力。系统须支持多平台音源接入，通过统一的音频链接解接口屏蔽底层平台差异，扩展可播放曲目范围。系统须实时采集用户的播放时长数据，作为隐式反馈信号上报至服务端以供推荐引擎使用。

(4) 收藏与歌单管理

系统须支持用户对单曲执行收藏与取消收藏操作，并在页面上实时反映收藏状态。除单曲收藏外，系统须提供用户自定义歌单功能，允许用户创建多个歌单并向歌单中添加或移除歌曲，同时支持歌单名称与描述的编辑及歌单删除，并限制同一首歌重复加入同一歌单。每位用户在注册时须自动生成默认收藏歌单，作为收藏行为的统一承载容器。

(5) 个性化推荐展示

系统须在用户登录后的主页面展示由推荐引擎生成的个性化推荐列表，推荐结果须实时从数据库中读取，并支持用户手动触发推荐刷新。推荐列表须集成播放与收藏操作入口，以便在展示场景下直接完成用户行为的闭环采集。

(6) 播放历史查询

系统须记录用户的全量播放行为，并以时间倒序提供分页浏览能力，用户可通过播放历史页面回顾历史播放曲目。

图31 用户端用例图

3.2.2 管理端功能需求

管理端面向系统管理员，提供平台运营与内容治理所需的后台管理能力。管理员须通过独立的身份识别机制与普通用户登录流程区分，在通过身份验证后访问管理后台。整体功能如图32所示，管理端的核心用例覆盖以下四个功能域。

(1) 数据概览仪表盘

管理后台须提供实时数据统计视图，汇总展示当前注册用户总数、系统入库歌曲总数、全局收藏记录数量等平台核心运营指标，辅助管理员掌握系统整体运行状态。

(2) 用户账号管理

管理员须能够查看全量注册用户列表，支持按用户名、注册时间等条件进行搜索与排序。针对存在违规行为的用户，管理员须能够执行账号冻结操作，指定冻结截止时间与冻结原因；对于状态正常的账号，管理员须能解除冻结限制。系统须通过权限控制机制确保普通用户无法访问管理端的任何接口与页面。

(3) 申诉审核管理

管理员须能查看所有待处理的账号申诉记录，对每条申诉作出同意或拒绝的处置决定，并可填写回复说明。系统须在申诉处置完成后通过邮件服务自动向用户发送审核结果通知；当申诉被批准时，系统须同步恢复该账号的正常访问状态。

(4) 歌曲与收藏管理

管理员须能够浏览系统全量歌曲库，查看每首歌曲的元数据信息，并支持新增、编辑与删除歌曲记录。针对用户歌单，管理员须能查看所有用户创建的歌单及其包含的歌曲，并支持对违规或异常歌单执行删除操作以及从歌单中移除特定歌曲。

图32 管理员端用例图

3.2.3 推荐引擎功能需求

推荐引擎模块（MusicMode）作为系统的算法核心，承担从候选生成到最终推荐写库的全流程计算任务，其功能需求覆盖以下五个方面。

(1) 多路并行候选召回

系统须实现三条相互独立的候选召回通道：基于FAISS的向量近邻检索通道，通过用户画像向量与全量歌曲嵌入向量的相似度匹配，从数百万量级索引中召回高相关性候选；基于ALS协同过滤的召回通道，利用用户-歌曲交互矩阵的隐式因子分解结果生成候选；热度兜底召回通道，按歌曲热度与新鲜度综合排序补充候选，有效应对新用户及交互数据稀疏用户的冷启动场景。三路通道的候选结果须经去重合并后统一进入后续排序阶段。

(2) 多模型异构精排

候选集须经粗排与精排两个阶段逐级筛选。在粗排阶段，系统须调用LightGBM对全量合并候选进行基于手工特征的快速评分，筛选出置信度较高的子集。在精排阶段，系统须以DeepFM与BST双模型对粗排结果分别进行高阶特征交叉建模与用户行为序列建模，两模型的输出评分须通过离线Stacking优化得出的权重系数进行加权融合，得到最终集成评分并筛选出推荐候选集。

(3) 多样性重排

精排结果须经MMR（最大边际相关）算法进行多样性重排，综合权衡候选歌曲与用户偏好的相关性及其与已入选结果之间的差异性，防止推荐列表内容同质化。同时对同一艺术家的入选曲目数量设置兜底上限，保障结果集的风格多样性。

(4) 隐式反馈采集与冷却机制

系统须将每次推荐的歌曲记录持久化至推荐反馈表，并在用户发生播放、收藏等行为后更新对应记录的播放完成度与收藏标志。针对累计产生多次负向交互的曲目，系统须触发升级冷却机制，在冷却期内屏蔽该曲目对该用户的重复推荐，规避无效内容的持续曝光。

(5) 定时推荐更新调度

系统须支持通过定时调度机制在每日指定时间自动触发全量推荐重算，确保每日向所有注册用户更新个性化推荐列表，并将推荐结果批量写入数据库供前端实时读取。

3.3 后端功能性需求分析

3.3.1 性能需求

(1) 交互响应延迟

用户端页面在完成服务端数据查询与渲染后，须在可接受的响应时间内返回结果，以保证基本的交互流畅性。音乐搜索、排行榜查询等高频只读请求须通过Redis缓存层进行结果缓存，降低数据库的直接访问压力，保障热点请求的响应时效。

(2) 推荐计算吞吐能力

推荐引擎在执行每日全量推荐重算时，须能在预设的定时窗口内完成面向全量注册用户的三通道候选召回、多模型排序评分与推荐结果写库操作，保证每日推荐更新的计算吞吐能力。

(3) 数据库并发连接能力

系统须通过C3P0数据库连接池统一管理并发数据库连接，在高并发请求峰值期间弹性扩展可用连接数，保证请求不因连接资源耗尽而长时间阻塞；在访问低谷期须自动回收空闲连接，降低数据库端的持续资源占用。

3.3.2 安全性需求

(1) 注入攻击防护

系统所有涉及数据库读写的操作须采用参数化查询机制，将用户输入与SQL语句结构严格分离，从根本上消除SQL注入攻击的风险。前端表单须对用户输入进行格式与长度的合法性验证，确保非法输入在提交前被有效拦截。

(2) 跨站脚本防护

系统在将用户提交的内容回显至页面时，须对特殊字符进行转义处理，防止XSS（跨站脚本攻击）将恶意脚本注入其他用户的浏览器上下文，保护用户会话数据的安全性。

(3) 身份认证与权限隔离

系统须基于服务端会话机制维护用户登录状态，所有需要登录权限的页面与接口须在服务端进行会话有效性验证，防止未授权的直接访问。管理端与用户端须实现严格的角色权限隔离，管理员账号须通过独立的身份识别逻辑与普通用户区分，所有管理端操作接口须对普通用户完全不可达。

(4) 账号状态管控

系统须对被冻结或注销账号的用户拦截其登录请求，并向其展示明确的账号状态说明与申诉入口，防止异常账号继续访问受保护资源。管理员对账号的冻结与解冻操作须即时生效。

3.4 本章小结

本章围绕系统目标与需求规格展开，从功能性与非功能性两个维度对系统进行了完整梳理。在系统目标层面，从功能、性能与可用性三个角度明确了系统的整体定位；在功能性需求层面，分别从用户端、管理端与推荐引擎三个参与者维度梳理了核心业务用例，依次覆盖账号管理、音乐检索与播放、收藏与歌单管理、推荐展示等用户侧功能，数据概览、用户治理、申诉审核与歌曲资源管理等运营侧功能，以及三路候选召回、两阶段分层排序、MMR多样性重排与隐式反馈采集等推荐引擎侧功能；在非功能性需求层面，从性能、安全性与可扩展性三个维度明确了系统质量约束，涵盖交互响应与吞吐、注入与跨站脚本防护及权限隔离、推荐管道模块化与数据库可延伸性。

4 系统设计

4.1 引言

本章承接第3章确立的算法核心与功能边界，将多模型集成精排及Java Web交互等需求转化为技术方案。通过对系统总体架构、推荐算法流水线、数据库结构及前端交互四个核心域的深度设计，实现了从需求“做什么”到设计“怎么做”的逻辑跨越。本章所得技术架构与质量约束方案，将直接作为第5章工程实现的指导依据与核心输入。

4.2 系统总体架构设计

本系统采用双模块解耦架构，由面向用户交互的MusicWeb模块与面向算法计算的MusicMode模块协同构成，两者以MySQL关系型数据库为共享数据层进行集成，通过异步批处理机制实现数据闭环。如图41所示，系统整体架构由左侧MusicWeb、右侧MusicMode及底部共享数据层三部分组成：MusicWeb持续将用户行为信号写入共享数据库，MusicMode周期性从数据库读取行为数据完成推荐计算后将结果回写，MusicWeb再从数据库读取推荐结果渲染至用户界面，形成完整的数据驱动推荐闭环。

图41 MusicWeb + MusicMode双模块整体架构图

4.2.1 MusicWeb前端模块架构

MusicWeb是系统的用户交互载体，基于Java与Jakarta Servlet/JSP技术栈构建，采用经典的MVC三层分离架构，自上而下由表现层、控制层、业务逻辑层与数据访问层四个层次组成，各层之间职责边界清晰，层间依赖关系单向向下，以保证模块内部的低耦合性与高可维护性。

(1) 表现层

表现层由JSP动态页面、JavaScript行为脚本与CSS样式表共同构成，负责向用户浏览器输出可交互的HTML界面。页面集合涵盖首页、用户中心、歌曲搜索、歌单详情、播放历史、用户设置与账号申诉等业务场景，以及管理员后台的仪表盘、用户列表、申诉审核等运营页面。表现层通过异步请求机制与控制层交互，实现推荐列表刷新、收藏状态更新等无刷新动态操作，降低整页加载带来的用户感知延迟。

(2) 控制层

控制层由一组按业务职能划分Servlet控制器组成，统一接收表现层发起的HTTP请求并完成请求的分发与调度。按业务域归类，控制器集合覆盖用户认证、个人信息管理、音乐服务、行为上报、内容管理、推荐服务及管理端七个功能域。控制层不直接处理数据库操作，仅负责参数解析、权限校验与流程调度，以保持自身的轻量化。

(3) 业务逻辑层

业务逻辑层负责承载跨DAO的复合操作与推荐服务的协调逻辑。推荐服务组件负责从数据库读取由推荐引擎预计算的推荐结果，并结合用户当前的收藏状态与历史播放记录对推荐列表进行过滤与补全，最终向控制层返回可直接渲染的推荐歌曲列表。

(4) 数据访问层

数据访问层通过C3P0连接池获取数据库连接，对系统全部11张核心业务表的读写操作进行统一封装，向上层屏蔽SQL语句细节与结果集映射逻辑。各数据访问组件按业务实体划分，分别负责用户信息、歌曲元数据、播放历史、收藏关系、歌单数据、推荐记录与反馈数据等核心实体的持久化操作，全部SQL操作均采用参数化查询机制，有效防范SQL注入攻击。

(5) 缓存层

系统引入Redis作为热点数据缓存层，对用户收藏状态等读多写少的数据进行内存级缓存，减少数据库的重复查询压力。缓存层位于数据访问层之上，采用旁路缓存策略：读请求优先命中缓存，缓存未命中时回源数据库并更新缓存；写请求同步更新数据库并使相关缓存键失效，保证缓存数据与数据库数据的一致性。

4.2.2 MusicMode推荐引擎模块架构

MusicMode是系统的算法计算核心，基于Python与PyTorch深度学习框架构建，以定时批处理模式运行，不提供实时在线服务接口。模块内部自上而下由数据ETL层、特征工程层、模型训练层与推荐生成层四个功能层次组成，各层的产出物通过磁盘序列化文件或数据库表进行跨层传递，支持各层的独立执行与增量更新。

(1) 数据ETL层

ETL层负责从KKBOX公开数据集与MySQL业务数据库中抽取原始数据，执行数据清洗、格式规范化与样本构建操作。对于KKBOX的大规模歌曲数据集，系统采用PySpark分布式计算框架通过JDBC接口完成全量批量导入，并基于歌曲唯一标识进行增量去重，避免重复写入。对于模型训练样本的构建，ETL层以用户30天内的重复收听行为作为正样本标准，以等比例随机负采样生成负样本，输出结构化的训练样本集供特征工程层使用。

(2) 特征工程层

特征工程层基于ETL层输出的原始样本，为三个模型分别构建相互独立的特征集。LightGBM的特征集共59维，涵盖用户行为统计、歌曲属性统计、用户-歌曲交互匹配、时序特征、近期交互信号与SVD嵌入向量等特征组；DeepFM的特征集共50维；BST的特征集共58维，在DeepFM稀疏特征基础上额外扩展了序列行为特征，以支持对用户历史交互序列的时序建模。所有类别型特征的目标编码均采用OOE折外预测策略，在K折交叉验证框架下，每折编码值仅由其余K-1折样本统计得出，验证集与测试集编码通过全量训练集统计值计算，有效避免标签信号向训练阶段渗漏。

(3) 模型训练层

模型训练层中，LightGBM作为粗排模型，使用其59维特征集进行独立训练。DeepFM与BST作为精排层的两个基模型，分别使用各自的特征集通过GPU加速完成深度模型训练。精排集成阶段，以DeepFM与BST在验证集上的折外预测概率作为元特征，采用SLSQP约束优化算法求解最优融合权重，权重非负且总和为1的约束确保了集成结果的概率可解释性。各模型权重文件与集成配置分别序列化至磁盘，供推荐生成层调用。

(4) 推荐生成层

推荐生成层实现四层推荐管道的完整在线执行逻辑，按照三通道候选召回、LightGBM粗排筛选、DeepFM与BST双模型加权集成精排以及多样性重排的顺序依次处理，最终生成每位用户的个性化推荐列表并批量写入数据库。

4.2.3 双模块交互与部署设计

MusicWeb与MusicMode两个模块之间不存在直接的进程间通信依赖，采用以共享MySQL数据库为唯一数据交换媒介的松耦合集成模式。这一设计具有三方面工程优势：其一，两个模块可独立部署、独立重启与独立扩展，任一模块的故障不直接传播至另一模块；其二，数据库作为持久化消息载体，具备

断点续传能力——即使推荐引擎在某次执行中途中断，已写入数据库的推荐结果仍可被前端正常读取；其三，调试与运维人员可直接通过数据库查询工具观察模块间的数据流转状态，降低跨模块问题的排查复杂度。

在部署层面，MusicWeb打包为标准的WAR文件，部署于Apache Tomcat应用服务器，以持续进程形式提供在线服务。MusicModel以Python脚本形式运行，由操作系统级定时调度任务在每日指定时间自动触发推荐重算流程，无需常驻进程。Redis缓存服务与MySQL数据库服务以独立进程形式部署于同一台服务器，由MusicWeb启动脚本负责服务的有序启动与就绪检测，确保各依赖服务在Web应用接受请求前均已就绪。

4.3 推荐算法流水线设计

推荐算法流水线是本系统实现“千人千面”个性化推荐的核心机制。如图4-2所示，流水线采用四层串行架构，依次由召回层、粗排层、集成层与重排层构成。各层承担不同粒度的候选筛选职责：召回层以高覆盖率为目标，从全量曲库并行生成约600条候选；粗排层以效率为导向，通过梯度提升模型对候选集进行快速评分与压缩排序；集成层通过DeepFM与BST双模型异构融合对精选候选进行高精度精排；重排层在最终输出前施加多样性约束，防止推荐列表内容同质化。四层管道分工明确、接口清晰，支持各层独立迭代而不影响相邻层的运行逻辑。

图4-2 四层推荐管道总体流程图

4.3.1 召回层设计

召回层的核心设计目标是在计算效率约束下实现对高质量候选歌曲的高覆盖率捕获。系统设计了三条相互独立、特性互补的召回通道，通过并行执行后去重合并的方式构建统一候选集。如图4-3所示，三通道分别基于向量近邻检索、协同过滤与热度排序三种不同的信息源进行候选生成，以覆盖不同类型的用户兴趣信号。

通道A：FAISS向量检索召回

向量检索通道基于用户行为历史构建用户兴趣向量，通过FAISS内积索引在全量歌曲向量空间中执行精确内积搜索，召回与用户兴趣向量内积相似度最高的Top-200候选歌曲。该通道的设计逻辑在于用户的历史播放偏好语义嵌入空间中可以被有效压缩为一个固定维度的兴趣表示向量，与该向量距离近的歌曲在语义特征分布上与用户偏好高度吻合，因而具有较高的被播放概率。向量索引在离线阶段对全量歌曲库进行预计算与持久化，在线召回阶段仅执行向量查询操作，单次查询效率较高，能够满足批量推荐场景对吞吐效率的要求。

通道B：ALS协同过滤召回

协同过滤通道基于ALS隐式反馈矩阵分解模型，通过挖掘用户-歌曲交互矩阵中的群体行为相似性，为符合条件的用户召回最多200首候选歌曲。其核心逻辑在于捕获用户间的协同信号，即推荐与目标用户行为模式相近的其他群体所偏好的内容。针对用户活跃度差异，系统设计了三层降级路由：Tier1面向冷启动用户，依据注册偏好执行流派与艺术家兜底召回；Tier2面向中等活跃用户（满足5首收藏或10次播放），进行多维度内容相似度加权召回；Tier3面向高活跃用户（在ALS训练集且有效播放不少于10次），直接利用离线训练的隐因子向量执行内积排序召回。ALS模型在离线阶段完成矩阵分解并实现隐向量序列化存储，有效支撑了在线召回的高吞吐与低延迟要求。

通道C：热度兜底召回

热度兜底通道综合歌曲总播放量与用户偏好艺术家加权分进行排序，从高热候选池中筛选Top200歌曲作为补充。该通道旨在解决冷启动场景下的推荐可用性问题，针对行为信号极度稀疏的新用户，当向量检索与协同过滤通道失效时，热度兜底通过平台级高热内容保障推荐列表的基础质量与时效性。对于活跃用户，该候选与前述通道结果去重合并，有效提升了候选集的覆盖面。通过该机制，系统构建了完备的多层级召回体系，显著增强了推荐引擎在极端数据环境下的鲁棒性。候选合并与去重。

三通道各自独立生成候选列表后，系统以歌曲唯一标识为键执行集合去重操作，过滤用户近期已播放及处于推荐冷却期的歌曲，最终合并形成约600条不重复的候选集，传递至下游精排层。

图4-3 三通道并行召回结构图

4.3.2 粗排层与精排层设计

召回层以高覆盖率为目标输出约600首候选，但候选间的相对优劣尚未得到精细化区分。其后的粗排层与精排层承担连续两阶段的候选压缩任务：粗排层以效率为导向，通过轻量级模型对全量候选快速过滤；精排层以精度为导向，通过两个深度模型对过滤后的候选执行独立评分。两层依次将候选规模从约600首压缩至300首，再由精排层为集成层提供双路评分输入，这一过程实现了从海量数据到精准预估的逻辑跨越，确保系统兼顾推断效率与推荐质量。

粗排层利用LightGBM梯度提升模型对全部约600首候选执行快速评分，并按预测播放概率降序截取Top300传递至精排层。系统选用LightGBM的核心原因在于其基于直方图近似算法执行决策树分裂，相比涉及矩阵乘法与激活函数运算的深度神经网络，在大批量候选推断场景下吞吐效率更高，可将延迟控制在极低水平。此外，DeepFM与BST深度模型的计算开销较大，若对全量候选执行推断将显著增加系统负担，故将其范围限定在粗排后的Top300子集。特征设计上，粗排层采用独立的59维特征集，在保证推断效能的同时为精排层提供了可靠的输入依据。

精排层对粗排输出的Top300候选分别调用DeepFM与BST两个深度模型执行独立评分。DeepFM通过共享嵌入层同时建模低阶因子分解特征交叉与高阶非线性变换，能够捕捉手工特征未显式覆盖的隐式属性组合，从静态偏好视角提供评分。BST通过多头自注意力机制对用户历史播放序列进行时序Transformer编码，保留行为信号的时序细节并动态感知兴趣演化，从序列偏好视角提供评分。两个模型从静态属性匹配与动态序列偏好两个互补维度对同一批候选各自输出独立概率，二者结果共同传入集成层进行加权融合，实现了建模视角的深度互补与预估精度的提升。

4.3.3 集成层设计

集成层承接精排层输出的DeepFM与BST两组独立评分，通过离线Stacking训练得出的SLSQP优化权重系数对其进行加权融合，按集成得分降序截取前150首传递至重排层。

两模型的融合权重通过离线Stacking框架学习，以确保权重有数据支撑而非经验指定。在离线训练阶段，DeepFM与BST分别基于相同的K折交叉验证划分，生成各自在验证集上的折外预测概率；以两组折外预测向量为优化输入，以验证集真实标签为目标，通过SLSQP约束优化算法在权重非负且满足归一化约束的条件下，求解使加权集成效果最优的权重系数 w_1 、 w_2 。

在线推荐阶段，集成层对Top-300候选中每首歌曲读取精排层输出的两组评分概率，按式(4-1)计算集成推荐得分：

式中， d ——分别为DeepFM与BST对该歌曲的评分概率；

w_1 、 w_2 ——为离线Stacking优化得到的最优权重，满足 $w_1 + w_2 = 1$ 且 $w_1, w_2 \geq 0$ 。

按集成得分降序截取前150首传递至重排层。至此，集成层输出的150首候选在预测播放概率层面已经过充分筛选，以供重排层进行进一步的多样性约束筛选。

4.3.4 重排层设计

重排层承接集成层基于式(4-1)评分后输出的150首候选，在最终写入数据库前依次施加两类操作：以MMR算法对候选列表进行多样性重排，以及过滤当前处于推荐冷却期的歌曲，最终将候选压缩至每用户50首。重排层是四层管道的最后一级，其核心目的是在维持集成评分精度的前提下修正推荐列表的内容分布，防止模型偏好导致的同质化曝光。

(1) MMR最大边际相关重排

集成评分以单曲维度的播放概率为优化目标，不感知推荐列表的整体内容分布。重排层采用MMR（最大边际相关，Maximal Marginal Relevance）算法，在候选歌曲的相关性与已选列表的多样性之间进行权衡，其得分公式如式(4-2)所示：

式中 d ——当前待评估的候选歌曲；

$Rel(d)$ ——该候选歌曲的归一化集成评分，取值范围为 $[0, 1]$ ；

$Sim(d, d_i)$ ——候选歌曲 d 与已选列表中歌曲 d_i 基于FAISS嵌入向量计算的余弦相似度；

S ——已选列表，即当前已通过贪心选取加入推荐结果的歌曲集合；

λ ——相关性权重系数，取 $\lambda = 0.7$ ，即相关性占70%，多样性惩罚占30%。

算法按MMR得分贪心逐步选取：每轮从剩余候选中取MMR值最高的歌曲加入已选列表，循环执行直至选满50首。此外，系统设置同一艺术家入选上限作为安全兜底，超限候选将被施加软惩罚而非直接排除，保证多样性约束为软约束机制。

(2) 推荐冷却过滤

系统在推荐反馈表中为每对用户-歌曲记录冷却截止日期，对连续收到负向反馈的歌曲触发一定天数的推荐冷却。重排层在贪心筛选的同时实时过滤冷却期内的候选歌曲，防止对用户持续不感兴趣的内容进行重复曝光。重排层仅执行只读过滤操作，冷却策略的触发条件与时长由上游反馈处理逻辑负责计算，各层职责保持单一。

经多样性重排与冷却过滤后，最终生成的每用户50首推荐列表兼顾评分精度与内容多样性，批量写入数据库推荐表，供MusicWeb前端在用户访问时实时读取与渲染，从而完成四层管道的完整推荐闭环。

4.4 数据库设计

4.4.1 表的概念结构设计

概念结构设计阶段通过实体—关系模型（E-R模型）对系统业务数据进行抽象，明确实体的属性及其相互关联，为后续逻辑结构设计奠定基础。

本系统共梳理出11个核心实体，分别为：用户表、歌曲表、播放历史表、用户歌单表、歌单歌曲关联表、推荐结果表、推荐反馈表、用户满意度反馈表、申诉表、用户屏蔽内容表以及歌曲滚动统计表。

各实体间的核心关联关系如下：用户与歌曲之间通过播放历史表形成多次播放记录的关联；用户与歌单之间为一对多关系，一个用户可创建多个歌单，歌单与歌曲之间通过歌单歌曲关联表构成多对多关系；用户与推荐结果表之间为一对多关系，系统每日为每位用户生成若干推荐记录；推荐反馈表依附于推荐结果表，记录用户对推荐歌曲的真实交互行为；用户口味反馈表、申诉表及用户屏蔽内容表均以用户为核心，分别记录偏好标签、违规申诉及内容屏蔽信息。

歌曲滚动统计表与歌曲主表为一对一关系，每首歌曲对应一条预聚合的滚动统计记录，以独立表结构存储近7天、近30天播放量及热度趋势指标，避免频繁统计更新影响歌曲主表的查询效率。系统核心实体关系如图4-4所示。

图4-4 系统核心实体关系图

4.4.2 表各字段功能设计

在对各表功能设计阶段，本人将概念模型中的11个实体映射为MySQL数据库中的11张业务表，通过外键约束与联合索引保证数据一致性与查询效率。各表的详细字段结构见附件1。

11张表具体的作用分别是：用户表存储全量注册用户的账号信息与状态标记；歌曲主表承载246万首歌曲的完整元数据；播放历史表以时间戳记录每次用户-歌曲交互事件，是特征工程与模型训练的原始数据基础；用户歌单表管理用户创建的歌单，歌单歌曲关联表实现歌单与歌曲的多对多映射；推荐结果表批量存储每日为各用户生成的50首推荐候选，推荐反馈表在此基础上记录用户的实际交互行为与冷却状态；用户满意度反馈表记录用户对每日推荐整体的显式评分；申诉表承接用户提交的申诉请求；用户屏蔽内容表维护流派与艺术家的软屏蔽规则；歌曲滚动统计表预聚合每首歌曲近7天与近30天的播放量及热度趋势，以独立表结构避免频繁写入影响歌曲主表查询效率。

4.5 前端交互设计

4.5.1 页面总体结构设计

系统采用统一的页面框架，所有功能页面共享同一套顶部导航栏与底部版权区。顶部导航栏提供全局功能入口，涵盖音乐发现、个人推荐、歌单管理与个人中心四大模块；底部版权区承载项目声明信息。主内容区根据当前功能模块动态渲染对应的视图，各页面样式以独立样式文件进行维护，确保样式隔离与可维护性。

系统页面按访问权限分为两类：公开访问页面（主页、音乐搜索、歌曲详情等）与登录后可用页面（个人推荐、歌单管理、个人中心等）。两类页面均通过统一的权限拦截机制进行校验，未登录用户访问受保护页面时将被自动重定向至登录入口，确保用户数据安全。系统整体页面导航层次如图4-5所示。

图4-5 系统页面导航层次结构图

图4-5以树形层次清晰呈现了系统各功能页面的组织关系。一级节点为四大功能模块，二级节点为各模块下的具体页面。用户可通过顶部导航栏直达各一级模块，再经页面内部交互跳转至对应二级页面，路径清晰，交互层级不超过三级，有效降低用户的操作认知负担。

4.5.2 核心功能页面设计

系统核心功能页面共分为四个模块，各模块在交互设计上均以简洁高效为原则，力求以最少的操作步骤完成目标任务。

(1) 音乐发现模块

音乐发现模块为系统的公开主入口。页面上方展示热门歌曲排行与最新上架内容，用户可通过关键词搜索框按歌名或歌手名检索歌曲。搜索结果以卡片形式排列，每张卡片包含封面图、歌名、歌手及快捷操作按钮（播放、收藏、加入歌单）。点击卡片后进入歌曲详情页，用户可查看完整信息并触发播放，系统同步记录本次播放行为至播放历史表。

(2) 个性化推荐模块

个性化推荐模块是系统的核心展示界面，负责呈现推荐算法为当前用户生成的每日推荐结果。页面以有序列表形式展示当日50首推荐歌曲，每条记录包含歌曲基本信息及操作区域（播放、收藏、反馈不喜欢）。用户在此页面的所有交互行为均通过异步请求实时上报至后端，后端将其写入推荐反馈记录，作为下一轮推荐迭代的训练信号。

(3) 歌单管理模块

歌单管理模块支持用户创建、重命名与删除自定义歌单，并可向歌单中批量添加或移除歌曲。歌单列表页以卡片网格呈现用户的所有歌单，点击卡片后进入歌单详情页，以分页表格展示歌单内全部歌曲，每行末尾提供移除操作入口。歌单数据经由数据访问层持久化至数据库，操作结果通过页面消息提示即时反馈。

(4) 个人中心模块

个人中心模块聚合了用户账户管理与行为记录查询功能。用户可在此修改账户信息、查看播放历史与收藏列表、配置流派或歌手屏蔽偏好，并可对认为不当的内容提交申诉请求。管理员账户在个人中心额外具备用户管理与歌曲管理两项后台入口，支持对系统核心数据的集中维护与审核处理。

4.5.3 推荐交互与行为反馈设计

推荐交互设计的核心目标是高效采集行为信号并形成持续优化的反馈闭环。如图4-6所示，推荐引擎离线完成候选生成与排序后将结果写入数据库，前端在用户访问时读取并展示当日推荐列表。用户在推荐页面触发的交互归为三类分支处理：播放行为触发前端计时器实时记录播放进度，用户离开时通过异步请求将完播率上报至后端；收藏行为作为强正向信号即时写入反馈记录；反馈不喜欢行为被标记为负向交互，触发对应内容的降权处理。三类行为均汇入推荐反馈表，作为下一轮推荐迭代的训练信号输入。在评分细节上，完播率低于20%的播放行为被标记为跳曲，系统据此对该歌曲或歌手在后续推荐中进行降权处理；收藏行为则作为强正向信号，提升相似风格内容的推荐权重。

此外，用户可在个人中心主动声明对特定流派或歌手的屏蔽偏好，系统采用递增冷却机制：每次屏蔽操作累加屏蔽计数，冷却到期日随计数递增而延长，到期后屏蔽状态自动失效，避免单次操作造成永久性内容排除，上述多维度行为反馈共同构成系统推荐的在线学习闭环。

图4-6 推荐交互行为反馈闭环流程图

4.6 本章小结

本章在第三章需求分析所确立的功能边界与算法目标的基础上，完成了系统从“做什么”到“怎么做”的设计转化，围绕系统总体架构、推荐算法流水线、数据库结构与前端交互四个核心设计域展开，形成了可直接指导工程实现的完整技术方案。

在系统总体架构设计上，本章确立了MusicWeb与MusicMode双模块解耦架构。MusicWeb基于Java与Jakarta Servlet/JSP构建，以MVC三层架构承载用户交互逻辑；MusicMode基于Python与PyTorch构建，以ETL、特征工程、模型训练与推荐生成四个功能层驱动算法计算。两个模块以MySQL共享数据库为唯一数据交换媒介，采用松耦合集成模式，互不依赖进程间通信，具备独立部署与独立扩展的能力。

在推荐算法流水线设计上，本章构建了三路召回、粗排、双模型精排与重排的四层串行管道。召回层设计了FAISS向量检索、ALS协同过滤与热度兜底三条互补通道，并行生成约600首候选集。粗排层由LightGBM对全量候选快速评分，压缩至Top-300。集成层对DeepFM与BST两个精排模型的独立评分以SLSQP优化权重进行加权融合，保留Top-150。重排层采用MMR算法在相关性与多样性之间权衡，并施加冷却过滤，最终为每位用户生成50首个性化推荐。在数据库设计上，本章基于E-R模型梳理了11张核心业务表，以外键约束与联合索引保障数据一致性与查询效率。

在前端交互设计上，本章规划了音乐发现、个性化推荐、歌单管理与个人中心四大功能模块的页面结构与交互逻辑，并设计了以播放时长上报、收藏、不满意反馈与屏蔽偏好配置为核心的行为采集闭环，使用户的实时交互信号能够持续流入推荐系统的更新链路。上述四个设计域的方案共同构成了系统完整的技术架构蓝图，第五章将在此方案的直接指引下，逐一展开各核心模块的工程实现过程。

5 系统实现

5.1 引言

本章在第四章系统设计方案的基础上，对各核心模块的具体实现过程进行详细阐述。全章围绕开发环境配置、数据处理与特征工程、推荐管道算法实现、前端功能实现与系统部署四条主线展开，结合工程实践中的关键技术决策与调优细节，完整呈现系统从原始数据到线上服务的实现全貌。

5.2 开发环境与工具配置

本系统的开发与训练均在本地单机环境下完成，Python端承担算法计算与模型训练任务，Java端承担Web服务与页面渲染任务，两端共享同一MySQL实例实现数据联动。系统软硬件环境配置如表5-1所示。

表5-1 系统实验环境配置

类别 环境 配置

硬件 操作系统 Windows 11专业版（64位）
处理器 13th Gen Intel(R) Core(TM) i9-13900HX
GPU NVIDIA GeForce RTX 4060
显存 / 内存 8 GB VRAM / 16 GB RAM
CUDA版本 13.1（驱动591.74）
Python端软件 Python 3.12
PyTorch 2.6.0（cu124）
LightGBM 4.6.0
FAISS 1.13.2

表5-1（续表） 系统实验环境配置

类别 环境 配置

Python端软件 PySpark 4.0.0
scikit-learn 1.5.2
Pandas / NumPy 2.2.2 / 1.26.4
Redis 7.4.0
Java端软件 JDK (Eclipse Adoptium) 23 LTS
Jakarta Servlet / JSP 6.1 / 3.1
MySQL 8.4.0

系统Java端采用C3P0连接池统一管理数据库连接，连接池启动时预建5条连接，并发峰值时最多扩展至20条；空闲超过300秒的连接自动回收，防止MySQL服务端因长期闲置连接积压触发超时断开；每次签出连接前执行存活验证，配合30秒的定期心跳检测，保证连接池中的连接始终处于可用状态；所有数据访问方法在异常处理的最终块中归还连接，确保任何异常路径均不会造成连接泄漏。具体参数配置表5-2所示。

表5-2 C3P0连接池配置参数

参数 取值 说明

初始连接数 5 启动时预建连接数
最小连接数 5 连接池保持的下限
最大连接数 20 并发扩展上限
最大空闲时间 300秒 超时未使用的连接自动回收
获取连接超时 30000毫秒 超时未获取到连接则抛出异常
空闲连接检测周期 30秒 定期发送心跳探测连接存活

表5-2（续表） C3P0连接池配置参数

参数 取值 说明

签出前存活验证 开启 签出连接前执行轻量查询验证
获取失败重试次数 3次 连接获取失败后的最大重试数
重试等待间隔 1000毫秒 每次重试前的等待时间

5.3 数据处理与特征工程实现

5.3.1 数据来源与ETL处理

本系统模型训练的核心数据来源于KKBOX公开音乐数据集，源自KDD Cup推荐系统竞赛数据，由用户行为交互数据、歌曲元数据及用户画像数据三类结构化数据构成，合计覆盖约229万首歌曲、约737万条历史收听行为记录及约3.4万名注册用户，能够支撑大规模推荐算法的训练与离线评估。此外，还从网易云音乐端获取了约2万首网易云音乐的歌曲元数据，经清洗去重后与KKBOX歌曲数据合并存入歌曲表，共同构成推荐候选池，进一步丰富了候选歌曲的覆盖范围。其中用户行为交互数据约含737万条样本，每条记录对应一次用户与歌曲的交互事件，目标变量是正负样本划分的依据，亦是全部推荐模型训练与离线评估所依赖的直接监督信号，各字段含义如表5-3所示。

表5-3 用户行为交互数据字段说明

字段名称 数据类型 字段说明

msno String 用户唯一标识
song_id String 歌曲唯一标识
source_system_tab String 用户触达该歌曲的功能页面
source_system_tab String 用户触达该歌曲的功能页面
source_screen_name String 用户当前所在的具体界面名称

表5-3（续表） 用户行为交互数据字段说明

字段名称 数据类型 字段说明

source_type String 播放入口类型
target Int 目标变量：用户首次收听后一个月内是否产生重复收听行为（1为是，0为否）

歌曲元数据由歌曲基础信息与歌曲扩展信息两部分合并构成，覆盖约229万首歌曲，为系统构建歌曲侧内容特征提供原始数据支撑。其中国际标准录音制品编码（ISRC）内嵌了发行国家与发行年份信息，通过正则解析可解析出歌曲的来源地区特征与时效性特征，是特征工程阶段歌曲侧特征扩展的重要数据来源，各字段含义如表5-4所示

表5-4 歌曲元数据字段说明

字段名称 数据类型 字段说明

song_id String 歌曲唯一标识
song_length Int 歌曲时长

genre_ids String 流派标识列表
artist_name String 演唱艺术家名称
composer String 作曲者名称
lyricist String 作词者名称
language Int 歌曲语言编码
name String 歌曲名称
isrc String 国际标准录音制品编码

用户画像数据记录了KKBOX平台注册用户的基本属性信息，共3.4万名用户，用于构建用户侧静态属性特征。其中年龄字段存在大量异常值（如取值为0或明显超出合理范围），在后续数据清洗阶段需进行缺失值填充或样本剔除处理，各字段含义如表5-5所示。

表5-5 用户画像数据字段说明

字段名称 数据类型 字段说明

msno String 用户唯一标识

city Int 城市编码

bd Int 出生年份

gender String 性别

registered_via Int 注册渠道编码

registration_init_time Int 注册时间戳

expiration_date Int 会员过期时间戳

ETL处理阶段采用分布式读取策略，以分布式计算框架通过标准数据库接口对歌曲信息、播放历史、用户信息及歌单关系四张核心业务表执行全量抽取。

在执行计划层，框架根据后续特征工程的字段依赖关系，自动生成并应用列裁剪（Column Pruning）与谓词下推（Predicate Pushdown）两项优化策略：列裁剪仅向数据源请求特征构建所必需的字段，舍弃与建模无关的冗余列；谓词下推则将过滤条件前移至数据源侧执行，使不满足条件的行在磁盘读取阶段即被排除，而非在内存中完成过滤。

两项优化协同作用，将原始数据在磁盘读取阶段的实际传输量压缩约60%，显著降低了集群内存的峰值占用，并缩短了数据加载至分布式内存的时间开销，为后续的数据清洗与特征变换操作奠定了高效的数据流基础。

5.3.2 数据清洗

原始数据存在三类质量问题，需在特征构建前逐一处理：

（1）缺失值填充

歌曲元数据中artist_name、genre_ids等字段存在一定比例的缺失，采用语义占位符（如“unknown”）填充分类型字段，数值型字段（如song_length）以全局中位数填充，保留数据行数的同时避免引入极端偏差。训练行为数据中存在少量缺失行，直接丢弃以确保样本标签完整性。

（2）冷启动过滤

交互次数少于3次的用户因行为信号过于稀疏，难以支撑统计特征的可靠估计，将其从训练集中移除。歌曲侧保留所有至少被播放1次的歌曲，以最大化Embedding层的覆盖范围，避免过度过滤导致召回层候选集收缩。

（3）样本分布校验

经对KKBOX原始训练数据统计，正样本（target=1）约占50.35%，负样本（target=0）约占49.65%，正负样本天然接近均衡（约1:1），无需执行额外的下采样操作。清洗阶段直接保留全量有效样本参与模型训练，以避免人为采样引入分布偏差。

5.3.3 特征工程

系统为粗排层与精排层各模型分别构建了独立的特征集：LightGBM粗排特征集共59维，DeepFM精排特征集共50维，BST精排特征集共58。三个特征集在稀疏特征种类与稠密特征组合上各有侧重，但均从用户画像、歌曲属性、行为统计、交叉匹配、时序动态和隐向量嵌入六个维度对“用户-歌曲”交互关系进行刻画，表5-6按特征类别对上述特征进行分类展示。

表5-6 特征工程各维度特征概览

特征维度 特征数 代表特征 类型

用户画像 9 性别、年龄、城市、账龄分桶、播放量对数、平均完播率、流派多样性熵、近30日活跃天数、收听高峰时段 稀疏\稠密
歌曲属性 11 流派、语言、歌手、来源国、年份分桶、时长分桶、播放量对数、平均完播率、归一化热度、歌曲年龄对数 稀疏\稠密
上下文 1 来源渠道（source_channel） 稀疏

表5-6(续表) 特征工程各维度特征概览

特征维度 特征数 代表特征 类型

交叉匹配 4 用户-流派匹配度、用户-歌手匹配度、用户-语言匹配度、用户-国家匹配度 稠密
时序行为 8 距上次听同曲天数、历史播放次数、近7/30日播放量对数、近7日平均完播率、歌曲近7/30日播放量、热度趋势比 稠密
SVD协同嵌入 26 用户-歌曲矩阵分解10维、歌曲-用户矩阵分解10维、用户-歌手矩阵分解5维、SVD点积分数1维 稠密
行为先验 3 用户重复收听率、歌曲重复收听率、用户跳过程率 稠密

（1）用户侧特征

用户侧特征分为画像类与行为统计类两类。画像类特征包括性别、城市、年龄分段（5档：未滿18岁、18~25岁、26~35岁、36~50岁、51岁以上）和账户成熟度分段（4档：新用户、成长期、活跃期、忠诚用户），经离散化后作为稀疏特征输入嵌入层。

行为统计类特征在全量历史播放记录基础上预计算得出，包括：用户累计播放总量（经对数变换压缩长尾分布）、历史平均完播率、流派偏好多样性（采用香农熵量化，熵值越高品味越多元）、近30天活跃天数、历史重复收听率、跳过程率（完播进度低于10%的记录占比）及用户收听高峰时段（该时段下播放频次最高）。

（2）歌曲侧特征

歌曲侧特征同样分为属性类与统计类两类。属性类特征包括流派标识、发行语言、演唱艺术家、来源国家、年代分段（6档：1980年前、20世纪80年代、90年代、21世纪00年代、10年代、20年代）和时长分段（4档：短曲<90秒、中等90~240秒、较长240~420秒、超长>420秒），以及播放来源渠道。统计类特征包括：全局累计播放总量、全局平均完播率、归一化热度得分、歌曲年龄、歌曲重复收听率和歌曲被跳过程率。

此外引入热度趋势指标以捕捉近期播放动态，其计算方式如式5-1所示：

式中 count_7 表示该歌曲最近7天的播放次数；

count_{30} 表示最近30天的播放次数。

两者均采用严格的左闭时间窗口计算，以确保特征计算的时间无泄漏性。该指标大于1时说明歌曲近期热度加速上升，小于1时代表热度趋于衰退。

（3）用户-歌曲交叉特征

系统从流派、艺术家、语言和来源国家四个维度计算用户-歌曲匹配度，统计用户历史播放中该属性取值与候选歌曲相同的记录占该用户总播放记录的比例，得分落于[0,1]区间，量化用户对该维度属性的偏好强度。此外，系统构建时段匹配特征（当前时段是否在用户历史最高频前3个收听时段内）与活跃日匹配特征（当前日期是否在用户历史最活跃前3个工作日内），从时序维度补充用户行为规律的刻画。

（4）时序行为特征

时序行为特征分为记忆衰减特征与滚动窗口统计特征两类。记忆衰减特征包括：距用户上一次收听同一首歌的天数（-1表示首次收听）和当前播放前该歌曲的累计收听次数。滚动窗口统计特征以严格左闭窗口方式计算，分别在7天与30天两个时间粒度上统计用户播放总量、用户近期平均完播率、歌曲播放

总量，结合热度趋势指标反映用户与歌曲的近期动态。

(5) SVD隐向量嵌入特征

为将用户-歌曲协同交互信息压缩为低维稠密表示，系统基于截断奇异值分解对用户-歌曲交互矩阵执行矩阵分解，公式见5-2所示：

式中 R ——为用户-歌曲交互矩阵（发生播放记为1，否则为0）；

U ——为用户隐向量矩阵；

Σ ——为奇异值对角矩阵；

V 为歌曲隐向量矩阵。

分解后取前10个奇异分量分别得到10维用户嵌入向量与10维歌曲嵌入向量；进一步对用户-艺术家交互矩阵执行同样的分解操作，得到5维用户-艺术家嵌入向量；最终以用户向量与歌曲向量的点积作为隐式协同过滤评分。上述嵌入特征共26维，作为稠密特征直接拼接至统计特征之中。

(6) OOF目标编码

高基数稀疏特征（如用户标识、歌曲标识）的类别数量达数万至数十万量级，若直接标签编码，存在目标泄漏风险，导致训练集评估表现虚高。系统采用留出折叠目标编码（Out-of-Fold Target Encoding, OOF-TE）方案，其核心公式见式5-3所示：

式中 k ——为当前验证折编号；

$C_{-k}(x)$ ——为除第 k 折外的其余4折中特征取值等于 x 的正类样本数；

$N_{-k}(x)$ ——为对应的样本总数；

M ——为全局正例率；

A ——为平滑系数（本系统取 $\alpha=10$ ）。

如图5-1所示，OOF-TE将训练集划分为5折，每一折样本的编码值仅由其余4折的统计量计算得出，每条样本的目标编码值均来自其未曾参与训练的数据，从目标上消除了特征计算环节引入的数据泄漏。测试集及线上推理阶段则使用全量训练集统计量计算目标编码，以充分利用所有可用的历史信息。

图5-1 基于折外样本策略的目标编码五折交叉验证机制示意图

5.3.4 数据集时序切分

推荐场景下，训练集与验证集的划分必须尊重时间先后顺序，随机划分会使模型在验证阶段“看见”未来数据，导致离线指标虚高。本系统采用用户级时序切分策略：对每位用户的播放记录按播放时间升序排列，取各用户最后一条播放记录作为验证集，其余历史记录保留为训练集。该策略模拟了真实推荐场景中“用过去的行为预测未来偏好”的评估语义，使验证集AUC能够客观反映模型在实际部署环境下的泛化能力。

5.4 MusicMode推荐算法实现

在完成数据清洗与特征工程的基础上，本节依次实现推荐管道的四个核心层次：三路候选召回、LightGBM粗排、DeepFM与BST双模型精排集成，以及MMMR多样性重排，逐步将约600首候选歌曲筛选至最终50首推荐结果。

5.4.1 ALS协同过滤召回实现

ALS召回模块基于用户-歌曲历史交互矩阵进行矩阵分解，为每位用户生成偏好相近的候选歌曲集合。实现时首先从特征矩阵中提取用户编码与歌曲编码，构造稀疏交互矩阵，矩阵中非零元素表示用户曾播放该歌曲。ALS模型的核心超参数配置为：隐向量维度（rank）=50，迭代轮次=10，正则化系数=0.1。训练完成后，通过计算每位用户的隐向量与所有歌曲隐向量的点积，取得分最高的前200首歌曲作为ALS通道的候选集。

5.4.2 FAISS向量检索召回实现

FAISS召回通道利用DeepFM训练好的Embedding层提取歌曲的内容语义向量。具体而言，从DeepFM模型中抽取五类稀疏特征的Embedding：歌曲ID、流派、语言、歌手、来源国，将五者拼接得到每首歌曲的160维（5类稀疏特征×32维）复合向量，该向量同时编码了歌曲的协同过滤信息与内容属性信息。

对全量歌曲向量执行L2归一化后，以IndexFlatIP（内积索引）构建FAISS索引——L2归一化后的内积等价于余弦相似度，无需额外计算。用户画像向量由其历史播放歌曲的Embedding加权聚合得出（近期播放权重更高），再以该向量在FAISS索引中检索，召回Top-200余弦相似度最高的候选歌曲。整个索引涵盖约229万首歌曲，单次检索时延不超过10ms。

5.4.3 热度兜底召回实现

热度召回通道基于预计算热度缓存实现。系统在离线预处理阶段将全量歌曲按累计播放次数降序排列，保留前10000首构成热度候选池。在线召回时，以各歌曲的累计播放次数为基础得分，叠加艺术家偏好加权分：系统依据用户对各艺术家的历史反馈等级，从预置的艺术家偏好加权映射表中读取对应加权分值（用户反馈等级为不满意时加800分、中性时加500分、满意时加300分、非常满意时加150分），对候选池中属于偏好艺术家的歌曲执行加分，最终取综合得分最高的前200首作为热度通道的候选集。当热度缓存读取失败时，系统自动回退至按歌曲流行度降序排列的兜底方案，保障召回通道的稳定性。

5.4.4 LightGBM粗排实现

粗排阶段选用LightGBM对三路召回合并的约600首候选歌曲进行快速评分，将候选规模压缩至300首，为后续深度精排模型减少无效计算负担。LightGBM基于直方图优化的梯度提升决策树（Gradient Boosting Decision Tree, GBDT）框架，通过对连续特征值进行分桶直方图统计来寻找最优分裂点，推理延迟仅为毫秒级，契合粗排阶段对吞吐量的高要求。

模型输入采用全部59维特征，涵盖用户侧、歌曲侧与交叉特征。针对训练集内的目标泄漏风险，结合5.3.3节所述的折外样本目标编码（OOF-TE）策略进行特征构建，确保每条训练样本的目标编码值均由其所在折之外的样本统计得出，有效规避标签信息在特征计算环节的提前泄露。训练采用二分类交叉熵目标函数，通过叶节点最低样本量参数设定分裂门槛，防止决策树在小样本叶节点上记忆噪声。此外树棵数与学习率的组合控制集成规模与收敛节奏，完整超参数配置如表5-7所示。

表5-7 LightGBM粗排模型超参数配置

超参数 取值 说明

num_leaves 160 每棵树最大叶节点数

max_depth 6 树最大深度

n_estimators 15000 决策树棵数

learning_rate 0.007 学习率

min_child_samples 2000 叶节点最少样本数，防止过拟合

objective binary 二分类任务

5.4.5 DeepFM深度精排实现

DeepFM模型部署于集成层精排阶段，对LightGBM粗排输出的300首候选进行深度建模评分。该模型将因子分解机（FM）与深度神经网络（DNN）联合训练，在同一框架内同时捕捉低阶交互式特征交叉与高阶隐式特征交叉，弥补了梯度提升树对高维特征组合建模能力有限的不足。

特征输入分为稀疏特征与稠密特征两类。14个稀疏特征分别通过独立Embedding映射为32维向量，各词表容量额外保留1个未见标识符（OOV）槽位，确保推理阶段的未知标识符不引发越界异常。14个稀疏特征的Embedding拼接后形成448维向量，同时送入FM层与DNN层。FM层以 $O(kn)$ 的时间复杂度高效计算91对二阶特征交叉，然后DNN层将448维稀疏Embedding与全部稠密特征拼接后，依次经过四层全连接网络（512→256→128→64），每层后接ReLU激活与Dropout（丢弃率=0.35），最终FM层与DNN层输出求和后经Sigmoid函数映射至(0,1)区间，作为用户对候选歌曲的偏好概率。

深度模型输入不包含目标编码字段，以防将训练集标签信息注入特征空间产生隐式泄漏。训练采用用户级时序切分策略，以每位用户最近10%的交互记录（至少5条方参与切分）作为验证集，保障评估的时序语义一致性，并启用混合精度（AMP）训练降低显存占用，完整超参数配置如表5-8所示。

表5-8 DeepFM精排模型超参数配置

超参数 取值 说明

DNN隐藏层结构 (512, 256, 128, 64) 四层全连接，逐层降维

Dropout率 0.35 各隐藏层Dropout，防止过拟合

批量大小 8192 充分利用GPU并行计算

最大训练轮次 60 含早停机制

初始学习率 0.002 Adam优化器

LR衰减策略 ReduceLROnPlateau 耐心轮次3, 衰减系数0.35, 下限1e-6

早停耐心轮次 10 验证AUC连续10轮不提升则停止

混合精度训练 AMP (FP16/FP32) 加速训练, 降低显存占用

DNN隐藏层结构 (512, 256, 128, 64) 四层全连接, 逐层降维

5.4.6 BST行为序列Transformer精排实现

BST (行为序列Transformer) 与DeepFM并联部署于集成层精排阶段, 同样对粗排输出的300首候选进行深度建模评分。BST的核心设计在于引入Transformer自注意力机制对用户行为序列进行整体建模, 通过多头自注意力层捕捉序列内各历史行为之间的时序依赖关系, 输出的序列编码向量与候选歌曲特征融合后经多层感知机输出偏好预测概率, 与DeepFM的高阶特征交叉视角形成互补。

在数据预处理上, BST针对稀疏特征做了两项针对性处理。其一为低频标识符过滤: 统计训练集中各用户标识符与歌曲标识符的出现频次, 将不足3次的稀疏标识符统一映射为未知类别, 防止Embedding层对长尾低频标识符过度拟合, 损害模型泛化能力。其二为用户历史时序位置特征注入: 将当前交互在用户全部历史中的时序比例 (0表示最早记录, 1表示最近记录) 作为额外稠密特征注入模型, 使模型能够隐式区分近期行为与早期行为, 缓解时序概念漂移的干扰。

BST的核心是由3层多头自注意力层与前馈网络堆叠而成的Transformer编码器, 对固定长度为50的历史行为序列进行全局建模。序列中每个行为以32维Embedding表示, 经线性投影升维至128维后送入Transformer; 编码输出经注意力加权池化后与候选歌曲特征拼接, 通过三层全连接网络 (256→128→64, 各层后接批归一化与ReLU激活) 输出点击概率。完整超参数配置如表 5-9所示。

表5-9 BST精排模型超参数配置

超参数 取值 说明

稀疏特征数/Embedding维度 14/32 低频标识符 (出现次数 < 3) 映射至未知类别

Transformer层数/注意力头数 3/4 隐层维度128, 前馈维度256

DNN隐藏层结构 (256, 128, 64) 三层全连接, 各层后接批归一化

激活函数 ReLU 各隐藏层后接批归一化

表5-9 (续表) BST精排模型超参数配置

超参数 取值 说明

Dropout率 0.45 Transformer与DNN层共用

批量大小 4096 GPU显存与吞吐量平衡

最大训练轮次 40 含早停机制

初始学习率 5e-5 Adam优化器

LR衰减策略 CosineAnnealingLR 最小学习率下限1e-6

早停耐心轮次 10 验证AUC连续10轮不提升则终止

5.4.7 Stacking集成与重排输出的实现

(1) Stacking集成

集成层以DeepFM与BST两个精排模型对验证集样本的预测分数作为元特征, 通过离线权重优化确定各模型在最终融合评分中的贡献比例。权重求解采用SLSQP约束优化算法, 目标函数为最小化集成预测在验证集上的负AUC值, 约束条件为两个权重之和等于1且各权重不低于0.20, 防止集成退化为单一模型。系统同时以等权平均 (0.5/0.5) 作为稳健基线, 取两种策略中验证集AUC更高者作为最终方案, 将对应权重持久化存储, 在线推荐时直接加载, 不引入额外运行时开销。

在线推理阶段, 精排集成层对LightGBM粗排保留的300首候选分别调用DeepFM与BST进行独立评分, 以离线优化所得权重对两组分数执行加权线性融合, 取集成综合评分最高的前150首进入重排阶段。

(2) 重排与结果写入

重排阶段采用MMR (最大边际相关) 算法对150首候选进行多样性重排。算法以贪心方式逐步选取歌曲: 每轮选取MMR得分最高的候选加入推荐列表, 该得分综合考虑候选与用户兴趣的相关性 (权重 $\lambda=0.7$) 及候选与已选列表的最大余弦相似度 (权重0.3), 上述过程持续至选出50首为止。

内容过滤在贪心选取过程中同步执行: 跳过用户近期已播放或显式屏蔽的内容; 对推荐反馈表中累积冷却惩罚较高的内容执行动态降权, 使其在竞争中自然后退。上述过滤规则均从数据库实时读取, 与集成评分计算在同一请求上下文完成。

最终50首推荐结果以批量写入方式更新至数据库推荐结果表, Java前端在用户发起页面请求时直接查询并渲染展示, 推荐计算与前端服务在时序上完全解耦, 避免实时推断对接响应时延的影响。

5.5 MusicWeb前端实现

5.5.1 MVC分层架构搭建

系统遵循MVC三层架构进行代码组织。控制层由若干业务处理单元构成, 每个单元对应一类业务请求 (用户认证、播放记录、推荐获取、歌单管理等), 通过注解声明请求路径映射, 由Web容器统一管理生命周期; 视图层由JSP页面负责响应渲染, 结构与样式分离; 数据访问层为每张核心业务表封装独立的数据访问对象, 所有数据库操作均采用参数化查询执行, 在语法层面消除SQL注入风险。三层之间通过业务实体对象传递数据, 避免跨层直接耦合。

5.5.2 用户认证与账户管理实现

(1) 登录实现:

登录服务端接收用户名与密码参数, 完成非空校验后查询数据库获取账号凭据与状态信息, 并对三种状态分别处理: 状态正常的账号加载完整用户信息, 检查并按需补建默认收藏歌单, 依据管理员权限标识跳转至用户主页或管理后台, 并将用户对象写入服务端会话; 冻结账号重定向至状态说明页并附带冻结原因与截止时间; 已注销账号重定向至状态说明页并提示相应信息。用户主动退出时, 服务端立即销毁会话并跳转至系统首页。登录页面如图5-2所示。

图5-2 系统登录页面

(2) 两步式注册实现:

注册采用两步引导流程, 如图5-3所示。第一步, 服务端对用户名与密码的非空性及唯一性进行校验, 通过校验后将账号基础信息写入用户表。第二步, 服务端接收用户所勾选的流派与歌手偏好并写入偏好字段, 随后触发推荐引擎冷启动流程生成初始推荐候选集, 同时建立“我喜欢的音乐”默认收藏歌单; 上述操作完成后自动执行登录逻辑, 用户无需手动登录即可进入主页。

图5-3 用户注册页面

图5-3 (续图) 用户注册页面

(3) 基本信息与安全设置

账户设置页面提供“个人信息”、“账户安全”、“账户管理”三个入口, 对应基本资料修改、密码变更与账号注销三项功能, 如图5-4所示。基本信息修改方面, 服务端对昵称、邮箱、手机号、性别与城市字段逐项进行格式校验: 昵称须在长度限制内且不含脚本注入类特殊字符, 邮箱须符合标准邮件地址格式, 手机号须符合中国大陆11位格式, 全部校验通过后更新数据库相应字段并同步刷新服务端会话。密码修改方面, 服务端先验证当前密码正确性, 再对新密码进行强度校验 (长度6-20位, 须至少包含字母、数字、特殊字符中的两类), 并确认新密码与当前密码不同, 校验通过后更新数据库密码字段并刷新会话。账号注销方面, 操作要求用户输入当前密码进行身份二次确认, 验证通过后服务端对账号执行软删除标记, 数据库外键约束自动级联清理关联的歌单与收藏记录, 随即销毁会话并重定向至首页; 密码错误或系统异常时保持会话不变并返回错误提示。

图5-4 账户设置页面

5.5.3 个性化推荐展示

个性化推荐是本系统的核心功能，推荐展示界面如图5-5所示。推荐数据由Python端推荐引擎离线运行后预先写入数据库推荐结果表，Java端负责按需读取并以JSON格式推送至前端渲染。服务端首先验证当前用户会话的有效性，未登录请求返回401状态。验证通过后按推荐综合评分降序读取当前用户的推荐列表，每次取5首并支持偏移量参数以实现“换一批”的滑动翻页效果，同时查询每首歌曲的收藏状态，将歌曲基础信息与收藏标记一并组装为JSON响应返回前端。前端推荐卡片展示封面、曲名、演唱者及操作按钮，用户点击播放或收藏后，行为数据通过反馈机制回写至推荐反馈表，供下次推荐计算参考，形成推荐→行为→更新→再推荐的数据闭环。

图5-5 个性化推荐展示页面

5.5.4 音乐搜索与播放收藏实现

搜索服务端接收关键词与来源参数（网易云/QQ/全部），以代理身份转发请求至外部接口中间服务，搜索结果如图5-6。针对异质响应结构实施解析，将标题、演唱者、封面及时长等映射为系统内部歌曲对象，选择“全部”来源时采用交替合并方式以实现均衡呈现。搜索阶段不执行数据入库，当触发播放或收藏时，服务端对外部歌曲执行两阶段去重，去重匹配字段为标题、演唱者与演唱者集合交集，并依次触发P1至P5五级降维元数据补全策略，利用网易云百科、MusicBrainz及本地检测等手段确保流派与语种字段完整，为推荐特征提取提供基础支撑。

在线播放基于HTML5原生能力实现，提供进度控制与模式切换。播放触发后启动前端计时器累计时长。切换歌曲或关闭页面时，通过异步请求上报标识与实际时长，服务端据此计算完播率并更新推荐反馈记录。执行收藏操作时，外部歌曲经去重入库与元数据补全后，由服务端关联用户默认歌单并清除缓存。若被收藏歌曲属于当日推荐条目，系统同步提升反馈评分并置位标记，形成显式正向反馈闭环，以此优化推荐算法的精准度。

图5-6 音乐搜索结果页面

5.5.5 歌单管理功能实现

歌单服务端以操作类型参数统一处理创建、添加歌曲、更新与删除四类请求，全部操作均先验证当前会话的有效性，其实现效果见图5-7。创建歌单时，服务端以用户标识与自定义名称建立新歌单记录（标记为非默认歌单）。添加歌曲时，若目标歌曲来自外部平台，服务端先执行与5.5.4节相同的两阶段去重入库流程，随后校验歌单归属权，通过后将歌曲加入歌单。更新歌单名称或描述时同样校验归属权；删除操作额外拦截对默认歌单（“我喜欢的音乐”）的删除请求，防止用户误删收藏容器。全部写入操作均以JSON格式返回操作结果。

图5-7 用户歌单管理页面

5.5.6 管理员后台功能实现

管理员后台以统一的服务入口接收操作类型参数，将请求路由至系统统计、用户信息管理、申诉管理、歌单管理、歌曲管理五个功能模块，所有请求均先校验会话中的管理员身份标识，非管理员请求直接拦截。

(1) 系统统计

统计模块聚合数据库中的用户总量、歌曲总量、播放记录数与推荐条目数四项关键指标，展示于数据看板，同时在后台静默执行保护期满30天的注销账号物理清理，如图5-8所示。

图5-8 管理员后台数据统计看板

(2) 用户信息管理

用户信息管理模块支持分页查询全部用户列表与单用户详情。账号冻结操作将账号状态更新为冻结并记录冻结原因与截止日期，而解冻操作则将状态恢复为正常。此外软删除操作将账号标记为已注销并设置30天数据保护期，期内数据完整保留。用户申诉审核通过后由申诉模块自动触发解冻或账号恢复，用户信息管理页面如图5-9示。

图5-9 管理员后台用户信息管理页面

图5-9 (续图) 管理员后台用户详情页面

(3) 歌曲管理

歌曲管理模块支持关键词分页搜索歌曲列表，可对歌曲执行添加、删除与编辑操作；编辑保存后自动清除服务端歌曲信息缓存，确保前端数据一致性。管理员还可在列表中直接预览播放歌曲，验证音频文件可用性，如图5-10所示。

图5-10 管理员后台歌曲管理页面

(4) 歌单管理

歌单管理模块以全局视角展示系统内所有用户的歌单列表，每条记录附带创建者信息与歌曲数量。管理员可查看任意歌单的歌曲明细，对违规歌单执行删除操作或从歌单中移除特定歌曲；系统对默认歌单（“我喜欢的音乐”）设有保护，禁止管理端强制删除用户的收藏容器，如图5-11所示。

图5-11 管理员后台歌单管理页面

(5) 申诉管理

申诉管理模块展示全部用户提交的申诉列表及详情，含申诉类型、原因与联系邮箱。批准申诉时，服务端修改申诉状态、解除账号冻结或注销标记，并通过异步线程向用户联系邮箱发送审核通过通知。而拒绝申诉时则同步更新状态并发送拒绝通知邮件，如图5-12所示。

图5-12 管理员后台申诉管理页面

5.5.7 隐式反馈采集实现

隐式行为侦测与显式意图采集构成系统获取用户反馈的双通路机制，共同驱动推荐引擎的持续迭代。在隐式通路中，用户触发播放后，前端计时器随即启动记录有效收听时长，待切歌、关页或自然结束任一事件发生时，前端以异步请求将歌曲编号与实际时长一并上报至服务端，服务端计算完播率后写入推荐反馈表并更新播放状态；完播率低于20%的行为被判定为跳曲，系统对该歌曲及艺人累计冷却分值，使其在后续候选排序竞争中自然靠后，抑制对用户明确抗拒内容的反复曝光。在显式通路中，用户可通过个人中心的口味反馈页面主动提交满意度评分与当前偏好的流派、歌手，服务端将上述数据写入口味反馈表——当日多次提交则后者覆盖前者——同时将偏好列表合并去重后同步更新至用户信息表并刷新会话中的偏好缓存，确保后续推荐计算使用最新的偏好配置。

5.6 本章小结

系统采用Python与Java两端协同架构，通过共享MySQL实例与C3P0连接池保障并发访问稳定性。利用PySpark对KKBOX数据集执行分布式ETL，经清洗后为排序各层构建涵盖画像、属性及嵌入的特征集。引入五折交叉验证下的折外目标编码以防范标签泄漏，并按时序划分训练集与验证集，确保评估语义与真实场景一致。

推荐管道由召回、粗排、精排及重排四层组成。ALS、FAISS与热度兜底三路通道共生成600首候选，LightGBM粗排层利用59维特征将规模压缩至300首，DeepFM与BST独立建模后经SLSQP权重融合取Top150进入重排，最终应用MMR算法兼顾相关性与多样性，输出50首结果写入数据库，各层排序性能评估见第六章。

前端MusicWeb基于MVC架构组织代码，实现了控制层与数据访问层的职能分离。功能覆盖引导式注册登录、个性化展示、多源搜索及元数据补全、在线播放收藏及歌单管理，并设有包含统计与审批功能的完整管理后台。

系统通过监测完播率与反馈数据驱动推荐动态调整，至此工程链路就绪，后续将从离线与在线维度对效果进行量化验证。本章内容将需求转化为设计，以指导后续的工程实现。

6 系统测试与评估

6.1 引言

第五章已完成涵盖特征工程管道、四层推荐算法、MusicWeb前端及隐式反馈采集等模块的全链路工程实现。

系统实现后，需对其推荐性能进行系统性验证。本章围绕推荐质量评估展开，分离线与在线两条路径，分别基于大规模公开数据集的历史记录与系统部署后的真实交互数据，对模型的排序精度与实际可用性进行量化分析。离线评估以KKBOX数据集中28172位用户的约73万条验证样本为基础，侧重算法的泛

化能力；在线评估则以真实用户的反馈为依据，直接反映系统对实际需求的满足程度。

两种评估方式相互补充，克服了单一维度的局限性，共同构成对系统能力的双轨验证体系。本章通过客观真切的实验数据表述，体现了对大数据专业知识的掌握与应用，符合本科毕业论文撰写规范的要求。

6.2 推荐效果评估

6.2.1 评估指标说明

离线评估选取命中率（HR@K）、精确率（Precision@K）、归一化折损累积增益（NDCG@K）与平均倒数排名（MRR）四项指标，从不同角度量化推荐结果的排序质量，上述指标均在Top-10推荐场景下计算（K=10）。

(1)命中率

命中率衡量系统能否将用户真正感兴趣的内容纳入推荐列表前K位，即验证集中至少命中一个正样本的用户占比，命中率越高说明系统对绝大多数用户均能在有限推荐位中呈现其偏好内容，公式见式（6-1）所示。

式中 U ——为验证集用户集合；

$|U|$ ——为用户总数；

$rank_u$ ——为用户u的真实正样本在推荐列表中的排名位置；

$1[\cdot]$ 为示性函数，当括号内条件成立时取值为1，否则为0。

(2)精确率

精确率衡量推荐列表中相关内容所占的比例，精确率越高说明系统推荐的内容中有用信息密度越大，用户无需在大量无关推荐中筛选目标，在音乐推荐场景下直接关联用户对推荐列表的整体满意度，公式见式（6-2）所示。

式中 L_u ——为系统为用户u生成的Top-K推荐列表；

U ——为用户u的真实正样本集合；

K ——推荐列表长度，本系统取 $K=10$ 。

(3)归一化折损累积增益

归一化折损累积增益在命中基础上引入排名位置的对数折损权重，对排名靠前的命中给予更高奖励，能够区分“排在第1位命中”与“排在第10位命中”的质量差异，更精细地反映系统将偏好内容优先排列于列表前端的能力，计算公式见式（6-3）和（6-4）所示。

式中 $IDCG_u$ ——为用户u在理想排序下的最大DCG值，即将该用户所有正样本置于列表最前端时所能达到的DCG上界；

DCG_u ——用户u的折损累积增益；

rel_i ——第i个推荐位置的相关性标签，命中正样本时取值为1，否则为0；

$\log_2(i+1)$ ——位置折损因子，使排名越靠后的命中贡献以对数速率递减；

K ——推荐列表长度，本系统取 $K=10$ ；

(4) 平均倒数排名

平均倒数排名以每位用户正样本首次出现位置的倒数取均值，对列表头部极为敏感，正样本出现在第1位贡献为1.0，出现在第5位仅为0.2，MRR高的系统不仅能命中用户兴趣，还能将最相关内容优先呈现，公式见式（6-5）所示。

式中 $rank_u$ ——为用户u的正样本在推荐列表中首次出现的排名位置；

$|U|$ ——为验证集用户总数。

6.2.2 不同模型AUC结果分析

为量化各模型在推荐管道中的独立贡献，分别对LightGBM粗排、DeepFM精排、BST精排及双模型（DeepFM+BST）Stacking集成四个层级进行验证集AUC评估，结果如图6-1所示。

图6-2 不同模型AUC得分

在单模型层面，三个模型的AUC呈现出与各自管道定位相符的差异分布。LightGBM作为粗排模型，以快速推理吞吐量换取适度精度，AUC为0.7648，其定位于毫秒级压缩候选规模，对精度的约束属于可接受的工程权衡。DeepFM通过因子分解机与深度神经网络联合建模捕捉高阶特征交叉，AUC为0.7434。BST引入Transformer自注意力机制对用户历史行为序列进行时序建模，能够感知行为的前后顺序依赖关系，AUC达到0.7761，成为三个子模型中精度最高的单模型。BST显著优于DeepFM（差距+0.0327），根本原因在于DeepFM对历史行为特征采用并列交叉建模，无法感知行为的顺序信息，而BST的序列感知能力弥补了这一不足。

在集成层面，SLSQP约束优化求解的最优融合权重为DeepFM:0.2、BST:0.8，Stacking集成AUC为0.7767，高于任一单模型，但与最优单模型BST的差距仅为0.0006。集成边际收益极小，说明两个精排模型的预测相关性较高，且权重高度集中于BST，表明BST已基本覆盖了DeepFM的预测信息，集成增益接近上限。

6.2.3 离线推荐效果评估

在完成子模型AUC横向对比后，进一步以Stacking集成模型的推荐结果为基础，在验证集上计算Top-10场景下的多维度排序质量指标，从命中覆盖、列表精度、位置感知精度与头部排序能力四个维度对推荐系统进行综合评估，结果如表6-1所示。

表格6-1 Stacking集成模型Top-10推荐质量离线评估指标

评估指标 计算场景 评估结果

HR@10 前10推荐至少命中1个正样本的用户比例 0.9955

Precision@10 前10推荐列表中正样本的平均占比 0.5954

NDCG@10 考虑排名位置权重的归一化折损累积增益 0.7963

7963

MRR 正样本首次出现排名位置倒数的用户均值 0.8728

由表6-1可以看出，集成模型在Top-10推荐场景下展现出较为均衡的综合排序能力。HR@10=0.9955，意味着验证集中约99.

55%的用户能够在前10条推荐中命中至少一首真实偏好歌曲，命中覆盖能力极高，与召回层三通道并联设计保障约600首候选多样性覆盖密切相关。

Precision@10=0.5954，离线评估采用用户级时序切分，验证集取每位用户最后10%的交互记录（含正、负样本），在近似均衡的正负样本分布下，模型将平均约59.

54%的正样本推至Top-10，明显优于随机基线（约50%），体现了集成模型对用户偏好的有效判别能力。NDCG@10=0.7963，在引入排名位置的对数折损权重后仍维持0.79以上的归一化增益，说明命中的正样本整体集中于推荐列表前端而非靠后的低权重位置，这与MRR的结果相互印证，而MRR=0.

8728意味着正样本平均首次出现在推荐列表的第1.15位附近，系统具备将用户偏好内容优先排列于列表头部的显著能力，与用户实际浏览时倾向于重点关注前几条推荐的行为习惯高度吻合。综合四项指标来看，系统在命中覆盖与头部排序两个维度上表现尤为突出，整体离线推荐质量满足个性化音乐推荐系统的工程预期。

6.2.4 在线推荐效果评估

受实际部署条件限制，在线评估仅基于有限用户样本进行，结论具有一定参考价值但不具备统计显著性，主要用于验证推荐管道工程实现的功能正确性。在线评估阶段，系统对两位测试用户的真实交互行为持续记录，累计产生377条推荐记录。

评估选取点击率、完播率、收藏率与跳曲率四项行为指标，其定义如下：点击率为用户点击播放推荐歌曲的次数占系统推荐展示总次数的比例；完播率为已播放歌曲的平均播放进度百分比；收藏率为用户对推荐歌曲执行收藏操作的次数占推荐展示总次数的比例；跳曲率为播放进度低于20%的歌曲占已播放歌曲总数的比例。

逐用户评估结果如表6-2所示。

由表6-2可以看出，两位用户在各项指标上存在明显差异，与其初始画像的丰富程度直接相关。用户j的历史行为数据源自长期在主流音乐平台积累的真

实收听记录, 偏好分布覆盖多个流派, 画像信息丰富, 推荐引擎能够充分利用其历史兴趣向量生成针对性推荐, 点击率达13.

26%, 收藏率为12.71%, 表明推荐内容与其实际偏好具有较高匹配度。用户jf2为系统上线后新注册的冷启动账号, 历史行为记录为零, 推荐引擎仅能依赖注册时填写的流派与歌手偏好触发热度兜底通道生成推荐, 点击率为5.

61%, 低于约7.65个百分点, 冷启动阶段的推荐精度受到用户画像稀疏性的制约, 但CTR仍维持在5%以上, 说明基于注册偏好的冷启动策略能够为新用户提供具有基本可用性的推荐内容。

两位用户的跳曲率均偏高, 完播率亦相对较低。这与音乐流媒体场景的用户行为规律一致, 用户在浏览推荐列表时普遍倾向于试听数秒后快速决定是否继续收听, 播放进度低于20%的跳过行为属于该场景下的正常收听模式, 并不直接等同于对推荐内容的否定。结合点击率与收藏率综合来看, 系统在已有偏好用户的个性化推荐与冷启动用户的兜底推荐两类场景下均实现了基本可用的功能验证。

表6-2 在线推荐效果评估指标汇总

评估指标 用户jf 用户jf2 累计推荐展示次数 181 196 有效点击次数 24 11 点击率 13.26% 5.61% 完播率 17.86% 12.52% 收藏率 12.71% 2.55% 跳曲率 79.17% 81.82%

6.3 在线与离线评估的差距分析

对比在线评估结果与离线评估结果, 两者在指标量级上存在明显差距。离线评估中HR@10高达0.9955, 表明集成模型在KKBOX历史数据上具备极强的候选覆盖能力; 而在线评估中, 具有丰富历史画像的用户jf点击率为13.26%, 冷启动用户jf2点击率仅为5.61%, 均远低于离线命中率水平。

造成这一差距的原因是多方面的。其一, 在评估语义层面, 离线评估以每位用户最后10%的交互记录作为正样本, 本质上考量的是模型对用户已知偏好的排序能力; 在线推荐面对的是受情绪、时间、场景等即时上下文因素影响的真实收听意愿, 两者评估目标并不等价。其二, 在样本规模层面, 离线验证集涵盖约73万条交互记录, 统计稳定性较高; 在线累计377条推荐记录, 样本量有限, 结论的统计代表性相对受限。其三, 在用户群体层面, 离线验证集来自全量活跃用户, 历史行为数据丰富; 在线评估中jf2为零历史记录的新冷启动用户, 画像稀疏性对推荐精度造成额外约束, 进一步拉低了整体在线表现。

上述分析表明, 离线与在线评估在评估视角上具有本质的互补性。离线评估以充足样本量衡量模型的泛化判别能力, 在线评估则直接反映推荐结果在真实用户需求与即时情境下的实际可用性, 两者共同构成对系统推荐能力的双轨验证体系, 不宜以单一维度替代对整体性能的综合判断。

6.4 本章小结

本章在第五章完成全链路工程实现的基础上, 以离线评估与在线评估双轨并行的方式对系统推荐性能进行了系统性验证。

在模型精度层面, LightGBM作为粗排模型以推理效率优先, DeepFM与BST分别从静态特征交叉与用户行为序列两个维度提供精排评分, BST凭借Transformer序列建模能力在三个子模型中精度最高。Stacking集成通过SLSQP约束优化以数据驱动方式确定两个精排模型的最优融合权重, 集成结果高于任一单模型, 验证了分层管道设计的合理性。

在离线排序质量层面, 集成模型在命中覆盖与头部排序两个维度上表现尤为突出, 四项排序指标整体均衡, 满足个性化音乐推荐的工程预期。在线评估阶段, 具有丰富历史画像的用户与冷启动用户之间的指标差距, 直接印证了用户画像丰富程度对推荐精度的影响。本章进一步从评估语义、样本规模与用户群体三个维度解释了离线与在线指标量级分化的成因, 指出两者在评估视角上具有本质的互补性, 共同构成对系统推荐能力的双轨验证体系。

结 论

本文基于KKBOX公开数据集, 设计并实现了由MusicWeb与MusicMode构成的个性化音乐推荐系统, 采用三路召回一粗排一精排集成一重排的四层推荐管道, Stacking集成验证集AUC为0.7767, 整体达到预期工程目标。

(1) 主要工作总结

在数据与算法方面, 系统在五折交叉验证框架下采用折外目标编码方案, 从工程层面隔绝高基数类别特征的标签泄漏风险。推荐管道以FAISS向量检索、ALS协同过滤与热度兜底三路并联召回约600首候选, 经LightGBM粗排压缩至300首, DeepFM与BST双精排模型深度评分后经SLSQP优化加权融合, MMR重排输出Top-50推荐列表, 并根据用户行为丰富度动态切换召回路径, 保障冷启动与活跃用户两类场景的推荐可用性。

在工程与评估方面, 前端平台MusicWeb基于MVC架构实现了注册登录、个性化推荐、音乐播放与收藏、歌单管理及管理员后台等完整功能, 通过节流机制异步采集播放行为, 构建推荐反馈闭环。在线评估基于2位用户共377条推荐记录展开, 冷启动与有偏好用户两类场景均实现了可用的推荐效果。

(2) 创新点

第一, 将折外目标编码策略应用于推荐系统特征工程, 在五折框架下隔绝标签信号的反向渗漏, 提升了模型泛化能力与评估结论的可靠性。第二, 构建了LightGBM粗排与DeepFM、BST精排协同的分层集成架构, 三个模型分别从梯度提升、高阶特征交叉与行为序列时序建模三个维度捕捉用户偏好, 经SLSQP约束优化实现双模型互补融合, 集成AUC达到预期目标, 初步验证系统的有效性。第三, 设计了基于用户行为丰富度的动态分层召回路由机制, 依据历史交互规模自动选择对应召回通道, 在冷启动与活跃用户两类场景下均保障了推荐内容的基本可用性。

(3) 不足与展望

系统部署于单机环境, 缺乏生产级容灾保障。在线评估仅涉及2位用户共377条推荐记录, 统计代表性不足。冷启动场景下推荐引擎依赖注册偏好与热度兜底, 偏好画像精细度与活跃用户相比仍有差距。后续可向微服务与容器化部署演进, 引入流式行为更新机制以缩短推荐响应延迟, 并结合知识图谱对歌曲语义显式建模, 提升长尾曲目的推荐覆盖能力。

参考文献

- [1]赵吉. 基于Spark的个性化音乐推荐系统设计与实现 [D]. 长春: 吉林大学, 2022.
- [2]杨率. 基于深度神经网络的个性化实时音乐推荐系统研究与实现 [D]. 北京: 北京邮电大学, 2022.
- [3]李津. 基于知识图谱的个性化音乐推荐系统设计与实现 [D]. 北京: 北京交通大学, 2023.
- [4]冯亚寒. 基于WSM-CNN及其改进的音乐多情感分类方法研究与应用 [D]. 重庆: 西南大学, 2023.
- [5]吴亚迪, 陈平华. 基于用户长短期偏好和音乐情感注意力的音乐推荐模型 [J]. 广东工业大学学报, 2023, 40 (04): 37-44.
- [6]王慧心, 董向荣. 融合知识图谱的推荐系统研究进展 [J]. 浙江大学学报 (工学版), 2023, 57 (08): 1527-1540.
- [7]梁锋, 羊恩跃, 潘微科, 等. 基于联邦学习的推荐系统综述 [J]. 中国科学: 信息科学, 2022, 52 (05): 713-741.
- [8]郑楠, 章颂, 刘玉桥, 等. 基于深度学习的群组推荐方法研究综述 [J]. 自动化学报, 2024, 50 (12): 2301-2324.
- [9]闫猛猛, 汪海清, 贺建峰, 等. 基于自监督学习的序列推荐算法 [J]. 重庆邮电大学学报 (自然科学版), 2023, 35 (04): 722-731.
- [10]龚雪鸾, 陈艳姣, 王帅. 在线广告点击率预测方法的研究综述 [J]. 中文信息学报, 2023, 37 (04): 1-17.
- [11]Liu Z, Xu W, Zhang W, et al. An emotion-based personalized music recommendation framework for emotion improvement [J]. Information Processing & Management, 2023, 60(3): 103256.
- [12]Wang D, Zhang X, Yin Y, et al. Multi-view enhanced graph attention network for session-based music recommendation [J]. ACM Transactions on Information Systems, 2023, 42(1): 16.
- [13]Li L, Tao D, Zheng C, et al. Attentive autoencoder for content-aware music recommendation [J]. CCF Transactions on Pervasive Computing and Interaction, 2022, 4(1): 76-87.
- [14]Mao Y, Zhong G, Wang H, et al. Music-CRN: An efficient content-based music classification and recommendation network [J]. Cognitive Computation, 2022, 14(6): 2306-2316.
- [15]Paul S, Singh S, Rajbhoj S. Personalized music recommendation system [EB/OL]. (2021-01) [2026-03-18]. <https://ssrn.com/abstract=3772631>.
- [16]Niu X, Wang J, Chen X. Collaborative filtering-based music recommendation in Spark [J]. Mathematical Problems in Engineering, 2022: 1-12.
- [17]Johnson J, Douze M, Jegou H. Billion-scale similarity search with GPUs [J]. IEEE Transactions on Big Data, 2021, 7(3): 535-547.
- [18]Wang X, Li Q, Yu D, et al. Neural causal graph collaborative filtering [J]. Information Sciences, 2024, 680: 120872.

[19]TRAN V A, SALHA-GALVAN G, HENNEQUIN R, et al. Transformers meet ACT-R: repeat-aware and sequential listening session recommendation[C]// Proceedings of the 18th ACM Conference on Recommender Systems. New York: ACM, 2024: 486-496.

[20]CHEN Q, ZHAO H, LI W, et al. Behavior sequence transformer for e-commerce recommendation in Alibaba[C]// Proceedings of the 1st International Workshop on Deep Learning Practice for High-Dimensional Sparse Data. New York: ACM, 2019: 1-4.

致 谢

总觉得来日方长，毕业无期，行文至此，也百感交集。

人生中有许多节点，有些走得轻盈，有些却走得深重。这两年，无疑是我求学轨迹里权重最大的一段。从2025年冬日敲下第一行字，到如今数月间的字斟句酌、反复推敲，其间的甘苦，犹如一次漫长且充满未知的模型训练。二十四岁，不算年轻，却也不算老，刚好是一个人应当学着对自身命运按下“回车键”的年纪。这篇论文，便是在这个路口，交出的一份最为诚恳的答卷。

最深的谢意，首先要献给我的指导老师王波老师。在这场漫长的学术马拉松里，无论是线上的探讨还是线下的指点，王老师从未缺席。从最初选题时帮我锚定方向，到系统框架构建中的反复斟酌，再到初稿里那些我自以为严密、实则逻辑断层的段落，王老师的每一次批注都能直击要害，绝不以空洞的套话敷衍。学问之道，贵在真诚与严谨。正是王老师如同底层代码般扎实而耐心的引导，才让这篇论文得以拨开冗杂的噪点，一步步走向清晰。师恩如海，我将永远铭记。

感谢广州华立学院计算机工程学院的每一位任课老师。两年的光阴里，算法、数据库、分布式计算、机器学习……这些名词在黑板上出现时，我未必真切地感受到它们的重量。然而，当我真正坐在屏幕前，开始搭建这套个性化音乐推荐系统时，我才陡然发觉，那些曾经以为枯燥的知识，早已悄无声息地沉入地基，支撑起了整个系统的每一处细节。知识的给予往往是无声的，却总能在你最需要的时候，化作最坚实的算力。

最深沉的感激，要留给我的家人。他们或许永远弄不懂什么是协同过滤，什么是推荐算法，也看不明白终端里跳动的代码，但这从未妨碍他们给予我百分之百的爱。十七年的求学路，每一次跌倒与迷茫，都有他们在身后稳稳托底。他们不苛求我取得多耀眼的成绩，只求我平安顺遂。这份爱，不张扬、不喧哗，却是我人生长河里最不可或缺的前行动力，也是我越过所有难关时最踏实的依靠。

行文至此，这段学生时代的故事即将画上句点。但这并非终局，只不过是跳出了当前的循环，准备去往一个更广阔的天地重新运行。二十四岁，往后的路还长，愿我能走得踏实，走得辽阔，带着这十七年积攒的所有勇气，去迎接真实世界里更为庞杂的数据洪流。

欲买桂花同载酒，终不似，少年游。谨以此篇，献给所有陪我走过这段时光的人。

附 录

附件：

表4-1 用户表结构

字段名 数据类型 约束 说明

id INT PK,AUTO_INCREMENT 用户主键

username VARCHAR(50) UNIQUE NOT NULL 用户名

password VARCHAR(255) NOT NULL 密码

email VARCHAR(100) — 邮箱

nickname VARCHAR(50) — 昵称

phone VARCHAR(20) — 手机号

status ENUM NOT NULL active/frozen/deleted

frozen_until TIMESTAMP — 冻结截止时间

frozen_reason VARCHAR(255) — 冻结原因

deleted_at TIMESTAMP — 逻辑删除时间

preferred_genres VARCHAR(255) — 偏好流派

preferred_artists VARCHAR(255) — 偏好艺术家

create_time TIMESTAMP DEFAULT NOW() 注册时间

表4-2 歌曲表结构

字段名 数据类型 约束 说明

id INT PK,AUTO_INCREMENT 歌曲主键

title VARCHAR(255) NOT NULL 歌名

artist VARCHAR(255) — 歌手

album VARCHAR(255) — 专辑

duration INT — 时长 (秒)

genre VARCHAR(100) — 流派

genre_ids VARCHAR(255) — KKBOX原始流派ID列表

字段名 数据类型 约束 说明

language VARCHAR(10) — 语言代码

release_year INT — 发行年份

kkbox_id VARCHAR(100) — KKBOX原曲ID

popularity INT DEFAULT 0 歌曲热度

origin_country VARCHAR(50) — 原产地

cover_image VARCHAR(500) — 封面图片路径

表4-3 播放历史表结构

字段名 数据类型 约束 说明

id INT PK,AUTO_INCREMENT 主键

user_id INT FK→users.id NOT NULL 用户ID

song_id INT FK→songs.id NOTNULL 歌曲ID

play_time TIMESTAMP NOT NULL 播放时间

表4-4 用户歌单表结构

字段名 数据类型 约束 说明

id INT PK,AUTO_INCREMENT 主键

user_id INT FK→users.id NOT NULL 创建者ID

name VARCHAR(100) NOT NULL 歌单名称

description TEXT — 歌单描述

cover_image VARCHAR(500) — 歌单封面

is_default TINYINT(1) DEFAULT 0 是否为默认收藏夹

create_time TIMESTAMP DEFAULT NOW() 创建时间

update_time TIMESTAMP DEFAULT NOW() 最后更新时间

表4-5 歌单歌曲关联表结构

字段名 数据类型 约束 说明

id INT PK,AUTO_INCREMENT 主键

playlist_id INT FK→user_playlists.id NOT NULL 歌单ID

song_id INT FK→songs.id NOT NULL 歌曲ID

add_time TIMESTAMP DEFAULT NOW() 添加时间

表4-6 推荐结果表结构

字段名 数据类型 约束 说明

id INT PK, AUTO_INCREMENT 主键

user_id INT FK→users.id NOT NULL 目标用户ID

song_id INT FK→songs.id NOT NULL 推荐歌曲ID

score DOUBLE — 集成推荐得分

source_type VARCHAR(20) DEFAULT 'deepfm' 推荐来源标记

create_time DATETIME DEFAULT NOW() 推荐生成时间

表4-7 推荐反馈表结构

字段名 数据类型 约束 说明

id INT PK,AUTO_INCREMENT 主键

user_id INT FK→users.id NOT NULL 用户ID

song_id INT FK→songs.id NOT NULL 歌曲ID

recommend_date DATE NOT NULL 推荐日期

was_played TINYINT(1) DEFAULT 0 是否已播

表4-7(续表) 推荐反馈表结构

字段名 数据类型 约束 说明

play_completion FLOAT — 播放完成度 (0~1)

was_favorited TINYINT(1) DEFAULT 0 是否已收藏 (0/1)

consecutive_ignore_days INT DEFAULT 0 连续忽略天数

feedback_score FLOAT DEFAULT 0 综合反馈得分

cooldown_until DATE — 推荐冷却期截止日

created_at TIMESTAMP DEFAULT NOW() 记录创建时间

updated_at TIMESTAMP DEFAULT NOW() 最后更新时间

表4-8 用户口味反馈表结构

字段名 数据类型 约束 说明

id INT PK,AUTO_INCREMENT 主键

user_id INT FK→users.id NOT NULL 用户ID

feedback_date DATE NOT NULL 反馈日期

satisfaction ENUM NOT NULL 用户满意度

genres_added VARCHAR(255) — 新增偏好流派

artists_added VARCHAR(255) — 新增偏好艺术家

created_at TIMESTAMP DEFAULT NOW() 记录创建时间

表4-9 申诉表结构

字段名 数据类型 约束 说明

id INT PK,AUTO_INCREMENT 主键

username VARCHAR(50) NOT NULL 申诉账号名

user_id INT FK→users.id 关联用户ID

appeal_type ENUM NOT NULL frozen/deleted

reason TEXT — 申诉理由

contact_email VARCHAR(100) — 联系邮箱

status ENUM DEFAULT 'pending' pending/approved/rejected

admin_reply TEXT — 管理员回复内容

create_time TIMESTAMP DEFAULT NOW() 申诉创建时间

update_time TIMESTAMP DEFAULT NOW() 最后处理时间

表4-10 用户屏蔽内容表结构

字段名 数据类型 约束 说明

id INT PK,AUTO_INCREMENT 主键

user_id INT FK→users.id NOT NULL 用户ID

block_type ENUM NOT NULL 屏蔽类型

block_value VARCHAR(100) NOT NULL 屏蔽的流派名或歌手名

block_count INT DEFAULT 1 屏蔽次数

blocked_at TIMESTAMP DEFAULT NOW() 最近一次屏蔽时间

blocked_until DATE NOT NULL 屏蔽到期日

is_active TINYINT(1) DEFAULT 1 是否生效 (1/0)

表4-11 歌曲滚动统计表结构

字段名 数据类型 约束 说明

song_id INT PK,FK→songs.id,NOTNULL 歌曲ID (主键, 与歌曲主表一对一)

cnt_7d INT NOT NULL,DEFAULT 0 近7天播放次数

cnt_30d INT NOT NULL,DEFAULT 0 近30天播放次数

trending FLOAT NOT NULL,DEFAULT 0 热度趋势 (7天播放量/30天日均+1)

total_plays BIGINT NOT NULL,DEFAULT 0 累计总播放次数

updated_at TIMESTAMP NOT NULL,DEFAULT NOW() ON UPDATE NOW() 最后更新时间

2

说明

- 1.疑似 AIGC 全文占比=重度疑似AIGC生成的字符数/全文总字符数
- 2.重度疑似占比=重度疑似AIGC生成的字符数/全文总字符数
- 3.轻度疑似占比=轻度疑似AIGC生成的字符数/全文总字符数
- 4.红色文字表示重度疑似,黄色表示轻度疑似
- 5.AIGC占比与文章质量无必然联系,检测结果仅供参考。是否存在学术不端行为,最终需通过人工复核、机构审查与具体学术政策的综合应用,作出审慎判断。

大雅相似度分析官方检测网站: <https://www.dayainfo.com>

大雅AIGC检测